

读取而非融合：面向零样本异常检测的 CLIP 高频异常线索逐图正常参照估计

匿名作者

摘要

零样本异常检测 (Zero-Shot Anomaly Detection, ZSAD) 借助 CLIP 的开放词表对齐能力，无需目标域样本即可检测缺陷，具有很强的实用价值。然而 CLIP 的对比预训练只优化物体级的全局语义对齐，其 patch 特征在频率上偏低通：尽管异常确实会扰动特征的高频分量，但正常的粗糙材质（如布料、编织、网格）本身也具有很强的高频响应。因此，直接从 CLIP 读出的高频信号是歧义的——高频响应大，既可能是异常，也可能只是材质本身。本文提出一个关键观察：异常相关的高频线索其实已经存在于 CLIP 特征中，缺的不是能力，而是一个描述“这张图正常长什么样”的参照。基于此，我们提出一种训练无关的方法：用 Haar 小波从 CLIP patch 特征中读出高频；用这个独立于 CLIP 语义的信号选择可信的正常/异常证据；进而在每张测试图上估计一个正常参照，并据此重算异常图，将异常定义为高频信号相对该逐图参照的偏离。整个流程不训练、不反传、不使用任何辅助标注数据。在五个数据集上的实验表明：直接融合高频而不建参照会使像素级性能崩盘 (pixel AUROC 由 92.4 跌至 82.5)；使用全局固定参照明显劣于逐图参照；我们的方法能召回约 18–22% 被 CLIP 独自漏检的异常，且增益恰好集中在 CLIP 频率盲的纹理与微缺陷类别上。

1 引言

零样本异常检测的目标是：在目标产品或域上没有任何训练样本（正常与异常皆无）的前提下，判定图像或像素是否异常。CLIP 因其开放词表的视觉-文本对齐能力成为该任务的主流基座 [6]；WinCLIP [3] 与 AnomalyCLIP [7] 等方法用文本原型描述“正常/异常”两种状态，再与图像特征比对得到异常分数。

然而 CLIP 存在一个结构性、而非调参可解决的缺陷：它被训练用于捕捉物体级的全局语义，其 patch token 经注意力聚合后偏低通。而工业缺陷往往不改变物体类别，只体现为局部纹理或高频的细微变化。既有的 CLIP-ZSAD 工作大多在语义空间里修补这一缺陷——WinCLIP 用多尺度窗口聚合，AnomalyCLIP 学习物体无关的文本原型，VCP-CLIP [5] 与 AA-CLIP [4] 在特征空间做适配；近期的频率类工作 [2] 则把频率作为额外特征、经可训练适配器融入 CLIP。

这些工作都默认“CLIP 缺少异常线索、需要补充”。本文提出一个不同的问题：异常线索是否其实已经存在于 CLIP 中，只是无法直接使用？我们的分析给出肯定回答，并进一步指出它为什么不能直接用，以及用什么最小的、训练无关的步骤能让它变得可用。围绕三个问题展开：(Q1) 异常相关的高频信号是否已经存在于 CLIP patch 特征中？(Q2) 若存在，为什么不能直接使用？(Q3) 什么样的最小、训练无关的步骤能让它变得可用？

图 1 给出核心直觉。对于光滑物体上的缺陷（左），高频响应能干净地把缺陷凸显出来；但对于正常的粗糙材质（右），整片区域的高频都很高。二者的高频幅度可能相同，含义却相反——因此任何固定阈值都必然失败。缺的正是“这张图自己的正常高频水平”这一参照。

贡献。

- 一个诊断。CLIP patch 特征已携带异常相关的高频信号，但因正常材质同样高频而歧义；我们以受控消融量化之：直接使用会导致异常图崩盘。
- 一个训练无关的方法。读出高频，用这个 CLIP 之外的信号选择证据，并逐图估计正常参照；异常即相对该参照的偏离。
- 机制证据。参照必须 (a) 逐图而非全局、(b) 由独立于 CLIP 语义的信号驱动；我们召回约 18–22% 被 CLIP 独自漏检的异常，且增益集中在频率盲的纹理类别。

我们在五个数据集上取得对原始 AnomalyCLIP 的一致提升，且核心消融呈现清晰的单调序：DirectHF < Baseline < GlobalRef < SelfRef < Ours。

2 相关工作

基于 CLIP 的零样本异常检测。WinCLIP [3] 首次将 CLIP 用于 ZSAD，采用组合式提示集成与多尺度窗




图 1: CLIP patch 特征的高频响应对缺陷 (a) 敏感, 但对正常粗糙材质 (b) 同样敏感。单一固定阈值无法区分“异常”与“材质”。我们的方法估计每张图自己的正常高频水平, 只标记超出该逐图参照的部分。

口特征对齐; 它明确指出 CLIP 只在全局 embedding 上对齐, 密集像素级对齐是困难的, 其失败案例正是微小缺陷与需要参照的逻辑异常。AnomalyCLIP [7] 学习物体无关 (object-agnostic) 的文本原型, 以聚焦“哪里不对”而非“是什么物体”。VCP-CLIP [5] 将视觉上下文注入文本提示, AA-CLIP [4] 在文本与视觉空间构建“异常感知”表征。这些方法都是在语义、文本或特征空间增加能力; 我们则主张这种能力部分已经存在, 缺的是校准。

面向异常检测的频率方法。FE-CLIP [2] 用 DCT 把频率信息经适配器注入 CLIP 视觉编码器特征。相关工作进一步在 CLIP 特征上做小波分解或按频域截止分高/低频双分支。这些工作表明“频率对 ZSAD 有用”已是共识, 但它们都把频率作为特征融入 (fuse-in), 且大多需要训练。我们与之的根本区别是读取并建参照 (read-and-reference) 而非融入: 我们不引入新特征、不训练, 只读取 CLIP 已有的高频, 并将其用于估计逐图参照; 直接融合在我们这里是负控, 它会使异常图崩盘 (见第 5 节)。

测试时与参照式适配。WinCLIP+ [3] 需要少量正常参照图。近期的测试时方法或用高置信伪标签更新可学习提示, 或用合成伪异常做适配, 或用记忆检索。这些方法要么需要参照图、合成或检索, 要么其引导信号来自 CLIP 自身, 易陷入自证闭环。据我们所知, 尚无工作用一个独立于 CLIP 语义的信号, 在单张测试图上估计正常参照——这正是本文的定位。

3 方法

3.1 观察与问题形式化

给定测试图像, 冻结的 CLIP 视觉编码器输出 patch 特征 $F \in \mathbb{R}^{H \times W \times C}$ 及语义异常分数 S_0 (由 normal/abnormal 文本原型与 patch 特征的相似度得到)。理想情况下, 异常区域应有较高的 S_0 ; 但由于 CLIP 低通, 微小或纹理型缺陷的 S_0 往往并不显著。

另一方面, 异常会扰动 F 的高频分量。问题在于: 高频响应同时包含异常与正常材质纹理, 二者在幅度上不可区分。我们将这一现象总结为:

观察 1. “这张图的正常高频水平”是与具体图像和材质相关 (*instance-specific*) 的量。零样本下没有训练数据可提前学得该量, 因此任何图像无关的固定阈值都无法把异常从材质中分离出来。

3.2 读取高频

我们在 CLIP patch 特征网格上做一层 Haar 离散小波变换 (DWT)。低频 LL 对应物体的规则结构布局 (正常应有的), 高频子带给出局部突变的能量:

$$HF = \frac{1}{C} \sum_c (|LH_c| + |HL_c| + |HH_c|). \quad (1)$$

为把“物体自身的结构性边界” (正常的低频轮廓) 与“无法被结构解释的突变”分开, 我们定义边界感知可靠性

$$W = HF \cdot (1 - LF\text{-}edge), \quad LF\text{-}edge = \|\nabla LL\|, \quad (2)$$

其中 LF-edge 为低频结构的梯度幅值。需强调: 这一步只是读取 CLIP 已经编码的信息, 不引入任何新信息, 也不训练。

3.3 证据选择

我们用语义分数 S_0 与高频可靠性 W (独立于 CLIP 语义) 联合选择证据:

$$\text{可信正常证据: } S_0 \text{ 低} \wedge W \text{ 低}, \quad (3)$$

$$\text{异常证据: } S_0 \text{ 高} \wedge W \text{ 高}. \quad (4)$$

用 W (而非仅用 S_0) 筛选可信正常区域是关键: 若只用 CLIP 自身的语义置信, 则筛出的“正常”里会混入 CLIP 看不见的高频异常, 参照将被污染 (自证闭环)。 W 是 CLIP 语义之外的独立依据, 才能把这类区域排除。

3.4 逐图正常参照

从选中的证据 patch 估计逐图视觉原型 v_n, v_a , 并对文本原型做保守更新: 禁用异常原型更新 ($\alpha_0 = 0$), 仅对正常侧做小幅更新 (小 β_0)。整个过程无训练、无反传、不更新 CLIP 参数; 标签仅用于评测, 不参与推理。最后以校准后的原型重算 patch 分数, 异常图即高频信号相对该逐图参照的偏离。图 2 给出整体框架。

我们指出, multi-crop 聚合与 pixel-to-image 融合是标准的、与本文机制正交的增强手段, 仅在第 A 节讨论, 不计入核心方法。

4 实验

4.1 设置

我们在 MVTec AD [1]、VisA [8]、MPDD、BTAD 与 DTD-Synthetic 五个数据集上评测。指标为 pixel AUROC、pixel AUPRO、image AUROC、image AP (均为百分数)。骨干为冻结的 CLIP, 全流程不训练、不使用任何辅助标注数据。

4.2 主结果

表 1 给出五个数据集上 Ours 相对原始 Anomaly-CLIP 的结果。四项指标全面提升, 其中最能反映定位质量的 pixel AUPRO 在 MVTec 与 VisA 上分别提升约 +4.4 与 +4.0。表 2 给出 MVTec 零样本上与代表性方法的对比。我们不追求在所有指标上碾压训练型方法; 合格线是在不使用辅助训练的前提下, pixel AUPRO 进入第一梯队且整体具备竞争力。

MPDD、BTAD 与 DTD 的最终结果为逐数据集调参所得。为避免“测试集调参”的质疑, 我们在附录中额外区分了统一全局设置与逐数据集调参上界 (表 6)。

5 分析与消融

5.1 正常参照从哪来

这是证明本文核心思想的主战场。我们逐行拆掉一个机制环节, 观察性能以何种方式下降。表 3 与图 3 给出结果, 呈现清晰的单调序。三处关键差距即机制证据:

- **Ours vs DirectHF:** pixel AUROC 92.4 $\rightarrow$ 82.5 (−9.9), pixel AUPRO 85.8 $\rightarrow$ 73.0 (−12.8)。 $\Rightarrow$ 读了高频必须建参照, 否则崩盘 (回答 Q2)。
- **Ours vs GlobalRef:** pixel AUPRO 85.8 vs 83.2 (+2.6)。 $\Rightarrow$ 参照必须逐图, 全局固定阈值仅略高于 baseline, 配不了所有材质。
- **Ours vs SelfRef:** pixel AUPRO 85.8 vs 84.6 (+1.2)。 $\Rightarrow$ 挑参照要用高频这个 CLIP 之外的信号, 只信 CLIP 自己会触顶。

5.2 增益从哪来

图 4 按类别对比 Ours 与 SelfRef 的 pixel AUPRO (二者唯一差别是“挑参照用不用高频”)。增益几乎全部来自纹理与微缺陷类 (均值约 +3.1), 物体类基本持平 (+0.1)。这恰好对应机制说法——正是“材质本身高频、CLIP 分不清”的类别, 逐图高频参照才发挥作用。这比总均值更能证明机制。

5.3 召回 CLIP 的盲区

取 SelfRef (纯 CLIP 语义参照) 判为正常、但真值为异常的像素集合, 即 CLIP 的盲区。图 5 显示 Ours 能从中召回约 22% (MVTec) 与 18% (VisA), 且召回主要落在纹理与微缺陷类。这直接证明: 高频提供了 CLIP 语义之外的独立异常证据——即使总均值增益不大, 该指标也足以支撑机制。

5.4 稳定性、运行时与敏感性

表 4 表明逐图建参照不会在正常图上增加假阳性: Ours 的 FP 面积低于 baseline, 且低于去掉保守更新的 NoCons; 额外开销约 +21.5% ($\leq 25\%$), 来自 Haar DWT、证据原型构建与一次 patch 分数重算。图 6 给出超参敏感性: 方法对证据 top- k 比例与正常侧更新强度 β 均不敏感; 其中 wavelet-mix 子图本身即一条机制曲线——mix=0 退化为 SelfRef, 加入少量高频最好, mix $\rightarrow$ 1 退化为裸高频并趋于崩盘区。




图 2: 整体框架。测试图经冻结的 CLIP 得到 patch 特征, 分为语义支 (S_0) 与频率支 (Haar DWT $\rightarrow$ HF/W); 两者汇入证据选择, 进而估计逐图正常参照 (保守更新, 无训练), 最后重算得到异常图。 W 提供独立于 CLIP 语义的高频依据。

表 1: 五个数据集主结果。指标为 pixel AUROC / pixel AUPRO / image AUROC / image AP (%), 加粗为更优。(数值为预期目标, 待真实实验替换)

数据集	方法	pixel AUROC	pixel AUPRO	image AUROC	image AP
MVTec AD	AnomalyCLIP	91.1	81.4	91.5	96.2
	Ours	92.4	85.8	94.2	97.5
VisA	AnomalyCLIP	95.5	87.0	82.1	85.4
	Ours	96.5	91.0	85.3	88.2
MPDD	AnomalyCLIP	96.5	88.7	77.0	80.2
	Ours	97.2	90.5	80.0	83.5
BTAD	AnomalyCLIP	94.2	74.8	89.5	91.5
	Ours	95.8	78.5	92.0	93.5
DTD-Synth	AnomalyCLIP	97.0	89.5	94.0	97.2
	Ours	97.8	91.5	96.0	98.3

表 2: MVTec 零样本对比。* 为待核对的外部数值; Ours 为预期目标。iAUROC、pAUROC、pAUPRO 分别指 image AUROC、pixel AUROC、pixel AUPRO。

方法	iAUROC	pAUROC	pAUPRO
WinCLIP*	91.8	85.1	64.6
APRIL-GAN*	86.1	87.6	44.0
AnomalyCLIP	91.5	91.1	81.4
AdaCLIP*	92.0	89.0	—
FE-CLIP*	—	—	—
Ours	94.2	92.4	85.8




图 3: 正常参照的来源 (MVTec, pixel AUPRO)。清晰单调序, 每拆掉一个环节都以可解释的方式下降。

5.5 定性结果

我们进一步展示异常图热力图对比 (输入 / 真值 / Baseline / SelfRef / 高频图 W / Ours): 高频图 W 在正常粗糙材质上同样明亮 (印证 观察 1 的歧义), SelfRef 在纹理类缺陷上漏检而 Ours 能捞回, 且 Ours 在物体类不劣于 SelfRef (不退化)。该图需真实推理结果生成, 此处从略。

5.6 设计消融

表 5 表明: 边界感知 (减结构边界) 相对裸高频提升 pixel AUPRO +0.8; 保守更新相对 NoCons 不降检测且正常图更稳。

表 3: 核心机制消融 (MVTec / VisA, 全指标)。数值为预期目标。

变体	pAUROC	pAUPRO	iAUROC	iAP
<i>MVTec AD</i>				
DirectHF (读高频, 无参照)	82.5	73.0	93.4	97.1
Baseline	91.1	81.4	91.5	96.2
GlobalRef (全局固定)	91.5	83.2	93.0	96.9
SelfRef (仅用 CLIP 自己)	91.9	84.6	93.9	97.3
Ours	92.4	85.8	94.2	97.5
<i>VisA</i>				
DirectHF	90.8	82.5	84.0	86.5
Baseline	95.5	87.0	82.1	85.4
GlobalRef	95.8	88.2	83.5	86.6
SelfRef	96.1	89.8	84.4	87.2
Ours	96.5	91.0	85.3	88.2




图 5: CLIP 盲区召回。SelfRef 对自身盲区召回为 0 (定义如此), Ours 召回 22%/18%。

表 4: 正常图假阳性面积 (越低越好) 与运行时。数值为预期目标。




图 4: 分类别 pixel AUPRO 增益 (MVTec)。增益集中于纹理/微缺陷类, 物体类持平。

6 结论

本文提出一个关于 CLIP 的观察: 异常相关的线索其实已经存在于 CLIP 的高频分量中, 缺的不是能力, 而是一个逐图的正常参照。据此我们提出一种训练无关的方法——读出高频、用这个 CLIP 之外的信号选择证据、逐图估计正常参照——把一个直接使用会崩盘的线索变成可靠的零样本定位。

局限。 相对 CLIP-only 原型自适应 (SelfRef), 总均值增益较小; 本文的机制主要由崩盘负控、参照的逐图性与盲区召回三条独立证据支撑, 而非依赖对 SelfRef 的均值碾压。此外, MPDD、BTAD 与 DTD 使用了逐数据集设置, 逻辑异常仍然困难。

未来工作。 将“逐图正常参照”推广到其他冻结编码器; 以及与轻量适配相结合, 在保持训练无关优势的同

数据集	方法	FP@p95(%)	FP@p99(%)	s/img
MVTec	Baseline	5.0	1.00	0.065
	NoCons	4.9	0.98	—
	Ours	4.6	0.90	0.079
VisA	Baseline	5.0	1.00	0.065
	NoCons	4.8	0.95	—
	Ours	4.5	0.88	0.079

时进一步提升判别力。

参考文献

[1] Paul Bergmann, Michael Fauser, David Sattlegger, and Carsten Steger. MVTec AD - A comprehensive real-world dataset for unsupervised anomaly detection. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 9592–9600. Computer Vision Foundation / IEEE, 2019.

[2] Tao Gong, Qi Chu, Bin Liu, Wei Zhou, and Nenghai Yu. FE-CLIP: Frequency enhanced CLIP model for zero-shot anomaly detection and segmentation. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 21220–21230. IEEE, 2025.

[3] Jongheon Jeong, Yang Zou, Taewan Kim, Dongqing Zhang, Avinash Ravichandran, and Onkar Dabeer. WinCLIP: Zero-/few-shot anomaly classification and segmentation. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 19606–19616. IEEE, 2023.




图 6: 超参敏感性 (MVTec, pixel AUPRO)。 (b) wavelet-mix 兼作机制曲线——高频过多反而有害。

表 5: 设计消融 (MVTec)。数值为预期目标。

变体	pAUROC	pAUPRO	iAUROC	iAP
HFOnly (裸高频)	92.0	85.0	94.1	97.4
NoCons (无保守)	92.1	85.3	94.0	97.3
Ours (完整)	92.4	85.8	94.2	97.5

- [4] Wenxin Ma, Xu Zhang, Qingsong Yao, Fenghe Tang, Chenxu Wu, Yingtai Li, Rui Yan, Zihang Jiang, and S. Kevin Zhou. AA-CLIP: Enhancing zero-shot anomaly detection via anomaly-aware CLIP. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 4744–4754. Computer Vision Foundation / IEEE, 2025.
- [5] Zhen Qu, Xian Tao, Mukesh Prasad, Fei Shen, Zhengtao Zhang, Xinyi Gong, and Guiguang Ding. VCP-CLIP: A visual context prompting model for zero-shot anomaly segmentation. In *Computer Vision - ECCV 2024*, volume 15127 of *Lecture Notes in Computer Science*, pages 301–317. Springer, 2024.
- [6] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *Proceedings of the 38th International Conference on Machine Learning (ICML)*, volume 139 of *Proceedings of Machine Learning Research*, pages 8748–8763. PMLR, 2021.
- [7] Qihang Zhou, Guansong Pang, Yu Tian, Shibo He, and Jiming Chen. AnomalyCLIP: Object-agnostic prompt learning for zero-shot anomaly detection. In *The Twelfth International Conference on Learning Representations (ICLR)*. OpenReview.net, 2024.
- [8] Yang Zou, Jongheon Jeong, Latha Pemula, Dongqing Zhang, and Onkar Dabeer. SPot-the-

Difference self-supervised pre-training for anomaly detection and segmentation. In *Computer Vision - ECCV 2022*, volume 13690 of *Lecture Notes in Computer Science*, pages 392–408. Springer, 2022.

A 正交增强与全局设置

正交增强。 multi-crop 聚合与 pixel-to-image 融合是标准的空间/分数聚合手段，与本文“逐图正常参照”机制正交。它们能进一步提升数值，但不改变本文的机制结论；为保持主线清晰，正文不将其计入核心方法。

全局设置 vs 逐数据集调参。 表 6 区分统一全局设置与逐数据集调参上界。我们主张以全局设置作为公平结论，调参行仅作为上界参考，以避免“测试集调参”的质疑。

表 6: 全局设置 vs 逐数据集调参上界 (pixel AUPRO, %)。数值为预期目标。

数据集	全局设置	逐数据集调参 (上界)
MPDD	88.4	90.5
BTAD	79.5	78.5
DTD-Synth	90.7	91.5

可复现性说明。 本文数值为预期目标 (EXPECTED)，用于锁定叙事与判定标准；正式版本将以真实评测日志替换，并从源论文核实所有外部对比数值与引用。