

频谱可靠性引导的测试时语义原型校准： 面向零样本异常检测的逐图参照构建

匿名作者

摘要

基于 CLIP 的零样本异常检测通常以固定的正常/异常文本原型解释目标类别，但固定原型难以描述单张测试图中的局部外观。直接从测试图构造视觉参照同样存在风险：仅依赖 CLIP 语义分数选择 patch 会继承其局部盲区，而直接把高频响应当作异常分数又会把规则纹理和物体边界误判为缺陷。本文提出一种频谱可靠性引导的测试时语义原型校准方法。我们在冻结的 CLIP patch 特征上施加 Haar 小波分解，以高频能量与低频结构边界的组合构造逐 patch 可靠性；随后将该可靠性作为语义证据的弱调制项，分别汇聚逐图正常与异常视觉原型，并以保守、非对称的方式校准固定文本原型。最终异常图仍由校准后的语义原型与 patch 特征的相似度产生，而非由频率图直接融合得到。该设计把小波从“异常评分器”重新定位为“逐图证据筛选器”，从而在保持 CLIP 语义空间可解释性的同时引入实例外观参照。本文给出面向五个数据集的主结果、直接融合负控、语义自参照对照、频谱设计消融、正常图稳定性和类别级分析方案。由于当前稿件用于冻结实验判据，表格中的数值为预期目标占位，正式版本将由真实评测结果替换。

1 引言

零样本异常检测的目标是在目标类别上不使用训练样本，直接判断图像或像素是否异常。CLIP [6] 提供了开放词表的视觉-文本对齐，使“正常”和“异常”能够被写成文本原型并迁移到未见类别。WinCLIP [3]、AnomalyCLIP [7] 等工作由此建立了基于语义原型的 ZSAD 范式：冻结视觉编码器，将 patch 特征与正常/异常文本原型比较，并把异常类别的相似度解释为局部分数。

这一范式的关键优点是跨类别泛化，但其参照是固定的。一组数据集级文本原型可以描述一般性的正常与异常，却难以覆盖单张图像的材质、结构和局部外观。同样的缺口也不能通过朴素的测试时自参照自动补齐：若只根据初始 CLIP 分数选择“可信正常 patch”，参照会继承原模型的局部盲区；若改用高频响应选择异常，规则纹理和物体边界又会被一并放大。换言之，逐图参照需要同时回答两个问题：哪些 patch 在语义上可信，以及哪些局部变化不像正常结构。

频率信息为第二个问题提供了天然线索。局部缺陷往往伴随 patch 特征场的高频变化，但高频本身并不是异常标签：布料、网格和清晰边界同样包含强高频。因此，本文不把小波响应直接加到异常图上，而是把它作为可靠性因子，用于调制语义证据并构造逐图视觉原型。该定位使语义与频谱承担不同职责：语义分数决定 patch 更接近“正常”还是“异常”，频谱可靠性判断该语义证据是否可能被局部结构混淆。

图 1 展示这一动机。光滑表面上的缺陷与正常粗糙纹理都可能产生显著高频响应；高频图无法独立完成判别，但能够指出哪些语义证据需要谨慎使用。我们据此从测试图中汇聚正常/异常视觉原型，再以保守方式校准固定文本原型。最终异常图仍在 CLIP 语义空间内计算，因此方法不是频率图融合，而是频谱可靠性引导的逐图语义参照构建。

贡献。

- 频谱可靠性建模。我们在 CLIP patch 特征上构造边界感知的小波可靠性，将高频局部变化与低频结构边界区分开来，并把小波信号从异常评分器重新定位为语义证据的可靠性调制项。
- 逐图语义原型校准。我们联合初始语义概率与频谱可靠性，汇聚逐图正常/异常视觉原型，并以保守、非对称的方式校准固定文本原型；新增模块在测试时不反传，也不更新 CLIP 或 AnomalyCLIP 参数。
- 面向机制的验证协议。我们规划直接频率融合、纯语义自参照、频谱设计、保守更新、正常图稳定性和类别级分析，以区分“频率本身有效”与“频率作为证据可靠性有效”这两个不同命题。

本文当前版本用于冻结叙事、实验表格和判定标准。所有实验数字均以目标占位形式呈现，待真实评测后替换；因此本文只陈述方法与可证伪预测，不把预期数值写成已观察事实。




图 1: CLIP patch 特征的高频响应对缺陷 (a) 敏感, 但对正常粗糙材质 (b) 同样敏感。高频因而不能独立充当异常分数。本文将其作为语义证据的可靠性因子, 用于构造逐图视觉原型, 而最终异常图仍由校准后的语义原型产生。

2 相关工作

基于 CLIP 的零样本异常检测。WinCLIP [3] 通过组合式状态提示与多尺度窗口特征建立语言引导的零样本分类与分割; AnomalyCLIP [7] 从辅助异常数据中学习物体无关的正常/异常文本提示, 以提升未见类别上的泛化; VCP-CLIP [5] 将视觉上下文注入提示, AA-CLIP [4] 则同时重塑文本锚点和视觉特征。这些方法主要回答“如何获得更适合异常检测的跨类别语义表示”。本文关注一个互补问题: 当文本原型固定后, 如何利用单张测试图的局部外观校准该原型, 而不在目标类别上训练。

面向异常检测的频率方法。FE-CLIP [2] 用 DCT 和可学习适配器在 CLIP 视觉编码器的多层特征中注入频率信息。其他频率异常检测工作也常把高、低频分量作为互补特征分支。它们说明局部频谱结构对细粒度异常有价值, 但频率通常直接进入表征学习或最终判别。本文不把小波分量作为新增特征分支, 也不把频率图与异常图相加; 小波只产生逐 patch 可靠性, 用于控制哪些视觉 token 可以参与逐图原型构造。因此, 本文的创新点不是“在 ZSAD 中首次使用频率”, 而是明确频率在线语义参照构造中的角色。

测试时与参照式适配。WinCLIP+ [3] 从少量正常参考图中构建视觉关联分数; 其他测试时方法会依赖伪标签、合成异常或外部记忆。本文既不访问目标类别正常库, 也不在测试时优化参数, 而是从当前图像中汇聚视觉原型。与纯语义自参照不同, 小波可靠性为 patch 选择提供一条不由文本相似度直接产生的辅助依据。为避免过度声称, 我们不宣称该范式绝对新颖, 而是通过直接融合、纯语义证据与不同小波设计的受控比较来验证其必要性。

3 方法

3.1 问题设定与初始语义分数

给定测试图像 x , 冻结的 CLIP 视觉编码器在若干层输出 patch 特征。我们从指定层选择并归一化空间 token, 记为 $\mathbf{F} = \{f_i\}_{i=1}^N \in \mathbb{R}^{N \times C}$ 。AnomalyCLIP 提供固定的正常/异常文本原型 $t_n, t_a \in \mathbb{R}^C$ 。初始语义异常概率为

$$S_0(i) = \frac{\exp(\langle f_i, t_a \rangle / \tau)}{\exp(\langle f_i, t_n \rangle / \tau) + \exp(\langle f_i, t_a \rangle / \tau)}. \quad (1)$$

固定原型具有跨类别泛化能力, 但不包含当前图像的具体材质与结构。若仅以 S_0 选择正常 patch, 逐图参照会继承原语义模型的误差; 若直接使用高频响应, 高纹理正常区域又会被误认为异常。我们的目标不是替换语义分数, 而是估计每个语义证据的局部可靠性。

3.2 读取高频

我们将 $N = H \times W$ 个 token 重排为特征网格, 并施加一层 Haar 离散小波变换 (DWT)。低频 LL 描述局部平均结构, 高频子带给出局部不连续性的能量:

$$\text{HF} = \frac{1}{C} \sum_c (|\text{LH}_c| + |\text{HL}_c| + |\text{HH}_c|). \quad (2)$$

正常物体边界同样会产生高频, 因此我们从低频分量计算结构边界, 并定义边界感知可靠性

$$W = \text{HF} \cdot (1 - \text{LF-edge}), \quad \text{LF-edge} = \|\nabla \text{LL}\|, \quad (3)$$

其中 HF、LF-edge 与 W 均在每张图内做百分位裁剪和 $[0, 1]$ 归一化。 W 较高表示该位置具有明显的局部高频变化, 但不被低频结构边界充分解释。它是可靠性线索, 而不是异常标签。

3.3 语义—频谱证据权重

我们以 S_0 决定 patch 的语义方向，并以 W 做弱调制。正常与异常证据权重分别为

$$\omega_a(i) = S_0(i)^\gamma ((1 - \lambda) + \lambda W(i))^\eta, \quad (4)$$

$$\omega_n(i) = (1 - S_0(i))^\gamma ((1 - \lambda) + \lambda(1 - W(i)))^\eta, \quad (5)$$

其中 λ 控制小波线索的影响。小 λ 保留语义排序，只对可疑局部证据做温和重加权； $\lambda = 0$ 退化为纯语义自参照。对每组权重选取 top- k patch，并构造加权视觉原型

$$v_a = \frac{\sum_{i \in \mathcal{I}_a} \bar{\omega}_a(i) f_i}{\|\sum_{i \in \mathcal{I}_a} \bar{\omega}_a(i) f_i\|_2}, \quad v_n = \frac{\sum_{i \in \mathcal{I}_n} \bar{\omega}_n(i) f_i}{\|\sum_{i \in \mathcal{I}_n} \bar{\omega}_n(i) f_i\|_2}, \quad (6)$$

其中 $\bar{\omega}$ 是所选 patch 内归一化后的权重。

3.4 保守的逐图文本原型校准

视觉原型包含当前图像的实例外观，但可能被异常区域或背景噪声污染。我们因此采用置信度控制的保守更新：

$$\tilde{t}_n = \text{norm}((1 - \beta)t_n + \beta v_n), \quad (7)$$

$$\tilde{t}_a = \text{norm}((1 - \alpha)t_a + \alpha v_a), \quad (8)$$

其中 α, β 由视觉原型的平均证据权重和图像级更新门控共同决定。验证配置采用非对称更新： $\alpha_0 = 0$ ，即保持异常文本原型不变；仅以较小的 β_0 校准正常原型。该选择反映一个实际约束：测试图中的正常 patch 通常丰富，而异常 patch 稀少且更容易被错误选择。

最后，使用 $\tilde{t}_n, \tilde{t}_a$ 在各选定层重新计算式 (1)，并对层级结果求和或平均得到最终异常图。频率图不参与最终分数融合。新增模块在测试时不反传，也不更新 CLIP 或 AnomalyCLIP 参数；目标类别标签与像素标注只用于评测。图 2 给出整体框架。

multi-crop 聚合与 pixel-to-image 融合属于与本文机制正交的评测增强。为避免把工程增益与核心贡献混淆，正文将纯原型路径和带增强路径分开报告，并在第 A 节说明其作用。

4 实验

4.1 设置

我们规划在 MVTec AD [1]、VisA [8]、MPDD、BTAD 与 DTD-Synthetic 五个数据集上评测。指标为 pixel AUROC、pixel AUPRO、image AUROC、image AP（均为百分数）。基础模型采用已训练的 AnomalyCLIP；本文新增的原型校准模块仅在测试时运行，不反

传，也不更新视觉编码器、文本编码器或已学习提示。除非特别说明，主机制比较使用相同的特征层、平滑和后处理配置。

4.2 主结果

表 1 给出五个数据集的主结果骨架，表 2 给出代表性方法的对比骨架。表中数字均为实验目标，不是观察结果。正式实验应首先验证两个较弱但必要的结论：(1) 在固定协议下，完整路径不劣于原始 AnomalyCLIP；(2) 在纹理与微缺陷类别上获得更稳定的定位增益。只有当真实结果满足预先定义的判据时，正文才能把对应描述从“目标”改为“结果”。

MPDD、BTAD 与 DTD 的最终结果为逐数据集调参所得。为避免“测试集调参”的质疑，我们在附录中额外区分了统一全局设置与逐数据集调参上界（表 6）。

5 分析与消融

5.1 频谱可靠性在逐图原型中的作用

该实验区分三种可能的收益来源：固定语义原型本身、纯语义的逐图原型，以及小波可靠性调制。我们还保留直接频率图融合这一负控，用于验证小波是否应直接进入最终异常分数。表 3 与图 3 给出目标结果骨架。正式实验应关注以下可证伪关系：

- DirectFusion 低于 Ours：说明 W 不应被解释为独立异常图，也不能替代语义相似度。
- SemanticProto 高于 Baseline：说明逐图视觉原型本身能够补充固定文本原型。
- Ours 高于 SemanticProto，且增益集中在纹理类：才说明小波可靠性对 patch 证据选择提供了语义分数之外的有效信息。

5.2 增益从哪来

图 4 规划按类别对比 Ours 与 SemanticProto 的 pixel AUPRO，两者唯一差别是证据权重中是否使用小波可靠性。机制成立的理想模式不是所有类别普遍上升，而是纹理和微缺陷类别获得更稳定的增益，结构类基本持平。若真实结果不呈现该分组差异，就不能把平均增益归因于频谱可靠性。

5.3 语义原型漏检子集

我们把 SemanticProto 低分、但真值为异常的像素定义为“语义原型漏检子集”，再测量 Ours 在该子集




图 2: 整体框架。测试图经冻结的 CLIP 得到 patch 特征, 分为语义支 (S_0) 与频率支 (Haar DWT $\rightarrow$ HF/W); W 以弱调制方式改变正常/异常 patch 的证据权重, 进而构造逐图视觉原型并保守校准固定文本原型。最终异常图由校准后的语义相似度重算得到, 而非由频率图直接融合。

表 1: 五个数据集的主结果骨架。指标为 pixel AUROC / pixel AUPRO / image AUROC / image AP (%)。所有数字均为预期目标, 仅用于冻结实验判据。

数据集	方法	pixel AUROC	pixel AUPRO	image AUROC	image AP
MVTec AD	AnomalyCLIP	91.1	81.4	91.5	96.2
	Ours	92.4	85.8	94.2	97.5
VisA	AnomalyCLIP	95.5	87.0	82.1	85.4
	Ours	96.5	91.0	85.3	88.2
MPDD	AnomalyCLIP	96.5	88.7	77.0	80.2
	Ours	97.2	90.5	80.0	83.5
BTAD	AnomalyCLIP	94.2	74.8	89.5	91.5
	Ours	95.8	78.5	92.0	93.5
DTD-Synth	AnomalyCLIP	97.0	89.5	94.0	97.2
	Ours	97.8	91.5	96.0	98.3

表 2: MVTec 零样本对比。* 为待核对的外部数值; Ours 为预期目标。iAUROC、pAUROC、pAUPRO 分别指 image AUROC、pixel AUROC、pixel AUPRO。

方法	iAUROC	pAUROC	pAUPRO
WinCLIP*	91.8	85.1	64.6
APRIL-GAN*	86.1	87.6	44.0
AnomalyCLIP	91.5	91.1	81.4
AdaCLIP*	92.0	89.0	—
FE-CLIP*	—	—	—
Ours	94.2	92.4	85.8




图 3: 逐图原型与频谱可靠性的作用 (MVTec, pixel AUPRO, 占位目标)。正式版本应以真实结果检验 Baseline、SemanticProto、HFProto 与 Ours 的差异。

上的召回率。该指标不是独立的标准 benchmark 指标, 因此只用于机制分析, 且必须同时报告子集规模和阈值定义。图 5 仅给出目标占位: 若小波可靠性确实补充语义证据, Ours 应在纹理和微缺陷样本中恢复一部分漏检; 若召回只来自阈值变化或整体分数抬高, 则该分析不能支持机制。

5.4 稳定性、运行时与敏感性

表 4 与图 6 分别给出正常图稳定性、运行时和超参敏感性的目标骨架。mix=0 对应 SemanticProto; 随着 mix 增大, 小波可靠性影响增强。若性能在中小 mix 区间形成稳定平台、而过大 mix 下降, 说明频谱信号适

表 3: 核心机制消融骨架 (MVTec / VisA, 全指标)。数值为预期目标。

变体	pAUROC	pAUPRO	iAUROC	iAP
<i>MVTec AD</i>				
DirectFusion (直接图融合)	82.5	73.0	93.4	97.1
Baseline	91.1	81.4	91.5	96.2
SemanticProto ($\lambda = 0$)	91.9	84.6	93.9	97.3
HFProto (裸高频)	92.0	85.0	94.1	97.4
Ours	92.4	85.8	94.2	97.5
<i>VisA</i>				
DirectFusion	90.8	82.5	84.0	86.5
Baseline	95.5	87.0	82.1	85.4
SemanticProto	96.1	89.8	84.4	87.3
HFProto	96.2	90.3	84.7	87.6
Ours	96.5	91.0	85.3	88.2




图 4: 分类别 pixel AUPRO 的目标模式 (MVTec, 占位图)。正式版本比较 Ours 与 SemanticProto, 检验增益是否集中在纹理/微缺陷类。

合作为弱可靠性调制而非主导证据。所有数值在真实实验前仅作为通过线。

5.5 定性结果

我们规划展示输入、真值、Baseline、SemanticProto、频谱可靠性 W 与 Ours, 如图 7 所示。定性图需要同时说明两点: W 可以在缺陷附近响应, 但在正常纹理和结构边界上也可能明亮; Ours 并非复制 W , 而是通过校准语义原型抑制不可靠响应。该图为占位版, 待真实推理结果生成后替换。

5.6 设计消融

表 5 规划比较裸高频、边界感知可靠性和保守更新。只有当边界感知相对 HFProto 提升, 且保守更新在不损失平均指标的同时降低正常图误报, 才能分别支




图 5: 语义原型漏检子集的召回目标 (占位图)。正式版本必须报告漏检子集定义、规模及置信区间。

表 4: 正常图假阳性面积 (越低越好) 与运行时。数值为预期目标。

数据集	方法	FP@p95(%)	FP@p99(%)	s/img
MVTec	Baseline	5.0	1.00	0.065
	NoCons	4.9	0.98	—
	Ours	4.6	0.90	0.079
VisA	Baseline	5.0	1.00	0.065
	NoCons	4.8	0.95	—
	Ours	4.5	0.88	0.079

持两个设计。

6 结论

本文围绕固定文本原型缺少实例外观参照这一问题, 提出频谱可靠性引导的测试时语义原型校准。小波分解不直接产生最终异常图, 而是调制语义 patch 证据, 帮助构造逐图视觉原型; 视觉原型随后以保守方式校准正常/异常文本原型, 最终仍在 CLIP 语义空间中完成定位。该设计把频率线索与语义判别的职责分开, 也使直接融合、纯语义自参照和边界感知可靠性能够通过受控实验分别验证。

局限。当前稿件中的实验数字仍是占位目标, 不能被解释为完成结果。即使未来完整方法优于原始 AnomalyCLIP, 也只有在其相对 SemanticProto 的增益集中于预期类别、且稳定性与直接融合负控共同成立时, 才可以把提升归因于频谱可靠性。此外, 逐图原型会受背景、异常面积和 patch 分辨率影响, 逻辑异常也未被直接解决。

未来工作。将频谱可靠性引导的逐图原型构造推广到其他冻结视觉-语言编码器, 并研究能够显式处理背




图 6: 超参敏感性 (MVTec, pixel AUPRO)。 (b) wavelet-mix 兼作机制曲线——高频过多反而有害。

表 5: 设计消融 (MVTec)。数值为预期目标。

变体	pAUROC	pAUPRO	iAUROC	iAP
HFOnly (裸高频)	92.0	85.0	94.1	97.4
NoCons (无保守)	92.1	85.3	94.0	97.3
Ours (完整)	92.4	85.8	94.2	97.5

景和逻辑异常的参照构造策略。

参考文献

- [1] Paul Bergmann, Michael Fauser, David Sattlegger, and Carsten Steger. MVTec AD - A comprehensive real-world dataset for unsupervised anomaly detection. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 9592–9600. Computer Vision Foundation / IEEE, 2019.
- [2] Tao Gong, Qi Chu, Bin Liu, Wei Zhou, and Nenghai Yu. FE-CLIP: Frequency enhanced CLIP model for zero-shot anomaly detection and segmentation. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 21220–21230. IEEE, 2025.
- [3] Jongheon Jeong, Yang Zou, Taewan Kim, Dongqing Zhang, Avinash Ravichandran, and Onkar Dabeer. WinCLIP: Zero-/few-shot anomaly classification and segmentation. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 19606–19616. IEEE, 2023.
- [4] Wenxin Ma, Xu Zhang, Qingsong Yao, Fenghe Tang, Chenxu Wu, Yingtai Li, Rui Yan, Zihang Jiang, and S. Kevin Zhou. AA-CLIP: Enhancing zero-shot anomaly detection via anomaly-aware CLIP. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 4744–4754. Computer Vision Foundation / IEEE, 2025.
- [5] Zhen Qu, Xian Tao, Mukesh Prasad, Fei Shen, Zhengtao Zhang, Xinyi Gong, and Guiguang Ding. VCP-CLIP: A visual context prompting model for zero-shot anomaly segmentation. In *Computer Vision - ECCV 2024*, volume 15127 of *Lecture Notes in Computer Science*, pages 301–317. Springer, 2024.
- [6] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *Proceedings of the 38th International Conference on Machine Learning (ICML)*, volume 139 of *Proceedings of Machine Learning Research*, pages 8748–8763. PMLR, 2021.
- [7] Qihang Zhou, Guansong Pang, Yu Tian, Shibo He, and Jiming Chen. AnomalyCLIP: Object-agnostic prompt learning for zero-shot anomaly detection. In *The Twelfth International Conference on Learning Representations (ICLR)*. OpenReview.net, 2024.
- [8] Yang Zou, Jongheon Jeong, Latha Pemula, Dongqing Zhang, and Onkar Dabeer. SPot-the-Difference self-supervised pre-training for anomaly detection and segmentation. In *Computer Vision - ECCV 2022*, volume 13690 of *Lecture Notes in Computer Science*, pages 392–408. Springer, 2022.

A 正交增强与全局设置

正交增强。 multi-crop 聚合与 pixel-to-image 融合是标准的空间/分数聚合手段，与本文“逐图正常参照”机制正交。它们能进一步提升数值，但不改变本文的机制结论；为保持主线清晰，正文不将其计入核心方法。

全局设置 vs 逐数据集调参。 表 6 区分统一全局设置与逐数据集调参上界。我们主张以全局设置作为公平结论，调参行仅作为上界参考，以避免“测试集调参”的质疑。

表 6: 全局设置 vs 逐数据集调参上界 (pixel AUPRO, %)。数值为预期目标。

数据集	全局设置	逐数据集调参 (上界)
MPDD	88.4	90.5
BTAD	79.5	78.5
DTD-Synth	90.7	91.5

	输入	真值 GT	Baseline	SemanticProto	可靠性 W	Ours
carpet	原图	GT 掩码	异常图 偏弱	语义原型 漏检	全片亮 (含正常纹理)	准确 定位
	原图	GT 掩码	异常图 偏弱	语义原型 漏检	全片亮	准确 定位
grid	原图	GT 掩码	异常图 偏弱	语义原型 漏检	全片亮	准确 定位
	原图	GT 掩码	异常图 偏弱	部分 漏检	全片亮	准确 定位
wood	原图	GT 掩码	异常图 偏弱	部分 漏检	全片亮	准确 定位
	原图	GT 掩码	可定位	可定位	缺陷处亮	与语义原型 相当
bottle	原图	GT 掩码	可定位	可定位	缺陷处亮	与语义原型 相当
	原图	GT 掩码	异常图 偏弱	漏检 微缺陷	全片亮	捞回 微缺陷
VisA pcb	原图	GT 掩码	异常图 偏弱	漏检 微缺陷	全片亮	捞回 微缺陷

图 7: 定性对比 (占位图, 待真实推理结果替换)。列依次为: 输入、真值掩码、Baseline 异常图、SemanticProto (纯语义逐图原型) 异常图、频谱可靠性 W、Ours 异常图。前四行为 MVTec (纹理类 carpet/grid/wood + 物体类 bottle), 末行为 VisA。正式结果应展示: W 在缺陷附近响应, 但在正常纹理与结构边界上也可能明亮; SemanticProto 在部分纹理与微缺陷上漏检; Ours 通过原型校准改善定位, 同时在物体类上不退化。热力图统一采用同一色标与归一化。

可复现性说明。 本文数值为预期目标 (EXPECTED), 用于锁定叙事与判定标准; 正式版本将以真实评测日志替换, 并从源论文核实所有外部对比数值与引用。