

# 频谱可靠性引导的测试时语义原型校准： 面向零样本异常检测的逐图参照构建

匿名作者

摘要

基于 CLIP 的零样本异常检测依赖固定的正常/异常文本原型，但固定原型缺少单张测试图的局部外观参照。仅用 CLIP 分数从测试图中选择 patch 会继承其局部误差；直接使用高频响应又会把规则纹理和结构边界误判为缺陷。本文提出频谱可靠性引导的测试时语义原型校准：在冻结的 CLIP patch 特征上计算边界感知的小波可靠性，用它温和调制正常/异常语义证据，构造逐图视觉原型，再以保守、非对称的方式校准固定文本原型。最终异常图仍由校准后的语义相似度产生，而非频率图融合。该框架把小波从异常评分器重新定位为逐图证据的可靠性估计器。为验证这一定位，我们预先规划纯原型路径与工程增强路径，比较直接图融合、频率特征增强、纯语义原型和完整方法，并通过预注册类别分组、正常图稳定性与非循环的漏检子集分析排除替代解释。当前稿件用于冻结实验判据，所有数字均为目标占位，正式版本将由真实评测替换。

## 1 引言

零样本异常检测的目标是在目标类别上不使用训练样本，直接判断图像或像素是否异常。CLIP [8] 提供了开放词表的视觉-文本对齐，使“正常”和“异常”能够被写成本原型并迁移到未见类别。WinCLIP [4]、AnomalyCLIP [9] 等工作由此建立了基于语义原型的 ZSAD 范式：冻结视觉编码器，将 patch 特征与正常/异常文本原型比较，并把异常类别的相似度解释为局部分数。

这一范式的关键优点是跨类别泛化，但其参照是固定的。一组数据集级文本原型可以描述一般性的正常与异常，却难以覆盖单张图像的材质、结构和局部外观。同样的缺口也不能通过朴素的测试时自参照自动补齐：若只根据初始 CLIP 分数选择“可信正常 patch”，参照会继承原模型的局部盲区；若改用高频响应选择异常，规则纹理和物体边界又会被一并放大。换言之，逐图参照需要同时回答两个问题：哪些 patch 在语义上可信，以及哪些局部变化不像正常结构。

频率信息为第二个问题提供了天然线索。局部缺陷往往伴随 patch 特征场的高频变化，但高频本身并不是异常标签：布料、网格和清晰边界同样包含强高频。因此，本文不把小波响应直接加到异常图上，而是把它作为可靠性因子，用于调制语义证据并构造逐图视觉原型。该定位使语义与频谱承担不同职责：语义分数决定 patch 更接近“正常”还是“异常”，频谱可靠性判断该语义证据是否可能被局部结构混淆。

图 1 展示这一动机。光滑表面上的缺陷与正常粗糙

纹理都可能产生显著高频响应；高频图无法独立完成判别，但能够指出哪些语义证据需要谨慎使用。我们据此从测试图中汇聚正常/异常视觉原型，再以保守方式校准固定文本原型。最终异常图仍在 CLIP 语义空间内计算，因此方法不是频率图融合，而是频谱可靠性引导的逐图语义参照构建。

贡献。

- 频谱可靠性建模。我们在 CLIP patch 特征上构造边界感知的小波可靠性，将高频局部变化与低频结构边界区分开来，并把小波信号从异常评分器重新定位为语义证据的可靠性调制项。
- 逐图语义原型校准。我们联合初始语义概率与频谱可靠性，汇聚逐图正常/异常视觉原型，并以保守、非对称的方式校准固定文本原型；新增模块在测试时不反传，也不更新 CLIP 或 AnomalyCLIP 参数。
- 面向机制的验证协议。我们分离纯原型与工程增强口径，并规划直接图融合、频率特征增强、纯语义原型、频谱设计和保守更新等对照；类别分组和漏检子集定义均在观察结果前冻结，以区分“频率作为额外特征有效”与“频率作为证据可靠性有效”。

本文当前版本用于冻结叙事、实验表格和判定标准。所有实验数字均以目标占位形式呈现，待真实评测后替换；因此本文只陈述方法与可证伪预测，不把预期数值写成已观察事实。




图 1: CLIP patch 特征的高频响应对缺陷 (a) 敏感, 但对正常粗糙材质 (b) 同样敏感。高频因而不能独立充当异常分数。本文将其作为语义证据的可靠性因子, 用于构造逐图视觉原型, 而最终异常图仍由校准后的语义原型产生。

## 2 相关工作

基于 CLIP 的零样本异常检测。WinCLIP [4] 通过组合式状态提示与多尺度窗口特征建立语言引导的零样本分类与分割。PromptAD [5]、AnomalyCLIP [9] 与 AdaCLIP [2] 分别从提示设计、物体无关提示学习和混合可学习提示出发, 提高未见类别上的异常语义泛化; VCP-CLIP [7] 将视觉上下文注入提示, AA-CLIP [6] 则同时重塑文本锚点和视觉特征。这些方法主要回答“如何获得更适合异常检测的跨类别语义表示”。本文关注一个互补问题: 当文本原型固定后, 如何利用单张测试图的局部外观校准该原型, 而不在目标类别上训练。

面向异常检测的频率方法。FE-CLIP [3] 用 DCT 和可学习适配器在 CLIP 视觉编码器的多层特征中注入频率信息。其他频率异常检测工作也常把高、低频分量作为互补特征分支。它们说明局部频谱结构对细粒度异常有价值, 但频率通常直接进入表征学习或最终判别。本文不把小波分量作为新增特征分支, 也不把频率图与异常图相加; 小波只产生逐 patch 可靠性, 用于控制哪些视觉 token 可以参与逐图原型构造。因此, 本文的创新点不是“在 ZSAD 中首次使用频率”, 而是明确频率在线语义参照构造中的角色。

测试时与参照式适配。WinCLIP+ [4] 从少量正常参考图中构建视觉关联分数; 其他测试时方法会依赖伪标签、合成异常或外部记忆。本文既不访问目标类别正常库, 也不在测试时优化参数, 而是从当前图像中汇聚视觉原型。与纯语义自参照不同, 小波可靠性为 patch 选择提供一条不由文本相似度直接产生的辅助依据。为避免过度声称, 我们不宣称该范式绝对新颖, 而是通过直接融合、纯语义证据与不同小波设计的受控比较来验证其必要性。

## 3 方法

### 3.1 问题设定与初始语义分数

给定测试图像  $x$ , 冻结的 CLIP 视觉编码器在若干层输出 patch 特征。我们从指定层选择并归一化空间 token, 记为  $\mathbf{F} = \{f_i\}_{i=1}^N \in \mathbb{R}^{N \times C}$ 。AnomalyCLIP 提供固定的正常/异常文本原型  $t_n, t_a \in \mathbb{R}^C$ 。初始语义异常概率为

$$S_0(i) = \frac{\exp(\langle f_i, t_a \rangle / \tau)}{\exp(\langle f_i, t_n \rangle / \tau) + \exp(\langle f_i, t_a \rangle / \tau)}. \quad (1)$$

固定原型具有跨类别泛化能力, 但不包含当前图像的具体材质与结构。若仅以  $S_0$  选择正常 patch, 逐图参照会继承原语义模型的误差; 若直接使用高频响应, 高纹理正常区域又会被误认为异常。我们的目标不是替换语义分数, 而是估计每个语义证据的局部可靠性。

### 3.2 读取高频

我们将  $N = H \times W$  个 token 重排为特征网格, 并施加一层 Haar 离散小波变换 (DWT)。低频 LL 描述局部平均结构, 高频子带给出局部不连续性的能量:

$$\text{HF} = \frac{1}{C} \sum_c (|\text{LH}_c| + |\text{HL}_c| + |\text{HH}_c|). \quad (2)$$

正常物体边界同样会产生高频, 因此我们从低频分量计算结构边界, 并定义边界感知可靠性

$$W = \text{HF} \cdot (1 - \text{LF-edge}), \quad \text{LF-edge} = \|\nabla \text{LL}\|, \quad (3)$$

其中 HF、LF-edge 与  $W$  均在每张图内做百分位裁剪和  $[0, 1]$  归一化。 $W$  较高表示该位置具有明显的局部高频变化, 但不被低频结构边界充分解释。它是可靠性线索, 而不是异常标签。

### 3.3 语义-频谱证据权重

我们以  $S_0$  决定 patch 的语义方向，并以  $W$  做弱调制。正常与异常证据权重分别为

$$\omega_a(i) = S_0(i)^\gamma ((1 - \lambda) + \lambda W(i))^\eta, \quad (4)$$

$$\omega_n(i) = (1 - S_0(i))^\gamma ((1 - \lambda) + \lambda(1 - W(i)))^\eta, \quad (5)$$

其中  $\lambda$  控制小波线索的影响。小  $\lambda$  保留语义排序，只对可疑局部证据做温和重加权； $\lambda = 0$  退化为纯语义自参照。对每组权重选取 top- $k$  patch，并构造加权视觉原型

$$v_a = \frac{\sum_{i \in \mathcal{I}_a} \bar{\omega}_a(i) f_i}{\|\sum_{i \in \mathcal{I}_a} \bar{\omega}_a(i) f_i\|_2}, \quad v_n = \frac{\sum_{i \in \mathcal{I}_n} \bar{\omega}_n(i) f_i}{\|\sum_{i \in \mathcal{I}_n} \bar{\omega}_n(i) f_i\|_2}, \quad (6)$$

其中  $\bar{\omega}$  是所选 patch 内归一化后的权重。

### 3.4 保守的逐图文本原型校准

视觉原型包含当前图像的实例外观，但可能被异常区域或背景噪声污染。我们因此采用置信度控制的保守更新：

$$\tilde{t}_n = \text{norm}((1 - \beta)t_n + \beta v_n), \quad (7)$$

$$\tilde{t}_a = \text{norm}((1 - \alpha)t_a + \alpha v_a), \quad (8)$$

其中  $\alpha, \beta$  由视觉原型的平均证据权重和图像级更新门控共同决定。验证配置采用非对称更新： $\alpha_0 = 0$ ，即保持异常文本原型不变；仅以较小的  $\beta_0$  校准正常原型。该选择反映一个实际约束：测试图中的正常 patch 通常丰富，而异常 patch 稀少且更容易被错误选择。

最后，使用  $\tilde{t}_n, \tilde{t}_a$  在各选定层重新计算式 (1)，并对层级结果求和或平均得到最终异常图。频率图不参与最终分数融合。新增模块在测试时不反传，也不更新 CLIP 或 AnomalyCLIP 参数；目标类别标签与像素标注只用于评测。图 2 给出整体框架。

multi-crop 聚合与 pixel-to-image 融合属于与本文机制正交的评测增强。为避免把工程增益与核心贡献混淆，正文将纯原型路径和带增强路径分开报告，并在第 A 节说明其作用。

## 4 实验

### 4.1 设置

我们规划在 MVTec AD [1]、VisA [10]、MPDD、BTAD 与 DTD-Synthetic 五个数据集上评测。指标为 pixel AUROC、pixel AUPRO、image AUROC、image AP (均为百分数)。基础模型采用已训练的 AnomalyCLIP；本文新增的原型校准模块仅在测试时运行，不反

传，也不更新视觉编码器、文本编码器或已学习提示。除非特别说明，主机制比较使用相同的特征层、平滑和后处理配置。

两条报告口径。为防止 multi-crop 与 pixel-to-image 等工程增强掩盖核心机制，我们把实验拆成两条口径。Pure 口径只包含固定的 AnomalyCLIP 特征提取、统一平滑和原型校准，所有核心消融均在该口径下进行；Enhanced 口径对所有方法统一叠加相同的 multi-crop 与 pixel-to-image 后处理，仅用于检验兼容性。任何关于频谱可靠性和逐图原型的因果结论只能由 Pure 口径支持。

预注册分析协议。类别分组在运行 Ours 前冻结：MVTec 官方纹理类别 (carpet、grid、leather、tile、wood) 与其余物体类别分别统计；微缺陷子集按缺陷掩码面积占比的固定阈值定义。所有组别均报告完整类别结果和 bootstrap 置信区间。漏检子集阈值在独立验证划分或预设分位数上确定，测试标签不得用于选择阈值。

### 4.2 主结果

表 1 给出 Enhanced 口径的跨数据集主结果骨架，表 2 给出代表性方法的对比骨架。Pure 口径的结果与全部机制消融放在第 5 节。表中数字均为实验目标，不是观察结果。正式实验应首先验证两个较弱但必要的结论：(1) Pure 口径下完整方法不劣于固定文本原型，并在预注册纹理/微缺陷子集上优于 SemanticProto；(2) Enhanced 口径下工程增强不会改变方法排序。只有当真实结果满足预先定义的判据时，正文才能把对应描述从“目标”改为“结果”。

MPDD、BTAD 与 DTD 的最终结果为逐数据集调参所得。为避免“测试集调参”的质疑，我们在附录中额外区分了统一全局设置与逐数据集调参上界 (表 6)。

## 5 分析与消融

### 5.1 频谱可靠性在逐图原型中的作用

该实验全部采用 Pure 口径，并区分四种可能的收益来源：固定文本原型、频率作为最终图或特征偏置、纯语义的逐图原型，以及小波可靠性调制。表 3 与图 3 给出目标结果骨架。正式实验应关注以下可证伪关系：

- DirectFusion 低于 Ours：说明  $W$  不能替代语义相似度。
- FeatureAug 与 Ours 的比较：若把  $W$  作为 logit bias 也能获得同等增益，则不能声称逐图原型是关




图 2: 整体框架。测试图经冻结的 CLIP 得到 patch 特征, 分为语义支 ( $S_0$ ) 与频率支 (Haar DWT  $\rightarrow$  HF/W); W 以弱调制方式改变正常/异常 patch 的证据权重, 进而构造逐图视觉原型并保守校准固定文本原型。最终异常图由校准后的语义相似度重算得到, 而非由频率图直接融合。

表 1: Enhanced 口径下五个数据集的主结果骨架。指标为 pixel AUROC / pixel AUPRO / image AUROC / image AP (%)。所有数字均为预期目标, 仅用于冻结实验判据。

| 数据集       | 方法          | pixel AUROC | pixel AUPRO | image AUROC | image AP    |
|-----------|-------------|-------------|-------------|-------------|-------------|
| MVTec AD  | AnomalyCLIP | 91.1        | 81.4        | 91.5        | 96.2        |
|           | <b>Ours</b> | <b>92.4</b> | <b>85.8</b> | <b>94.2</b> | <b>97.5</b> |
| VisA      | AnomalyCLIP | 95.5        | 87.0        | 82.1        | 85.4        |
|           | <b>Ours</b> | <b>96.5</b> | <b>91.0</b> | <b>85.3</b> | <b>88.2</b> |
| MPDD      | AnomalyCLIP | 96.5        | 88.7        | 77.0        | 80.2        |
|           | <b>Ours</b> | <b>97.2</b> | <b>90.5</b> | <b>80.0</b> | <b>83.5</b> |
| BTAD      | AnomalyCLIP | 94.2        | 74.8        | 89.5        | 91.5        |
|           | <b>Ours</b> | <b>95.8</b> | <b>78.5</b> | <b>92.0</b> | <b>93.5</b> |
| DTD-Synth | AnomalyCLIP | 97.0        | 89.5        | 94.0        | 97.2        |
|           | <b>Ours</b> | <b>97.8</b> | <b>91.5</b> | <b>96.0</b> | <b>98.3</b> |

表 2: MVTec 零样本对比。\* 为待核对的外部数值; Ours 为预期目标。iAUROC、pAUROC、pAUPRO 分别指 image AUROC、pixel AUROC、pixel AUPRO。

| 方法          | iAUROC      | pAUROC      | pAUPRO      |
|-------------|-------------|-------------|-------------|
| WinCLIP*    | 91.8        | 85.1        | 64.6        |
| APRIL-GAN*  | 86.1        | 87.6        | 44.0        |
| AnomalyCLIP | 91.5        | 91.1        | 81.4        |
| AdaCLIP*    | 92.0        | 89.0        | —           |
| FE-CLIP*    | —           | —           | —           |
| <b>Ours</b> | <b>94.2</b> | <b>92.4</b> | <b>85.8</b> |

键; 只有 Ours 在平均指标、稳定性或跨类别一致性上更优, 才能支持本文的使用方式。

- SemanticProto 高于 Baseline: 说明逐图视觉原型本身能够补充固定文本原型。
- Ours 高于 SemanticProto, 且增益集中在纹理类: 才说明小波可靠性对 patch 证据选择提供了语义分数之外的有效信息。




图 3: 逐图原型与频谱可靠性的作用 (MVTec, pixel AUPRO, 占位目标)。正式版本应以真实结果检验 Baseline、SemanticProto、HFProto 与 Ours 的差异。

## 5.2 增益从哪来

图 4 规划按类别对比 Ours 与 SemanticProto 的 pixel AUPRO, 两者唯一差别是证据权重中是否使用小波可靠性。MVTec 的 texture/object 分组直接采用数据集官方类别类型, 并在实验前冻结; 微缺陷分组按掩码面积占比的预设阈值确定。我们报告全部类别、组均

表 3: 核心机制消融骨架 (MVTec / VisA, 全指标)。数值为预期目标。

| 变体                              | pAUROC      | pAUPRO      | iAUROC      | iAP         |
|---------------------------------|-------------|-------------|-------------|-------------|
| <i>MVTec AD</i>                 |             |             |             |             |
| DirectFusion (直接图融合)            | 82.5        | 73.0        | 93.4        | 97.1        |
| FeatureAug (logit 偏置)           | 90.8        | 82.8        | 93.5        | 97.1        |
| Baseline                        | 91.1        | 81.4        | 91.5        | 96.2        |
| SemanticProto ( $\lambda = 0$ ) | 91.9        | 84.6        | 93.9        | 97.3        |
| HFProto (裸高频)                   | 92.0        | 85.0        | 94.1        | 97.4        |
| <b>Ours</b>                     | <b>92.4</b> | <b>85.8</b> | <b>94.2</b> | <b>97.5</b> |
| <i>VisA</i>                     |             |             |             |             |
| DirectFusion                    | 90.8        | 82.5        | 84.0        | 86.5        |
| FeatureAug                      | 95.7        | 88.6        | 84.2        | 87.0        |
| Baseline                        | 95.5        | 87.0        | 82.1        | 85.4        |
| SemanticProto                   | 96.1        | 89.8        | 84.4        | 87.3        |
| HFProto                         | 96.2        | 90.3        | 84.7        | 87.6        |
| <b>Ours</b>                     | <b>96.5</b> | <b>91.0</b> | <b>85.3</b> | <b>88.2</b> |




图 4: 分类别 pixel AUPRO 的目标模式 (MVTec, 占位图)。正式版本比较 Ours 与 SemanticProto, 检验增益是否集中在纹理/微缺陷类。

值差和 bootstrap 置信区间。只有当纹理或微缺陷组的增益显著高于其余类别, 才能把平均增益解释为频谱可靠性的作用; 否则只报告总体改善, 不做机制归因。

### 5.3 语义原型漏检子集

我们先在独立验证划分上为 SemanticProto 固定像素阈值, 再把测试集中低于该阈值的异常像素定义为“语义原型漏检子集”。该指标只用于诊断, 必须同时报告: (1) 漏检子集占全部异常像素的比例; (2) Ours 相对 SemanticProto 的召回增量; (3) Ours 在其余像素上的误报增量; (4) bootstrap 置信区间。图 5 仅给出目标占位。若召回提升伴随等量的全局误报上升, 则不能说明小波可靠性补充了语义证据。




图 5: 语义原型漏检子集的召回目标 (占位图)。正式版本必须报告阈值来源、子集规模、召回增量、非子集误报增量及置信区间。

表 4: 正常图假阳性面积 (越低越好) 与运行时。数值为预期目标。

| 数据集   | 方法          | FP@p95(%)  | FP@p99(%)   | s/img |
|-------|-------------|------------|-------------|-------|
| MVTec | Baseline    | 5.0        | 1.00        | 0.065 |
|       | NoCons      | 4.9        | 0.98        | —     |
|       | <b>Ours</b> | <b>4.6</b> | <b>0.90</b> | 0.079 |
| VisA  | Baseline    | 5.0        | 1.00        | 0.065 |
|       | NoCons      | 4.8        | 0.95        | —     |
|       | <b>Ours</b> | <b>4.5</b> | <b>0.88</b> | 0.079 |

### 5.4 稳定性、运行时与敏感性

表 4 与图 6 分别给出正常图稳定性、运行时和超参敏感性的目标骨架。mix=0 对应 SemanticProto; 随着 mix 增大, 小波可靠性影响增强。若性能在中小 mix 区间形成稳定平台、而过大 mix 下降, 说明频谱信号适合作为弱可靠性调制而非主导证据。所有数值在真实实验前仅作为通过线。

### 5.5 定性结果

我们规划展示输入、真值、Baseline、SemanticProto、频谱可靠性  $W$  与 Ours, 如图 7 所示。定性图需要同时说明两点:  $W$  可以在缺陷附近响应, 但在正常纹理和结构边界上也可能明亮; Ours 并非复制  $W$ , 而是通过校准语义原型抑制不可靠响应。该图为占位版, 待真实推理结果生成后替换。

### 5.6 设计消融

表 5 规划比较裸高频、边界感知可靠性和保守更新。只有当边界感知相对 HFProto 提升, 且保守更新在不损失平均指标的同时降低正常图误报, 才能分别支持两个设计。




图 6: 超参敏感性 (MVTec, pixel AUPRO)。(b) wavelet-mix 兼作机制曲线——高频过多反而有害。

表 5: 设计消融 (MVTec)。数值为预期目标。

| 变体               | pAUROC      | pAUPRO      | iAUROC      | iAP         |
|------------------|-------------|-------------|-------------|-------------|
| HFOonly (裸高频)    | 92.0        | 85.0        | 94.1        | 97.4        |
| NoCons (无保守)     | 92.1        | 85.3        | 94.0        | 97.3        |
| <b>Ours (完整)</b> | <b>92.4</b> | <b>85.8</b> | <b>94.2</b> | <b>97.5</b> |

## 6 结论

本文围绕固定文本原型缺少实例外观参照这一问题，提出频谱可靠性引导的测试时语义原型校准。小波分解不直接产生最终异常图，而是调制语义 patch 证据，帮助构造逐图视觉原型；视觉原型随后以保守方式校准正常/异常文本原型，最终仍在 CLIP 语义空间中完成定位。该设计把频率线索与语义判别的职责分开，也使直接融合、纯语义自参照和边界感知可靠性能通过受控实验分别验证。

局限。当前稿件中的实验数字仍是占位目标，不能被解释为完成结果。即使未来完整方法优于原始 AnomalyCLIP，也只有在其相对 SemanticProto 的增益集中于预期类别、且稳定性与直接融合负控共同成立时，才可以把提升归因于频谱可靠性。此外，逐图原型会受背景、异常面积和 patch 分辨率影响，逻辑异常也未被直接解决。

未来工作。将频谱可靠性引导的逐图原型构造推广到其他冻结视觉-语言编码器，并研究能够显式处理背景和逻辑异常的参照构造策略。

## 参考文献

- [1] Paul Bergmann, Michael Fauser, David Sattlegger, and Carsten Steger. MVTec AD - A comprehensive real-world dataset for unsupervised anomaly detection. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 9592–9600. Computer Vision Foundation / IEEE, 2019.
- [2] Yunkang Cao, Jiangning Zhang, Luca Frittoli, Yuqi Cheng, Weiming Shen, and Giacomo Boracchi. AdaCLIP: Adapting CLIP with hybrid learnable prompts for zero-shot anomaly detection. In *Computer Vision - ECCV 2024*, volume 15093 of *Lecture Notes in Computer Science*, pages 55–72. Springer, 2024.
- [3] Tao Gong, Qi Chu, Bin Liu, Wei Zhou, and Nenghai Yu. FE-CLIP: Frequency enhanced CLIP model for zero-shot anomaly detection and segmentation. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 21220–21230. IEEE, 2025.
- [4] Jongheon Jeong, Yang Zou, Taewan Kim, Dongqing Zhang, Avinash Ravichandran, and Onkar Dabeer. WinCLIP: Zero-/few-shot anomaly classification and segmentation. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 19606–19616. IEEE, 2023.
- [5] Yiting Li, Adam David Goodge, Fayao Liu, and Chuan-Sheng Foo. PromptAD: Zero-shot anomaly detection using text prompts. In *IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, pages 1082–1091. IEEE, 2024.
- [6] Wenxin Ma, Xu Zhang, Qingsong Yao, Fenghe Tang, Chenxu Wu, Yingtai Li, Rui Yan, Zihang Jiang, and S. Kevin Zhou. AA-CLIP: Enhancing zero-shot anomaly detection via anomaly-aware CLIP. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 4744–4754. Computer Vision Foundation / IEEE, 2025.
- [7] Zhen Qu, Xian Tao, Mukesh Prasad, Fei Shen, Zhengtao Zhang, Xinyi Gong, and Guiguang Ding. VCP-CLIP: A visual context prompting model for zero-shot anomaly segmentation. In *Computer Vision - ECCV 2024*, volume 15127 of *Lecture Notes in Computer Science*, pages 301–317. Springer, 2024.
- [8] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever.

|          | 输入 | 真值 GT | Baseline | SemanticProto | 可靠性 W       | Ours     |
|----------|----|-------|----------|---------------|-------------|----------|
| carpet   | 原图 | GT 掩码 | 异常图 偏弱   | 语义原型 漏检       | 全片亮 (含正常纹理) | 准确 定位    |
|          | 原图 | GT 掩码 | 异常图 偏弱   | 语义原型 漏检       | 全片亮         | 准确 定位    |
| grid     | 原图 | GT 掩码 | 异常图 偏弱   | 语义原型 漏检       | 全片亮         | 准确 定位    |
|          | 原图 | GT 掩码 | 异常图 偏弱   | 部分 漏检         | 全片亮         | 准确 定位    |
| wood     | 原图 | GT 掩码 | 异常图 偏弱   | 部分 漏检         | 全片亮         | 准确 定位    |
|          | 原图 | GT 掩码 | 可定位      | 可定位           | 缺陷处亮        | 与语义原型 相当 |
| bottle   | 原图 | GT 掩码 | 可定位      | 可定位           | 缺陷处亮        | 与语义原型 相当 |
|          | 原图 | GT 掩码 | 异常图 偏弱   | 漏检 微缺陷        | 全片亮         | 捞回 微缺陷   |
| VisA pcb | 原图 | GT 掩码 | 异常图 偏弱   | 漏检 微缺陷        | 全片亮         | 捞回 微缺陷   |

图 7: 定性对比 (占位图, 待真实推理结果替换)。列依次为: 输入、真值掩码、Baseline 异常图、SemanticProto (纯语义逐图原型) 异常图、频谱可靠性 W、Ours 异常图。前四行为 MVTeC (纹理类 carpet/grid/wood + 物体类 bottle), 末行为 VisA。正式结果应展示: W 在缺陷附近响应, 但在正常纹理与结构边界上也可能明亮; SemanticProto 在部分纹理与微缺陷上漏检; Ours 通过原型校准改善定位, 同时在物体类上不退化。热力图统一采用同一色标与归一化。

Learning transferable visual models from natural language supervision. In *Proceedings of the 38th International Conference on Machine Learning (ICML)*, volume 139 of *Proceedings of Machine Learning Research*, pages 8748–8763. PMLR, 2021.

- [9] Qihang Zhou, Guansong Pang, Yu Tian, Shibo He, and Jiming Chen. AnomalyCLIP: Object-agnostic prompt learning for zero-shot anomaly detection. In *The Twelfth International Conference on Learning Representations (ICLR)*. OpenReview.net, 2024.

- [10] Yang Zou, Jongheon Jeong, Latha Pemula, Dongqing Zhang, and Onkar Dabeer. SPot-the-Difference self-supervised pre-training for anomaly detection and segmentation. In *Computer Vision - ECCV 2022*, volume 13690 of *Lecture Notes in Computer Science*, pages 392–408. Springer, 2022.

## A 正交增强与全局设置

**Pure / Enhanced 口径。** Pure 口径只包含固定特征提取、统一平滑和原型校准, 所有机制 claim 均由该口径支持。Enhanced 口径对每个对照统一叠加 multi-crop 聚合与 pixel-to-image 融合, 用于展示与标准后处理的兼容性。若 Enhanced 改变方法排序, 正文必须以 Pure 结果为准, 并把增强结果降为补充材料。

**全局设置 vs 逐数据集调参。** 表 6 区分统一全局设置与逐数据集调参上界。我们主张以全局设置作为公平结论, 调参行仅作为上界参考, 以避免“测试集调参”的质疑。

表 6: 全局设置 vs 逐数据集调参上界 (pixel AUPRO, %)。数值为预期目标。

| 数据集       | 全局设置 | 逐数据集调参 (上界) |
|-----------|------|-------------|
| MPDD      | 88.4 | 90.5        |
| BTAD      | 79.5 | 78.5        |
| DTD-Synth | 90.7 | 91.5        |

可复现性说明。 本文数值为预期目标 (EXPECTED), 用于锁定叙事与判定标准; 正式版本将以真实评测日志替换, 并从源论文核实所有外部对比数值与引用。