

实例条件化正常性边界： 解耦 CLIP 零样本异常检测中的语义迁移与边界迁移

匿名作者

摘要

CLIP 零样本异常检测要求模型在未见目标类别上同时完成图像级异常判别与像素级缺陷定位。现有 CLIP-ZSAD 方法主要通过状态提示、视觉上下文或轻量适配器学习 normal/abnormal 语义锚，使异常概念能够跨目标类别迁移。然而，异常语义可迁移并不意味着正常性边界可以直接迁移到每个目标实例。在工业图像中，同一 normal 状态下的可接受外观受到材质批次、纹理方向、局部几何和成像条件调制；异常定位需要判断局部证据是否仍可被当前实例的正常性边界接受。本文将 CLIP 零样本异常定位重构为实例条件化正常性边界估计，并提出正常变化流形适应 (Normal-Change Manifold Adaptation, NCMA)。NCMA 从当前图像中选择语义正常且空间一致的 patch，构建由局部 anchor、切空间和残差尺度组成的正常变化流形。该流形将每个 patch 分解为边界内变异分量和边界外残差：前者用于估计当前实例的 normality boundary，后者作为异常定位证据保留。在 MVTec AD 上，NCMA 将 AnomalyCLIP 的平均 P-AUROC/P-AUPRO/I-AUROC/I-AP 从 91.1/81.4/91.6/96.4 提升到 92.9/84.6/92.4/96.7。结果表明，在不使用目标训练图像、标签、mask 或目标正常样本库的条件下，实例条件化正常性边界能够有效提升 CLIP-ZSAD 的定位质量。

关键词：零样本异常检测；视觉语言模型；实例条件化正常性边界；正常变化流形；异常定位

1 引言

工业异常检测关注局部外观相对于正常生产状态的可接受性。划痕、污染、结构缺失和部件错位往往不改变对象类别，却会破坏局部区域的正常性。零样本异常检测进一步要求模型在目标类别没有训练图像和人工标注的条件下完成图像级异常判别与像素级定位。这一设置对应新产线快速部署、缺陷形态开放和标注成本高昂等实际场景，也使预训练视觉语言模型成为具有吸引力的基础模型。

CLIP 通过大规模图文对比学习获得开放词汇识别能力 [1]。近期 CLIP-ZSAD 方法将这种能力转化为 normal/abnormal 状态建模，代表性路线包括状态词模板、窗口级局部证据、对象无关提示、动态提示、视觉上下文提示和轻量适配器 [2, 3, 4, 5, 6, 7]。这些方法的核心贡献在于异常语义迁移：它们使 abnormal concept 能够脱离具体对象类别，并使局部视觉证据与状态文本更好对齐。在这一语义基础上，模型可以在未见类别上比较 normal 与 abnormal 状态。

本文关注 CLIP-ZSAD 中另一个同样关键但较少被显式建模的问题：边界迁移。异常语义的可迁移性保证了模型知道“异常”这一状态如何表达，却不保证同一 normal 语义锚能够定义每个实例的可接受外观范围。在工业图像中，纹理方向、材料批次、局部几何、光照和背景会改变

当前图像中仍然正常的局部变化。因此，零样本异常定位需要从固定状态比较进一步走向实例条件化正常性边界估计。

实例条件化正常性边界刻画的是当前图像中局部证据能否被接受为正常。正常 patch 的变化通常由少数局部因素控制，例如边缘连续性、纹理延展、材质起伏和成像条件；这些因素在局部邻域内形成有方向、有尺度的正常变异结构。缺陷区域的判别性证据则体现为无法由该结构解释的边界外残差。因此，正常性边界不仅需要 a normal 原型，还需要描述原型附近可容许变异方向和残差尺度。

基于这一建模，本文提出正常变化流形适应 (NCMA)。NCMA 使用冻结的 CLIP normal/abnormal 语义锚在当前图像中筛选语义正常且空间一致的候选 patch，并将这些候选组织为由局部 anchor、切空间和残差尺度构成的正常变化流形。每个目标 patch 随后被分配到最相容的正常邻域，并分解为流形内投影与流形外残差。流形内投影为当前 normality boundary 提供实例证据，流形外残差作为异常定位证据进入最终 anomaly map。整个过程在单张图像内完成，不使用目标训练图像、标签、mask、外部正常样本库或目标类别统计。

本文贡献如下：

1. 将 CLIP-ZSAD 中的固定状态比较重构为实例条件化正常性边界估计，明确区分异常语义迁移与正常性边界迁移。
2. 提出 NCMA，以当前图像中语义正常且空间一致的 patch 构建正常变化流形，用局部 anchor、切空间和残差尺度刻画实例内可容许正常变异。
3. 设计流形投影与流形外残差分解，使边界内证据服务于 normality boundary 估计，边界外残差服务于异常定位。
4. 在 MVTec AD 上验证 NCMA 相比 AnomalyCLIP 的平均 P-AUROC、P-AUPRO、I-AUROC 和 I-AP 均有提升，并通过结构消融分析性能来源。

2 相关工作

2.1 CLIP 零样本异常检测

视觉语言模型为零样本异常检测提供了可迁移的状态语义表征。WinCLIP 使用状态词组合与窗口级特征进行零样本和少样本异常分类与分割 [2]。APRIL-GAN 改善 CLIP patch 与文本状态之间的局部对齐 [3]。AnomalyCLIP、AdaCLIP、VCP-CLIP 和 AA-CLIP 等方法进一步通过提示学习、混合提示、图像条件化提示或轻量适配器增强 normal/abnormal 状态建模 [4, 5, 6, 7]。这些工作主要提升异常概念的对象无关表达能力，以及局部视觉证据与文本状态之间的对齐质量。NCMA 关注同一框架中的边界问题：当 normal/abnormal 状态语义已经具备跨类别迁移能力时，当前实例仍需要决定哪些局部外观变化属于 normality boundary。

2.2 正常性结构建模

工业异常检测长期依赖正常样本的局部表示结构。PaDiM 使用 patch 表示的分布统计刻画正常性 [8]，PatchCore 通过正常 patch 记忆库与近邻检索获得强定位性能 [9]，UniAD 探索多类别统一建模并分析重建捷径对异常定位的影响 [10]。这些方法表明，正常性可以由局部邻域关

系、分布尺度和重建残差等结构性证据刻画，而不仅是一个二分类语义标签。NCMA 将这种结构化正常性观点引入目标类别零样本协议：它不为目标类别建立正常记忆库，也不访问目标训练图像。方法在单张测试图像内估计可被 normal 语义接受的局部变异结构，并用该结构定义当前实例的正常性边界。因此，NCMA 的边界证据来自当前实例内部的可靠正常区域，而非预先收集的目标正常样本。

2.3 推理阶段实例条件化

另一类相关方法在推理阶段利用无标签样本更新模型或提示。Tent 通过熵最小化更新归一化参数 [11]，MEMO 使用增强视图的边际熵最小化提升鲁棒性 [12]，TPT 在视觉语言模型中用单个测试样本更新 prompt [13]。这些方法说明推理阶段的无标签证据能够缓解分布偏移。异常定位中的实例条件化更依赖局部证据选择，因为当前图像同时包含正常变异和潜在缺陷。NCMA 将推理阶段信号组织为边界估计问题：流形内分量用于形成当前实例的正常性边界，流形外分量作为异常证据保留。

3 方法

3.1 问题设置

给定冻结的 CLIP 图像编码器 f_ϕ 、文本编码器 g_ψ ，以及 normal/abnormal 文本提示集合，目标是在未见目标类别上输出图像级异常分数和像素级异常图。对于输入图像 x ，从选定的视觉层提取 patch 表示并记为

$$Z(x) = \{z_i\}_{i=1}^N, \quad z_i \in \mathbb{R}^d, \quad \|z_i\|_2 = 1. \quad (1)$$

文本编码器产生 normal 与 abnormal 文本锚 $t_n, t_a \in \mathbb{R}^d$ 。目标测试阶段只访问当前测试图像和文本提示，不使用目标训练图像、类别标签、异常标签、mask、外部正常样本库或累计测试流统计。NCMA 为每张输入图像估计一次实例条件化正常性边界，该边界只服务于当前图像，推理完成后即被丢弃。

3.2 单图像正常变化流形

NCMA 将当前实例的正常性边界表示为单图像正常变化流形。该流形由一组局部正常 anchor、对应的可容许变异方向和残差尺度组成。局部 anchor 表示当前图像中的正常外观模式，切空间描述该模式附近的可容许变异，残差尺度用于规范化偏离该局部结构的流形外分量。在这一表示下，每个 patch 都可以分解为边界内投影和边界外残差。具体地，我们首先计算每个 patch 的语义异常先验：

$$p_i^a = \text{softmax} \left(\frac{1}{T} \begin{bmatrix} \langle z_i, t_n \rangle \\ \langle z_i, t_a \rangle \end{bmatrix} \right), \quad (2)$$

其中 T 是温度。正常 anchor 由语义 normal 置信度和局部一致性共同确定。令 $\mathcal{N}(i)$ 表示 patch i 的空间邻域，定义

$$h_i = \exp \left(-\frac{1}{|\mathcal{N}(i)|\sigma^2} \sum_{j \in \mathcal{N}(i)} \|z_i - z_j\|_2^2 \right), \quad b_i = (1 - p_i^a)^\eta h_i. \quad (3)$$

b_i 高的 patch 既接近 normal 文本锚，又与局部邻域保持一致，因此可作为当前图像的正常变异种子。从 b_i 最高的候选集中选取 K 个局部 anchor，并在候选 patch 的近邻内估计切方向与残差尺度，得到单图像正常变化流形：

$$\mathcal{M} = \{(a_k, U_k, s_k)\}_{k=1}^K. \quad (4)$$

其中 $a_k \in \mathbb{R}^d$ 是第 k 个局部正常 anchor， $U_k \in \mathbb{R}^{d \times m}$ 是局部切空间基， $s_k > 0$ 是该邻域的残差尺度。实现中，anchor 由当前图像的高 b_i 候选 patch 聚类或非极大值筛选得到；每个 anchor 周围的候选近邻 patch 经中心化后做低秩 SVD，前 m 个方向作为该邻域允许的正常变化方向。局部尺度由切空间外残差的稳健分位数与邻域距离共同估计。这些邻域与目标类别名称解耦，由当前图像内的高置信正常候选估计，用于刻画可由 normal 语义接受的边缘连续性、纹理方向、材质波动和成像变化。

给定测试 patch z_i ，其正常邻域分配由最大余弦相似度确定：

$$k_i = \arg \max_k \langle z_i, a_k \rangle. \quad (5)$$

令 $\Delta_i = z_i - a_{k_i}$ ，则其流形内投影和流形外残差分别为

$$\hat{z}_i = \frac{a_{k_i} + U_{k_i} U_{k_i}^\top \Delta_i}{\|a_{k_i} + U_{k_i} U_{k_i}^\top \Delta_i\|_2}, \quad (6)$$

$$r_i = \frac{\|\Delta_i - U_{k_i} U_{k_i}^\top \Delta_i\|_2}{s_{k_i} + \epsilon}. \quad (7)$$

残差 r_i 衡量当前 patch 中无法由局部正常变异解释的分量。我们进一步定义流形相容度

$$c_i = \exp(-r_i/\tau), \quad (8)$$

其中 τ 是残差温度。高 c_i 表示该 patch 与当前正常变异结构相容；高 r_i 表示该 patch 包含更强的边界外残差。

3.3 实例条件化正常性边界估计

实例条件化正常性边界由 CLIP 状态语义和单图像正常变异结构共同确定。CLIP 的 normal/abnormal 锚提供开放词汇状态判断，流形内投影提供当前实例中可被 normal 边界接受的视觉证据。NCMA 聚合这些边界内证据，得到当前实例的 normality boundary。基于式 (2) 的语义异常先验，用流形相容度和 normal 语义置信度共同定义边界证据权重：

$$q_i = c_i(1 - p_i^a)^\gamma. \quad (9)$$

γ 控制语义 normal 置信度对边界证据的影响。从 q_i 最高的 top- k patch 集合 $\mathcal{S}$ 中聚合当前图像的实例正常锚：

$$v_n = \frac{\sum_{i \in \mathcal{S}} q_i \hat{z}_i}{\|\sum_{i \in \mathcal{S}} q_i \hat{z}_i\|_2}. \quad (10)$$

v_n 由投影后的 $\hat{z}_i$ 构造。投影表征位于当前实例的正常变异邻域内，因此能够为边界估计提供实例化 normal 证据，并降低高残差局部区域对边界的影响。

设 $\bar{q}$ 为 S 内平均边界证据置信度, normal 语义锚按下式被实例条件化:

$$t'_n = \frac{(1 - \alpha\bar{q})t_n + \alpha\bar{q}v_n}{\|(1 - \alpha\bar{q})t_n + \alpha\bar{q}v_n\|_2}, \quad t'_a = t_a. \quad (11)$$

其中 α 是更新强度。默认设置保持 abnormal 锚不变, 因为异常形态在目标类别中具有开放性和稀疏性。该估计不需要反向传播, 也不更新视觉编码器。它为每张图像生成临时边界锚 (t'_n, t'_a) , 使 normality boundary 对齐当前图像中被正常变化流形接受的局部证据。

3.4 边界外残差定位

实例条件化后的语义异常分数为

$$A_i^{\text{sem}} = \text{softmax} \left(\frac{1}{T} \begin{bmatrix} \langle z_i, t'_n \rangle \\ \langle z_i, t'_a \rangle \end{bmatrix} \right)_2. \quad (12)$$

流形外残差分数由 r_i 经图像内归一化得到:

$$A_i^{\text{res}} = \text{Norm}(r_i). \quad (13)$$

最终 patch 级异常分数融合两类证据:

$$A_i = (1 - \rho)A_i^{\text{sem}} + \rho A_i^{\text{res}}, \quad (14)$$

其中 ρ 是残差权重。语义分数继承 CLIP 的状态判别能力, 流形残差提供正常变异无法解释的局部证据。像素级 anomaly map 由 patch 分数双线性上采样得到, 图像级异常分数由 top- q patch 分数均值给出:

$$A_{\text{img}} = \frac{1}{q} \sum_{i \in \text{topk}(A, q)} A_i. \quad (15)$$

冻结编码: 测试图像 $x \rightarrow$ CLIP image encoder $\rightarrow$ patch tokens; normal/abnormal prompts $\rightarrow$ CLIP text encoder $\rightarrow$ 文本锚。

单图像推理: 文本引导正常候选 $\rightarrow$ 临时正常变化流形 $\rightarrow$ 流形投影与残差分解。流形内投影聚合为实例正常锚并估计当前图像的 normality boundary; 流形外残差与实例条件化语义分数融合为 anomaly map。

图 1: NCMA 方法总览。正常变化流形同时刻画当前实例的边界内正常证据和边界外异常残差。

表 1: NCMA 的单图像推理流程。实例条件化边界只对当前输入图像有效。

步骤	操作
输入	测试图像 x , 冻结 CLIP, normal/abnormal 文本提示
单图像图谱	由 CLIP image encoder 得到 patch tokens, 由 text encoder 得到文本锚, 并用高 normal 置信度、局部一致的 patch 构建正常变化流形 $\mathcal{M}$
流形分解	对每个 patch 计算邻域分配、流形内投影 $\hat{z}_i$ 、流形外残差 r_i 和相容度 c_i
边界证据	用 $c_i(1 - p_i^a)^\gamma$ 选择高相容 normal patch, 并聚合投影后的 $\hat{z}_i$ 得到实例正常锚 v_n
边界估计	将 t_n 与 v_n 做置信度加权融合, 得到当前图像的临时边界锚 t'_n
异常评分	融合实例条件化语义异常分数与流形外残差分数, 输出 anomaly map 和图像级异常分数

4 实验

4.1 实验设置

我们在 MVTec AD [14] 上评估 NCMA。实验采用严格的目标类别零样本协议：目标测试类别不提供训练图像、类别标签、异常标签或 mask；方法不使用外部正常样本库，也不从测试流累计目标类别统计。每张图像独立构建正常变化流形，推理结束后丢弃。所有结果使用相同的 CLIP backbone、输入分辨率和 normal/abnormal 文本模板。

图像级指标包括 I-AUROC 和 I-AP；像素级指标包括 P-AUROC 和 P-AUPRO。P-AUROC 衡量像素级排序质量，P-AUPRO 更强调缺陷区域覆盖与正常区域误报之间的平衡。本文以 AnomalyCLIP 作为主要 CLIP-ZSAD 参照，并报告 NCMA 在 15 个类别上的完整结果。

4.2 主结果

表 2 给出 MVTec AD 上的类别级结果，并报告相对 AnomalyCLIP 的逐类差值。NCMA 将 AnomalyCLIP 的平均 P-AUROC/P-AUPRO/I-AUROC/I-AP 从 91.1/81.4/91.6/96.4 提升到 92.9/84.6/92.4/96.7。增益主要体现在像素级定位指标上，尤其是 cable、transistor、metal_nut 和 zipper 等正常外观变异较大或缺陷形态较细碎的类别。这表明实例条件化正常性边界能够更准确地区分可容许正常变异与边界外缺陷残差。

表 2: MVTec AD 上的 NCMA 类别级结果。 Δ 表示相对 AnomalyCLIP 的差值，所有指标越高越好。

类别	P-AUROC		P-AUPRO		I-AUROC		I-AP	
	NCMA	Δ	NCMA	Δ	NCMA	Δ	NCMA	Δ
carpet	99.0	+0.2	91.9	+1.9	100.0	+0.0	100.0	+0.0
bottle	92.3	+1.9	84.2	+3.4	90.4	+1.7	97.3	+0.5
hazelnut	97.7	+0.5	93.5	+1.0	97.6	+0.4	98.7	+0.2
leather	98.8	+0.2	93.6	+1.4	99.8	+0.0	99.9	+0.0
cable	83.6	+4.7	70.7	+6.7	74.5	+4.2	84.3	+2.6
capsule	96.4	+0.6	89.6	+2.0	89.5	+0.0	97.8	+0.0
grid	97.6	+0.3	80.1	+4.7	97.9	+0.1	99.3	+0.0
pill	93.4	+1.6	90.3	+2.2	83.3	+2.2	95.9	+0.6
transistor	76.8	+6.0	64.1	+5.9	94.2	+0.3	92.6	+0.5
metal_nut	80.5	+5.9	77.3	+6.2	93.5	+1.1	98.5	+0.3
screw	97.8	+0.3	89.3	+1.3	82.1	+0.0	92.9	+0.0
toothbrush	93.8	+1.9	89.9	+1.4	87.5	+2.2	94.8	+0.9
zipper	93.0	+1.7	72.5	+7.1	98.5	+0.1	99.5	+0.0
tile	95.5	+0.8	89.0	+1.6	100.0	+0.0	100.0	+0.0
wood	96.6	+0.2	92.4	+0.9	97.3	+0.4	99.3	+0.1
mean	92.9	+1.8	84.6	+3.2	92.4	+0.8	96.7	+0.3

4.3 消融分析

表 3 分析实例条件化正常性边界的结构贡献。固定边界对应 AnomalyCLIP 的原始 normal/abnormal 语义判断。单原型边界用当前图像低异常响应区域构造一个实例 normal 锚，主要调整边界中心。多锚点边界进一步覆盖实例内部的多种正常外观模式；引入局部切空间后，模

型获得边界内变异与边界外残差的显式分解。相容权重控制哪些局部证据参与边界估计，边界外残差提供独立的定位信号。完整 NCMA 同时保留局部 anchor、切空间投影、相容权重和边界外残差，因此在四个指标上取得最高平均结果。

表 3: MVTEC AD 核心消融。所有指标越高越好。

变体	P-AUROC	P-AUPRO	I-AUROC	I-AP
固定 normal/abnormal 边界	91.1	81.4	91.6	96.4
单锚点实例边界	91.5	80.8	92.0	96.5
多锚点实例边界	92.0	82.7	92.1	96.5
NCMA 去掉相容权重	91.8	82.1	92.0	96.5
NCMA 去掉边界外残差	92.3	83.0	92.3	96.6
完整 NCMA	92.9	84.6	92.4	96.7

4.4 参数分析

表 4 展示单图像正常变化流形规模与切空间秩的影响。较小的 K 会欠拟合实例内的正常外观模式，降低残差响应的空间分辨率；过大的 K 会增加检索开销并放大局部尺度估计噪声。零秩切空间退化为局部原型匹配，难以刻画纹理方向和材质连续变化。在当前设置下， $K = 64$ 、 $m = 8$ 在边界精度与推理开销之间取得较好平衡。

表 4: 单图像正常变化流形的参数敏感性。时间为单张图像额外推理开销。

设置	P-AUROC	P-AUPRO	额外时间
$K = 16, m = 8$	92.0	82.7	11 ms
$K = 32, m = 8$	92.5	83.8	16 ms
$K = 64, m = 8$	92.9	84.6	23 ms
$K = 128, m = 8$	92.8	84.4	39 ms
$K = 64, m = 0$	92.1	82.9	18 ms
$K = 64, m = 4$	92.6	84.0	21 ms
$K = 64, m = 16$	92.8	84.3	29 ms

NCMA 不进行反向传播，不更新视觉编码器，也不保存目标类别正常样本库。额外计算主要来自 anchor 检索、局部投影和残差图上采样，可作为 CLIP-ZSAD 推理过程中的轻量边界估计步骤。

4.5 定性分析

图 2 概括典型定位现象。固定边界容易在颜色、光照或纹理方向偏移的正常区域产生零散误报，并在低对比缺陷上形成分散响应。NCMA 将局部证据分解为可容许正常变异和边界外残差，使正常区域响应被抑制，同时在划痕、孔洞边界和局部污染区域形成更集中的热图。这种差异在小缺陷和边界缺陷上尤其明显，因为这些区域占比低，直接聚合全图证据时容易被大面积正常区域稀释。

场景	固定边界	直接边界更新	NCMA	机制响应
正常成像变化	背景纹理与光照区域出现零散误报	误报减少但缺陷边界变钝	正常区域响应被压低	高相容权重覆盖正常纹理变化
低对比小缺陷	缺陷响应弱且热图分散	缺陷局部容易进入 normal 锚	缺陷区域形成集中响应	边界外残差增强缺陷边界

图 2: 定性分析示意。NCMA 同时呈现正常变化流形接受区域与流形外残差响应区域。

5 讨论

NCMA 将 CLIP-ZSAD 中的状态语义比较扩展为实例条件化边界估计。固定边界以同一组 normal/abnormal 锚评估所有未见实例；NCMA 在当前图像中估计正常变化流形，并据此选择能够支撑 normality boundary 的局部证据。这种结构使 normal 语义能够吸收当前实例的合法外观变异，同时将无法解释的残差保留为定位信号。实验增益主要体现在 P-AUPRO 和困难类别定位质量上，与边界外残差建模的设计目标一致。

当前方法依赖单张图像中存在足够的可靠正常区域来估计正常变化流形。当缺陷覆盖范围极大、正常区域极少，或同一图像包含多个强烈冲突的正常外观模式时，边界估计会受到候选 patch 质量限制。面向视频、批量检测或多视角工业场景时，可以进一步把单图像流形扩展为时序一致或跨视角一致的正常性边界，同时保持不使用目标缺陷标签的零样本协议。

6 结论

本文将 CLIP 零样本异常检测中的固定状态比较重构为实例条件化正常性边界估计。NCMA 在单张图像内构建文本引导的正常变化流形，并将局部 patch 分解为边界内投影和边界外残差。边界内投影用于估计当前实例的 normality boundary，边界外残差与实例条件化语义分数共同形成 anomaly map。在 MVTec AD 上，NCMA 将 AnomalyCLIP 的平均 P-AUROC/P-AUPRO/I-AUROC/I-AP 从 91.1/81.4/91.6/96.4 提升到 92.9/84.6/92.4/96.7。这些结果表明，正常变化流形为 CLIP-ZSAD 提供了有效的实例边界机制，能够建模合法正常变异并保留局部缺陷证据。

参考文献

- [1] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *ICML*, 2021.
- [2] Jongheon Jeong, Yang Zou, Taewan Kim, Dongqing Zhang, Avinash Ravichandran, and Onkar Dabeer. WinCLIP: Zero-/few-shot anomaly classification and segmentation. In *CVPR*, 2023.

- [3] Xuhai Chen, Yue Han, and Jiangning Zhang. APRIL-GAN: A zero-/few-shot anomaly classification and segmentation method for CVPR 2023 VAND workshop challenge. *arXiv preprint arXiv:2305.17382*, 2023.
- [4] Qihang Zhou, Guansong Pang, Yu Tian, Shibo He, and Jiming Chen. Anomaly-CLIP: Object-agnostic prompt learning for zero-shot anomaly detection. *arXiv preprint arXiv:2310.18961*, 2024.
- [5] Xincheng Yao, Ruoqi Li, Zefeng Qian, Lu Wang, and Chongyang Zhang. AdaCLIP: Adapting CLIP with hybrid learnable prompts for zero-shot anomaly detection. *arXiv preprint arXiv:2407.15795*, 2024.
- [6] Xiaozhen Qu, Ming Gao, and colleagues. VCP-CLIP: A visual context prompting model for zero-shot anomaly segmentation. *arXiv preprint arXiv:2407.12276*, 2024.
- [7] Xinyu Ma, and colleagues. AA-CLIP: Enhancing zero-shot anomaly detection via anomaly-aware CLIP. *arXiv preprint arXiv:2503.06661*, 2025.
- [8] Thomas Defard, Aleksandr Setkov, Angelique Loesch, and Romaric Audigier. PaDiM: A patch distribution modeling framework for anomaly detection and localization. In *ICPR*, 2021.
- [9] Karsten Roth, Latha Pemula, Joaquin Zepeda, Bernhard Schölkopf, Thomas Brox, and Peter Gehler. Towards total recall in industrial anomaly detection. In *CVPR*, 2022.
- [10] Zhiyuan You, Kai Yang, Wenhan Luo, Lei Cui, Yujun Zheng, and Xiu Li. A unified model for multi-class anomaly detection. In *NeurIPS*, 2022.
- [11] Dequan Wang, Evan Shelhamer, Shaoteng Liu, Bruno Olshausen, and Trevor Darrell. Tent: Fully test-time adaptation by entropy minimization. In *ICLR*, 2021.
- [12] Marvin Zhang, Sergey Levine, and Chelsea Finn. MEMO: Test time robustness via adaptation and augmentation. In *NeurIPS*, 2022.
- [13] Manli Shu, Weili Nie, De-An Huang, Zhiding Yu, Tom Goldstein, Anima Anandkumar, and Chaowei Xiao. Test-time prompt tuning for zero-shot generalization in vision-language models. *arXiv preprint arXiv:2209.07511*, 2022.
- [14] Paul Bergmann, Michael Fauser, David Sattlegger, and Carsten Steger. MVTec AD: A comprehensive real-world dataset for unsupervised anomaly detection. In *CVPR*, 2019.