

实例条件化正常性边界： 基于正常变化流形的 CLIP 零样本异常检测

匿名作者

摘要

CLIP 零样本异常检测要求模型在未见目标类别上识别异常图像并定位缺陷区域。现有 CLIP-ZSAD 方法通常通过状态提示、视觉上下文或轻量适配器构造 normal/abnormal 语义锚，并默认这组语义边界可以迁移到每个目标实例。然而，工业图像中的正常性具有显著的实例条件性：光照、材质批次、纹理方向、局部结构和成像条件都会改变当前图像中“仍然正常”的外观范围。固定 normal 锚容易把合法正常变化判为异常，而无约束的实例更新又可能把真实缺陷吸收为正常。本文将 CLIP 零样本异常定位重构为实例条件化正常性边界估计，并提出正常变化流形适应 (Normal-Change Manifold Adaptation, NCMA)。NCMA 从当前测试图像中选择语义正常且局部一致的 patch，以局部 anchor、切方向和残差尺度刻画当前实例的正常变化轨道。每个目标 patch 随后被分解为轨道内正常变化与轨道外残差；前者用于估计当前实例的 normality boundary，后者被保留为异常定位证据。在 MVTec AD 上，NCMA 将 AnomalyCLIP 的平均 P-AUROC/P-AUPRO/I-AUROC/I-AP 从 91.1/81.4/91.6/96.4 提升到 92.9/84.6/92.4/96.7。结果表明，实例条件化正常性边界能够在不使用目标训练图像、标签、mask 或目标正常样本库的条件下提升 CLIP-ZSAD 的定位质量。

关键词：零样本异常检测；视觉语言模型；实例条件化正常性边界；正常变化流形；异常定位

1 引言

工业异常检测的目标不是识别产品属于哪个类别，而是判断局部外观是否仍落在正常生产状态之内。划痕、污染、破损或缺失部件通常不会改变图像的对象语义，却会改变局部区域是否仍可被接受为正常。零样本异常检测进一步要求模型在目标类别没有训练图像和人工标注的情况下完成图像级检测与像素级定位。这一设置贴近新产线快速部署和缺陷形态不可预知的实际场景，也使预训练视觉语言模型成为自然选择。

CLIP 通过大规模图文对比学习获得开放词汇识别能力 [1]。近期 CLIP-ZSAD 方法将这种能力转化到 normal/abnormal 状态判断中，常见路线包括状态词模板、窗口级局部证据、对象无关提示、动态提示、视觉上下文提示和轻量适配器 [2, 3, 4, 5, 6, 7]。这些方法共同改进了异常语义如何被定义和对齐的问题，使模型能够在未见类别上比较正常状态与异常状态。但它们通常仍依赖一组固定或全局共享的 normal/abnormal 语义边界。当目标实例的正常纹理方向、材料批次、局部结构、光照和背景发生偏移时，固定 normal 锚不一定能准确描述当前图像中“仍然正常”的外观范围。

本文认为，CLIP-ZSAD 的一个关键瓶颈是正常性边界的迁移问题。同一类产品甚至同一张图像内，正常区域并不围绕一个静态原型分布，而是沿若干局部变化轨道移动。这些轨道包含可

接受的边缘连续性、材质起伏、纹理走向和成像变化；异常区域则表现为离开这些轨道的局部残差。因此，零样本异常定位需要在 normal/abnormal 语义比较之前估计当前实例中哪些局部变化仍属于正常性边界之内。

实例条件化正常性边界因此具有自然的局部几何形式。当前图像中的正常证据不仅提供一个新的 normal 中心，也提供该中心附近可接受的变化方向和变化尺度。沿这些方向移动的 patch 应被吸收到当前 normal 边界内；偏离这些方向的残差则应被保留为异常响应。这种边界表示在同一个判别过程中同时完成实例正常变化吸收与局部缺陷拒绝。

基于这一观点，我们提出正常变化流形适应（NCMA），用于估计实例条件化正常性边界。NCMA 首先由 frozen CLIP 的 normal/abnormal 语义锚在当前测试图像中选择语义正常且局部一致的候选 patch，并将这些候选 patch 组织为由局部 anchor、切空间和残差尺度构成的正常变化流形。随后，每个目标 patch 被分配到最相容的正常邻域，并被分解为流形内投影与流形外残差。流形内投影描述可被当前 normality boundary 接受的实例变化；流形外残差不进入 normal 边界估计，而是作为异常定位证据进入最终 anomaly map。整个过程不使用目标训练图像、标签、mask、外部正常样本库或目标类别统计，并且在每张测试图像上独立完成。

本文贡献如下：

1. 指出 CLIP-ZSAD 中的正常性边界迁移问题：固定 normal/abnormal 语义边界无法可靠定义每个未见目标实例的正常外观范围。
2. 提出实例条件化正常性边界估计框架 NCMA，通过当前图像中语义正常且局部一致的证据构建临时正常变化流形。
3. 将局部证据分解为流形内正常变化与流形外异常残差，前者用于 normality boundary 估计，后者用于异常定位。
4. 在 MVTec AD 上验证 NCMA 相比 AnomalyCLIP 的平均 P-AUROC、P-AUPRO、I-AUROC 和 I-AP 均有提升，并通过边界估计与残差评分消融分析机制来源。

2 相关工作

2.1 CLIP 零样本异常检测

视觉语言模型为零样本异常检测提供了可迁移的状态语义空间。WinCLIP 使用状态词组合与窗口级特征进行零样本和少样本异常分类与分割 [2]。APRIL-GAN 改善 CLIP patch 与文本状态之间的局部对齐 [3]。AnomalyCLIP、AdaCLIP、VCP-CLIP 和 AA-CLIP 等方法进一步通过提示学习、混合提示、图像条件化提示或轻量适配器增强 normal/abnormal 状态建模 [4, 5, 6, 7]。这些工作主要回答 abnormal concept 如何被对象无关地表达，以及 patch 证据如何与文本状态对齐。NCMA 处理同一框架中的另一个关键问题：即使 normal/abnormal 概念已经可迁移，固定语义边界仍需要在每个目标实例上被重新解释。本文沿着这一问题推进：在已有 abnormal concept 可迁移的基础上，进一步估计当前图像中哪些局部变化仍属于 normality boundary。

2.2 正常性结构建模

工业异常检测长期依赖正常样本的局部表示结构。PaDiM 使用 patch 表示的分布统计刻画正常性 [8], PatchCore 通过正常 patch 记忆库与近邻检索获得强定位性能 [9], UniAD 探索多类别统一建模并分析重建捷径对异常定位的影响 [10]。这些方法说明正常性不仅是一个二分类标签, 也可以由局部邻域、尺度和残差结构描述。NCMA 继承这种几何观点, 但不为目标类别建立正常记忆库, 也不需要目标类别的训练图像。它在单张测试图像内临时估计可被 normal 语义接受的局部变化结构, 并将该结构用于定义实例条件化正常性边界。与记忆库方法相比, NCMA 的边界来自当前实例内部的正常变化证据, 而不是来自预先收集的目标正常样本。

2.3 推理阶段实例条件化

另一类相关方法在推理阶段利用无标签样本更新模型或提示。Tent 通过熵最小化更新归一化参数 [11], MEMO 使用增强视图的边际熵最小化提升鲁棒性 [12], TPT 在视觉语言模型中用单个测试样本更新 prompt [13]。这些方法说明推理阶段的无标签证据能够缓解分布偏移, 但异常定位需要比全图不确定性更细的证据分解。当前图像同时包含正常变化和潜在缺陷, 直接让全部低异常 patch 参与更新会扩大 normal 边界并削弱缺陷响应。NCMA 将推理阶段信号组织为边界估计问题: 流形内分量用于移动当前实例的正常性边界, 流形外分量不进入边界估计, 而是作为异常证据保留。

3 方法

3.1 问题设置

给定冻结的 CLIP 图像编码器 f_ϕ 、文本编码器 g_ψ , 以及 normal/abnormal 文本提示集合, 目标是在未见目标类别上输出图像级异常分数和像素级异常图。对于输入图像 x , 从选定的视觉层提取 patch 表示并记为

$$Z(x) = \{z_i\}_{i=1}^N, \quad z_i \in \mathbb{R}^d, \quad \|z_i\|_2 = 1. \quad (1)$$

文本编码器产生 normal 与 abnormal 文本锚 $t_n, t_a \in \mathbb{R}^d$ 。目标测试阶段只访问当前测试图像和文本提示, 不使用目标训练图像、类别标签、异常标签、mask、外部正常样本库或累计测试流统计。NCMA 为每张输入图像估计一次实例条件化正常性边界, 该边界只服务于当前图像, 推理完成后即被丢弃。

3.2 单图像正常变化流形

NCMA 用单图像正常变化流形表示当前实例的正常性边界。该流形由一组局部正常 anchor、每个 anchor 周围的可接受变化方向, 以及对应的残差尺度组成。局部 anchor 给出当前图像中的正常外观状态, 切空间给出该状态附近仍可被接受的变化方向, 残差尺度给出离开该邻域后的边界外幅度。这一表示使每个 patch 都可以被写成边界内投影和边界外残差。具体地, 我们首先计算每个 patch 的语义异常先验:

$$p_i^a = \text{softmax} \left(\frac{1}{T} \begin{bmatrix} \langle z_i, t_n \rangle \\ \langle z_i, t_a \rangle \end{bmatrix} \right)_2, \quad (2)$$

其中 T 是温度。正常 anchor 来自语义 normal 置信度和局部一致性的共同评分。令 $\mathcal{N}(i)$ 表示 patch i 的空间邻域，定义

$$h_i = \exp \left(-\frac{1}{|\mathcal{N}(i)|\sigma^2} \sum_{j \in \mathcal{N}(i)} \|z_i - z_j\|_2^2 \right), \quad b_i = (1 - p_i^a)^\eta h_i. \quad (3)$$

b_i 高的 patch 既接近 normal 文本锚，又与局部邻域保持一致，因此更适合作为当前图像的正常变化种子。从 b_i 最高的候选集合中选取 K 个局部 anchor，并在候选 patch 的近邻内估计切方向与残差尺度，得到单图像正常变化流形：

$$\mathcal{M} = \{(a_k, U_k, s_k)\}_{k=1}^K. \quad (4)$$

其中 $a_k \in \mathbb{R}^d$ 是第 k 个局部正常 anchor， $U_k \in \mathbb{R}^{d \times m}$ 是局部切空间基， $s_k > 0$ 是该邻域的残差尺度。实现中，anchor 由当前图像的高 b_i 候选 patch 聚类或非极大值筛选得到；每个 anchor 周围的候选近邻 patch 经中心化后做低秩 SVD，前 m 个方向作为该邻域允许的正常变化方向。局部尺度由切空间外残差的稳健分位数与邻域距离共同估计。这些邻域不绑定目标类别名称，而是由当前图像内的高置信正常候选估计，用来刻画可由 normal 语义接受的边缘连续性、纹理方向、材质波动和成像条件变化。

给定测试 patch z_i ，其正常邻域分配由最大余弦相似度确定：

$$k_i = \arg \max_k \langle z_i, a_k \rangle. \quad (5)$$

令 $\Delta_i = z_i - a_{k_i}$ ，则其流形内投影和流形外残差分别为

$$\hat{z}_i = \frac{a_{k_i} + U_{k_i} U_{k_i}^\top \Delta_i}{\|a_{k_i} + U_{k_i} U_{k_i}^\top \Delta_i\|_2}, \quad (6)$$

$$r_i = \frac{\|\Delta_i - U_{k_i} U_{k_i}^\top \Delta_i\|_2}{s_{k_i} + \epsilon}. \quad (7)$$

残差 r_i 衡量当前 patch 中无法由正常变化切空间解释的部分。我们进一步定义流形相容度

$$c_i = \exp(-r_i/\tau), \quad (8)$$

其中 τ 是残差温度。高 c_i 表示该 patch 的偏移可由正常变化解释；高 r_i 表示该 patch 更可能携带缺陷残差。

3.3 实例条件化正常性边界估计

实例条件化正常性边界由 CLIP 状态语义和单图像正常变化结构共同确定。CLIP 的 normal/abnormal 锚提供开放词汇状态判断，流形内投影提供当前实例中可被 normal 边界接受的视觉证据。NCMA 聚合这些边界内证据，得到当前实例的 normality boundary。基于式 (2) 的语义异常先验，用流形相容度和 normal 语义置信度共同定义边界证据权重：

$$q_i = c_i(1 - p_i^a)^\gamma. \quad (9)$$

γ 控制语义 normal 置信度对边界证据的影响。从 q_i 最高的 top- k patch 集合 $\mathcal{S}$ 中聚合当前图像的实例正常锚：

$$v_n = \frac{\sum_{i \in \mathcal{S}} q_i \hat{z}_i}{\|\sum_{i \in \mathcal{S}} q_i \hat{z}_i\|_2}. \quad (10)$$

v_n 由投影后的 $\hat{z}_i$ 构造。投影后的证据已经被压回当前实例的正常变化邻域，因此能够推动边界吸收图像内正常变化，并抑制高残差局部证据对边界的影响。

设 $\bar{q}$ 为 $\mathcal{S}$ 内平均边界证据置信度，normal 语义锚按下式被实例条件化：

$$t'_n = \frac{(1 - \alpha \bar{q})t_n + \alpha \bar{q} v_n}{\|(1 - \alpha \bar{q})t_n + \alpha \bar{q} v_n\|_2}, \quad t'_a = t_a. \quad (11)$$

其中 α 是更新强度。默认设置保持 abnormal 锚不变，因为异常区域的形态在目标类别中不可预知；可选的 abnormal 锚更新只作为附录消融。该估计不需要反向传播，也不更新视觉编码器。它为每张图像生成临时边界锚 (t'_n, t'_a) ，使 normality boundary 贴合当前图像中被正常变化流形接受的局部证据。

3.4 边界外残差定位

实例条件化后的语义异常分数为

$$A_i^{\text{sem}} = \text{softmax} \left(\frac{1}{T} \begin{bmatrix} \langle z_i, t'_n \rangle \\ \langle z_i, t'_a \rangle \end{bmatrix} \right)_2. \quad (12)$$

流形外残差分数由 r_i 经图像内归一化得到：

$$A_i^{\text{res}} = \text{Norm}(r_i). \quad (13)$$

最终 patch 级异常分数融合两类证据：

$$A_i = (1 - \rho) A_i^{\text{sem}} + \rho A_i^{\text{res}}, \quad (14)$$

其中 ρ 是残差权重。语义分数继承 CLIP 的状态判断能力，流形残差提供正常变化无法解释的局部证据。像素级 anomaly map 由 patch 分数双线性上采样得到，图像级异常分数由 top- q patch 分数均值给出：

$$A_{\text{img}} = \frac{1}{q} \sum_{i \in \text{topk}(A, q)} A_i. \quad (15)$$

冻结编码： 测试图像 $x \rightarrow$ CLIP image encoder $\rightarrow$ patch tokens; normal/abnormal prompts $\rightarrow$ CLIP text encoder $\rightarrow$ 文本锚。

单图像推理： 文本引导正常候选 $\rightarrow$ 临时正常变化流形 $\rightarrow$ 流形投影与残差分解。流形内投影聚合为实例正常锚并估计当前图像的 normality boundary；流形外残差与实例条件化语义分数融合为 anomaly map。

图 1: NCMA 方法总览。正常变化流形同时定义当前图像中可进入实例正常性边界的局部证据，以及必须保留为异常响应的边界外残差。

表 1: NCMA 的单图像推理流程。实例条件化边界只对当前输入图像有效。

步骤	操作
输入	测试图像 x , 冻结 CLIP, normal/abnormal 文本提示
单图像图谱	由 CLIP image encoder 得到 patch tokens, 由 text encoder 得到文本锚, 并用高 normal 置信度、局部一致的 patch 临时构建正常变化流形 $\mathcal{M}$
流形分解	对每个 patch 计算邻域分配、流形内投影 $\hat{z}_i$ 、流形外残差 r_i 和相容度 c_i
边界证据	用 $c_i(1 - p_i^a)^\gamma$ 选择高相容 normal patch, 并聚合投影后的 $\hat{z}_i$ 得到实例正常锚 v_n
边界估计	将 t_n 向 v_n 做置信度加权插值, 得到当前图像的临时边界锚 t'_n
异常评分	融合实例条件化语义异常分数与流形外残差分数, 输出 anomaly map 和图像级异常分数

4 实验

4.1 实验设置

我们在 MVTEC AD [14] 上评估 NCMA。实验采用严格目标类别零样本设置：目标测试类别不提供训练图像、类别标签、异常标签或 mask；方法不使用外部正常样本库，也不从测试流累计目标类别统计。每张图像独立构建临时正常变化流形，推理结束后丢弃。所有结果使用相同的 CLIP backbone、输入分辨率和 normal/abnormal 文本模板。

图像级指标包括 I-AUROC 和 I-AP；像素级指标包括 P-AUROC 和 P-AUPRO。P-AUROC 衡量像素排序质量，P-AUPRO 更强调缺陷区域覆盖与正常区域误报的平衡。本文以 Anomaly-CLIP 作为主要 CLIP-ZSAD 参照，并报告 NCMA 在 15 个类别上的完整结果。

4.2 主结果

表 2 给出 MVTEC AD 上的类别级结果。NCMA 将 AnomalyCLIP 的平均 P-AUROC/P-AUPRO/I-AUROC/I-AP 从 91.1/81.4/91.6/96.4 提升到 92.9/84.6/92.4/96.7。提升最集中地出现在定位指标上，尤其是 cable、transistor、metal_nut 和 zipper 等正常外观变化较大或缺陷形态较细碎的类别。这说明固定 normal/abnormal 语义边界在这些类别上更容易误读实例级正常变化，而实例条件化正常性边界可以同时降低正常区域误报并保留边界外缺陷残差。

表 2: MVTEC AD 上的 NCMA 类别级结果。所有指标越高越好。

类别	P-AUROC	P-AUPRO	I-AUROC	I-AP
carpet	99.0	91.9	100.0	100.0
bottle	92.3	84.2	90.4	97.3
hazelnut	97.7	93.5	97.6	98.7
leather	98.8	93.6	99.8	99.9
cable	83.6	70.7	74.5	84.3
capsule	96.4	89.6	89.5	97.8
grid	97.6	80.1	97.9	99.3
pill	93.4	90.3	83.3	95.9
transistor	76.8	64.1	94.2	92.6
metal_nut	80.5	77.3	93.5	98.5
screw	97.8	89.3	82.1	92.9
toothbrush	93.8	89.9	87.5	94.8
zipper	93.0	72.5	98.5	99.5
tile	95.5	89.0	100.0	100.0
wood	96.6	92.4	97.3	99.3
AnomalyCLIP 平均	91.1	81.4	91.6	96.4
NCMA 平均	92.9	84.6	92.4	96.7

4.3 消融分析

表 3 分析实例条件化正常性边界的关键设计。固定边界对应 AnomalyCLIP 的原始 normal/abnormal 语义判断。单原型边界用当前图像低异常 patch 构造一个实例 normal 锚，能够移动边界中心，但不能表达正常变化方向。多原型边界保留多个局部正常状态，进一步覆盖实例内的外观多样性；加入切空间后，模型可以把局部偏移分解为边界内变化和边界外残差。去掉相容权重会弱化残差对边界证据的筛选，去掉边界外残差则会丢失独立的局部定位信号。完整 NCMA 同时保留局部 anchor、切空间投影和边界外残差，因此在四个指标上取得最高平均结果。

表 3: MVTEC AD 核心消融。所有指标越高越好。

变体	P-AUROC	P-AUPRO	I-AUROC	I-AP
固定 normal/abnormal 边界	91.1	81.4	91.6	96.4
单原型实例边界	91.5	80.8	92.0	96.5
多原型实例边界	92.0	82.7	92.1	96.5
NCMA 去掉相容权重	91.8	82.1	92.0	96.5
NCMA 去掉边界外残差	92.3	83.0	92.3	96.6
完整 NCMA	92.9	84.6	92.4	96.7

4.4 参数分析

表 4 展示单图像正常变化流形规模与切空间秩的影响。过少 anchor 会把不同类型的正常变化压到同一邻域中，残差图容易过粗；过多 anchor 会提升检索和尺度估计噪声。零秩切空间退

化为局部原型匹配，不能刻画纹理方向和材质连续变化。在当前设置下， $K = 64$ 、 $m = 8$ 在边界精度与推理开销之间取得较好平衡。

表 4: 单图像正常变化流形的参数敏感性。时间为单张图像额外推理开销。

设置	P-AUROC	P-AUPRO	额外时间
$K = 16, m = 8$	92.0	82.7	11 ms
$K = 32, m = 8$	92.5	83.8	16 ms
$K = 64, m = 8$	92.9	84.6	23 ms
$K = 128, m = 8$	92.8	84.4	39 ms
$K = 64, m = 0$	92.1	82.9	18 ms
$K = 64, m = 4$	92.6	84.0	21 ms
$K = 64, m = 16$	92.8	84.3	29 ms

NCMA 不进行反向传播，不更新视觉编码器，也不保存目标类别正常样本库。额外计算主要来自 anchor 检索、局部投影和残差图上采样，因此可以作为 CLIP-ZSAD 推理过程中的轻量边界估计步骤。

4.5 定性分析

图 2 概括典型定位现象。固定边界在整体颜色或纹理偏移较大的正常区域上产生零散误报，也会在低对比缺陷上给出分散响应。NCMA 将这些局部证据分成两类：可被正常变化流形接受的部分推动 normal 锚贴合当前图像，无法被流形解释的残差形成更集中的热图。这种分解在小目标缺陷和边界缺陷上尤其明显，因为这些区域往往只占少量 patch，直接参与全图更新时容易被高置信正常区域稀释。

场景	固定边界	直接边界更新	NCMA	机制响应
正常成像变化	背景纹理与光照区域出现零散误报	误报减少但边界响应变钝	正常区域响应被压低	高相容权重覆盖正常纹理变化
低对比小缺陷	缺陷响应弱且热图分散	缺陷局部容易被 normal 锚吸收	缺陷区域形成集中响应	边界外残差在缺陷边界增强

图 2: 定性分析示意。NCMA 的机制可视化同时呈现正常流形接受区域与流形外残差保留区域。

5 讨论

NCMA 改变了 CLIP-ZSAD 中 normal 语义边界的使用方式。固定边界把所有未见实例投到同一组 normal/abnormal 锚附近，而 NCMA 先在当前图像中估计正常变化流形，再决定哪些局部证据能够移动实例边界。这种分解使 normal 语义可以贴合当前图像的正常外观，同时避免让局部缺陷参与 normal 边界构造。从结果看，NCMA 的主要收益集中在 P-AUPRO 和困难类别的定位质量上，这与边界外残差定位的作用一致。

当前方法依赖单张图像中存在足够的正常区域来估计正常变化流形。当缺陷覆盖几乎整张图像、正常区域极少，或图像本身包含多个相互矛盾的正常外观模式时，边界估计会受到候选 patch 质量限制。面向视频、批量检测或多视角工业场景时，可以进一步把单图像流形扩展为短时一致的正常性边界，同时仍保持不使用目标缺陷标签的零样本协议。

6 结论

本文将 CLIP 零样本异常检测中的固定语义比较重构为实例条件化正常性边界估计。NCMA 在单张图像内构建文本引导的正常变化流形，并将局部 patch 分解为边界内投影和边界外残差。边界内投影用于估计当前实例的 normality boundary，边界外残差与实例条件化语义分数共同形成 anomaly map。在 MVTec AD 上，NCMA 将 AnomalyCLIP 的平均 P-AUROC/P-AUPRO/I-AUROC/I-AP 从 91.1/81.4/91.6/96.4 提升到 92.9/84.6/92.4/96.7。这些结果表明，正常变化流形为 CLIP-ZSAD 提供了清晰的实例边界机制，能够吸收合法正常变化并保留局部缺陷证据。

参考文献

- [1] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *ICML*, 2021.
- [2] Jongheon Jeong, Yang Zou, Taewan Kim, Dongqing Zhang, Avinash Ravichandran, and Onkar Dabeer. WinCLIP: Zero-/few-shot anomaly classification and segmentation. In *CVPR*, 2023.
- [3] Xuhai Chen, Yue Han, and Jiangning Zhang. APRIL-GAN: A zero-/few-shot anomaly classification and segmentation method for CVPR 2023 VAND workshop challenge. *arXiv preprint arXiv:2305.17382*, 2023.
- [4] Qihang Zhou, Guansong Pang, Yu Tian, Shibo He, and Jiming Chen. Anomaly-CLIP: Object-agnostic prompt learning for zero-shot anomaly detection. *arXiv preprint arXiv:2310.18961*, 2024.
- [5] Xincheng Yao, Ruoqi Li, Zefeng Qian, Lu Wang, and Chongyang Zhang. AdaCLIP: Adapting CLIP with hybrid learnable prompts for zero-shot anomaly detection. *arXiv preprint arXiv:2407.15795*, 2024.
- [6] Xiaozhen Qu, Ming Gao, and colleagues. VCP-CLIP: A visual context prompting model for zero-shot anomaly segmentation. *arXiv preprint arXiv:2407.12276*, 2024.
- [7] Xinyu Ma, and colleagues. AA-CLIP: Enhancing zero-shot anomaly detection via anomaly-aware CLIP. *arXiv preprint arXiv:2503.06661*, 2025.

- [8] Thomas Defard, Aleksandr Setkov, Angelique Loesch, and Romaric Audigier. PaDiM: A patch distribution modeling framework for anomaly detection and localization. In *ICPR*, 2021.
- [9] Karsten Roth, Latha Pemula, Joaquin Zepeda, Bernhard Schölkopf, Thomas Brox, and Peter Gehler. Towards total recall in industrial anomaly detection. In *CVPR*, 2022.
- [10] Zhiyuan You, Kai Yang, Wenhan Luo, Lei Cui, Yujun Zheng, and Xiu Li. A unified model for multi-class anomaly detection. In *NeurIPS*, 2022.
- [11] Dequan Wang, Evan Shelhamer, Shaoteng Liu, Bruno Olshausen, and Trevor Darrell. Tent: Fully test-time adaptation by entropy minimization. In *ICLR*, 2021.
- [12] Marvin Zhang, Sergey Levine, and Chelsea Finn. MEMO: Test time robustness via adaptation and augmentation. In *NeurIPS*, 2022.
- [13] Manli Shu, Weili Nie, De-An Huang, Zhiding Yu, Tom Goldstein, Anima Anandkumar, and Chaowei Xiao. Test-time prompt tuning for zero-shot generalization in vision-language models. *arXiv preprint arXiv:2209.07511*, 2022.
- [14] Paul Bergmann, Michael Fauser, David Sattlegger, and Carsten Steger. MVTec AD: A comprehensive real-world dataset for unsupervised anomaly detection. In *CVPR*, 2019.