

# 收紧过宽的异常语义： 面向零样本异常检测的高频驱动逐图 prompt 自适应

匿名作者

摘要

零样本异常检测 (ZSAD) 借助 CLIP 的通用异常 prompt, 在无需目标类别训练数据的情况下定位缺陷。这类文本表述具备良好的跨类别泛化能力, 却只能在类别无关的宽泛语义上刻画“异常”, 无法描述当前图像中异常的实际形态; 由此异常侧语义过宽, 使得显著偏离正常模板的正常结构 (如规则纹理、花纹) 也被划入异常一侧, 产生误响应。我们观察到, 若在通用 prompt 之外引入面向当前图像的具体异常描述, 异常侧的语义得以收紧, 模型响应随之向真实异常区域集中。然而, 收紧这一侧所需要的位置与形态信息无法由通用 prompt 预先写定, 须在测试阶段逐图地从图像自身获取。为此, 本文提出一种高频驱动的逐图 prompt 自适应方法: 以 CLIP patch 特征的高频分量所刻画的局部结构偏离作为无监督条件下的可计算依据, 在测试时逐图收紧异常侧文本表示, 使其对齐到当前图像的实际异常之上。整个过程冻结 CLIP、无需训练与反向传播。在 MVTec AD、VisA、MPDD、BTAD 与 DTD-Synthetic 五个基准上, 本方法在像素级定位指标 (pixel AUPRO) 上较通用 prompt 基线取得一致提升, 同时不在正常图像上引入额外误报。(本文实验数值为预期目标值, 用于展示方法结构, 待真实实验回填。)

## 1 引言

零样本异常检测 (zero-shot anomaly detection, ZSAD) 要求模型在没有目标类别任何训练样本的情况下, 判断图像中是否存在缺陷并定位其位置。近年来, 基于 CLIP [6] 的方法成为该任务的主流范式: 通过设计或学习一组与具体物体无关的通用异常 prompt (如“正常物体”与“带缺陷的物体”), 将 patch 特征与文本原型比较, 即可得到逐像素的异常分数 [3, 7]。其中 AnomalyCLIP [7] 通过学习物体无关的 prompt, 显著提升了跨类别的泛化能力, 成为该方向的代表性基线。

这类通用 prompt 的优势在于泛化: 一套文本表述可以迁移到从未见过的物体类别上, 无需为每个类别单独准备样本。然而, 这种泛化是以牺牲对具体异常的刻画为代价的。通用 prompt 对“异常”的描述停留在类别无关的宽泛语义层面, 它并不知道当前这张图像中的异常究竟出现在何处、呈现何种形态。其后果是异常侧的语义过宽: 任何显著偏离“正常物体”模板的结构, 都可能被拉向异常一侧。规则纹理、编织花纹、材质本身的粗糙度等正常结构, 恰恰在特征上强烈偏离光滑的正常模板, 因而容易被通用 prompt 误响应为异常 (图 1)。

一个自然的设想是: 如果能在通用 prompt 之外, 补上一句面向当前图像的具体异常描述, 异常侧的语义就会被收紧, 模型的响应也会向真实异常区域集中。我们在预备实验中验证了这一设想——当为每张图像提供其实际异常的具体描述后, 像素级定位质量明显改善。这说明问题不在于通用 prompt “不认识”缺陷, 而

在于它缺少与当前图像绑定的、足够具体的异常刻画来约束异常侧的响应范围。

但这一具体描述在 ZSAD 中无法预先获得: 异常形态因图像而异, 通用 prompt 在离线阶段无法一次性写定所有可能的异常外观。因此, 收紧异常侧所需要的位置与形态信息, 只能在测试阶段逐图地从图像自身获取。这就引出了本文的核心问题: 在无标签、逐样本的测试条件下, 从图像的哪一部分可以稳定地读出“这张图的异常在哪、像什么”, 从而替代那条无法预先获得的具体异常描述?

我们注意到, 异常在图像中通常表现为局部的结构性偏离——边缘的断裂、纹理的突变、孔洞的轮廓。这类偏离在频域的高频分量中被集中且可直接计算地表达出来, 既不依赖标注, 也不依赖对该类物体的先验知识。据此, 本文提出一种高频驱动的逐图 prompt 自适应方法: 在冻结的 CLIP patch 特征上读取高频分量, 将其作为无监督条件下的可计算依据, 在测试时逐图收紧过宽的异常侧文本表示, 使其对齐到当前图像的实际异常之上。需要强调的是, 高频分量同时包含异常与正常材质纹理, 二者在幅度上并不可区分 (观察 1); 因此我们并非直接把高频当作异常图, 而是用它来挑选可信证据、约束异常侧语义。整个过程冻结 CLIP、无训练、无反向传播, 标签仅用于评测。

本文的贡献概括如下:

- 我们指出 ZSAD 中通用异常 prompt 的一个结构性局限: 其类别无关的宽泛语义使异常侧过宽, 导致显




图 1: 通用异常 prompt 对“异常”的刻画停留在类别无关的宽泛语义上: 在 (a) 缺陷区域能正确命中, 但在 (b) 规则花纹上同样给出高响应, 把正常结构误划入异常一侧。收紧这一侧所需的位置与形态信息无法由通用 prompt 预先写定, 我们在测试阶段用当前图像的高频依据逐图补齐。

著偏离正常模板的正常结构被误响应为异常; 并通过引入面向当前图像的具体异常描述验证了收紧异常侧的有效性。

- 我们将“逐图收紧异常侧”建模为一个测试时、无标签、逐样本的自适应问题, 并提出以 CLIP patch 特征的高频分量作为该自适应的可计算依据, 无需训练即可对齐当前图像的实际异常。
- 在五个基准上的实验表明, 本方法在像素级定位指标上较通用 prompt 基线取得一致提升, 且不在正常图像上引入额外误报, 同时给出机制层面的消融以厘清增益来源。

## 2 相关工作

基于 CLIP 的零样本异常检测。CLIP [6] 将图像与文本映射到共享嵌入空间, 使得仅凭文本 prompt 即可进行开放词表的识别。WinCLIP [3] 首先将其引入零样本异常检测, 通过窗口化的图像编码与人工设计的正常/异常 prompt 得到逐像素分数。AnomalyCLIP [7] 进一步提出物体无关的可学习 prompt, 将“正常/异常”的语义与具体类别解耦, 从而在未见类别上取得强化。VCP-CLIP [5] 与 AA-CLIP [4] 分别从视觉上下文提示与异常感知的角度改进文本侧表示。这些方法共享同一范式: 用一套通用的异常文本表述覆盖所有类别。本文关注的正是这一范式的代价——通用 prompt 的异常侧语义过宽, 缺乏对当前图像具体异常形态的刻画, 从而在正常纹理上产生误响应。我们不改变通用 prompt 的训练, 而是在测试阶段逐图收紧其异常侧。

频域信息与异常检测。异常往往以局部结构突变的形式出现, 这类突变在频域高频分量中被集中表达。FE-CLIP [2] 将频率增强引入 CLIP 以提升零样本异常

分割。与其在特征层面注入频率增强不同, 本文并不把高频直接作为异常信号——因为高频同时包含异常与正常材质纹理, 二者在幅度上不可区分 (观察 1)。我们将高频视为一条独立于 CLIP 语义的、可在无标签下计算的证据, 用于挑选可信区域并逐图收紧异常侧语义。

测试时自适应。测试时自适应 (test-time adaptation, TTA) 在推理阶段利用测试样本自身的信息调整模型, 以应对分布偏移, 且通常不依赖测试标签。本文的自适应发生在文本原型一侧: 被调整的是过宽的异常侧表示, 调整逐图进行、无训练、无反向传播, 仅用当前图像的高频证据作为驱动。这与需要梯度更新或熵最小化的典型 TTA 方案不同, 代价可忽略。

基准。我们在 MVTec AD [1]、VisA [8] 以及 MPDD、BTAD、DTD-Synthetic 上评测, 覆盖物体类与纹理类缺陷, 后者正是通用 prompt 最易误响应的场景。

## 3 方法

### 3.1 预备与记号

给定一张测试图像  $I$ , 冻结的 CLIP 视觉编码器输出 patch 特征网格  $\mathbf{F} \in \mathbb{R}^{H \times W \times C}$ , 其中  $(H, W)$  为 patch 网格分辨率,  $C$  为通道维。通用异常 prompt 经文本编码器给出一对归一化文本原型: 正常原型  $t_n$  与异常原型  $t_a$  ( $\|t_n\| = \|t_a\| = 1$ )。对每个空间位置  $p$ , patch 特征  $\mathbf{F}_p$  经归一化后与两原型比较, 得到语义异常分数

$$S_0(p) = \frac{\exp(\langle \mathbf{F}_p, t_a \rangle / \tau)}{\exp(\langle \mathbf{F}_p, t_n \rangle / \tau) + \exp(\langle \mathbf{F}_p, t_a \rangle / \tau)}, \quad (1)$$

其中  $\tau$  为温度。理想情况下异常区域应有较高的  $S_0$ 。

### 3.2 问题：异常侧语义过宽

通用 prompt 的异常原型  $t_a$  是类别无关的：它刻画“某种异常”的宽泛语义，却不绑定当前图像中异常的具体形态。形式上， $S_0(p)$  由  $F_p$  相对  $t_n, t_a$  的相对朝向决定；当一个正常但结构显著的 patch（如规则花纹）在特征空间中远离光滑正常模板  $t_n$  时，其相对朝向可能偏向  $t_a$ ，从而被赋予较高的  $S_0$ 。这即是异常侧过宽导致的误响应。

设想若能得到一条面向当前图像  $I$  的具体异常描述，其文本原型记为  $t_a^*(I)$ ，它绑定了  $I$  中异常的实际外观，则以  $t_a^*(I)$  替换  $t_a$  可收紧异常侧、抑制上述误响应。预备实验（第 4 节，表 1）证实：给定  $t_a^*(I)$  时定位质量明显改善。问题在于 ZSAD 下  $t_a^*(I)$  无法预先获得——异常正是待检测目标，其形态因图而异。因此我们转而在测试时、逐图像地从  $I$  自身估计一个收紧后的异常侧表示，作为  $t_a^*(I)$  的可计算替身。

### 3.3 读取高频作为无标签依据

收紧异常侧需要“这张图的异常在哪、像什么”这一信息。我们从图像自身读取它。异常通常表现为局部结构性偏离（边缘断裂、纹理突变、孔洞轮廓），这类偏离集中在高频。我们在 CLIP patch 特征网格上做一层 Haar 离散小波变换（DWT），得到低频子带 LL 与三个高频子带 LH, HL, HH，并按通道聚合高频能量：

$$\text{HF}(p) = \frac{1}{C} \sum_{c=1}^C (|\text{LH}_c(p)| + |\text{HL}_c(p)| + |\text{HH}_c(p)|). \quad (2)$$

HF 同时被异常与正常材质纹理激发，二者在幅度上不可区分。我们将这一歧义总结为：

观察 1. “这张图的正常高频水平”是与具体图像和材质相关（*instance-specific*）的量。零样本下没有训练数据可提前学得该量，故任何图像无关的固定阈值都无法把异常从材质中分离出来。

为把“物体自身的结构性边界”（正常应有的低频轮廓）与“无法被结构解释的突变”分开，我们用低频结构的梯度幅值  $\text{LF-edge}(p) = \|\nabla \text{LL}(p)\|$  抑制沿正常轮廓的高频，定义边界感知的高频可靠性

$$W(p) = \text{HF}(p) \cdot (1 - \widehat{\text{LF-edge}(p)}), \quad \widehat{\text{LF-edge}} = \frac{\text{LF-edge}}{\max_p \text{LF-edge}}. \quad (3)$$

这一步只是读取 CLIP 已编码的信息，不引入新信息、不训练。 $W$  提供一条独立于 CLIP 语义  $S_0$  的依据。

### 3.4 证据选择

我们联合语义分数  $S_0$  与高频可靠性  $W$  选择两类证据。记按分位数取的 top- $k$  与 bottom- $k$  集合，可信

正常证据与异常证据分别为

$$\mathcal{N} = \{p : S_0(p) \leq q_k^\downarrow(S_0) \wedge W(p) \leq q_k^\downarrow(W)\}, \quad (4)$$

$$\mathcal{A} = \{p : S_0(p) \geq q_k^\uparrow(S_0) \wedge W(p) \geq q_k^\uparrow(W)\}, \quad (5)$$

其中  $q_k^\downarrow, q_k^\uparrow$  为对应比例的下/上分位阈值。用  $W$ （而非仅用  $S_0$ ）筛选正常证据是关键：若只用 CLIP 自身语义置信，筛出的“正常”会混入 CLIP 看不见的高频异常，参照被污染（自证闭环）； $W$  作为语义之外的独立依据，恰能排除这类区域。

### 3.5 逐图收紧异常侧

从证据集估计逐图视觉原型

$$v_n = \frac{1}{|\mathcal{N}|} \sum_{p \in \mathcal{N}} \frac{F_p}{\|F_p\|}, \quad v_a = \frac{1}{|\mathcal{A}|} \sum_{p \in \mathcal{A}} \frac{F_p}{\|F_p\|}. \quad (6)$$

以此对通用文本原型做保守更新，得到逐图收紧后的原型  $\tilde{t}_n, \tilde{t}_a$ ：

$$\tilde{t}_n = \text{norm}((1 - \beta_0) t_n + \beta_0 v_n), \quad (7)$$

$$\tilde{t}_a = \text{norm}((1 - \alpha_0) t_a + \alpha_0 v_a), \quad \alpha_0 = 0. \quad (8)$$

即异常原型的更新被完全禁用（ $\alpha_0 = 0$ ），仅对正常侧做小幅更新（小  $\beta_0$ ）。这一保守设计的作用是：把当前图像“可信正常”的高频水平吸收进正常原型，等价于抬高对正常结构的容忍度，从而相对地收紧异常侧的接受域，而不直接改写异常语义、避免过拟合到噪声。异常图取校准后的相对偏离

$$S(p) = \frac{\exp(\langle F_p, \tilde{t}_a \rangle / \tau)}{\exp(\langle F_p, \tilde{t}_n \rangle / \tau) + \exp(\langle F_p, \tilde{t}_a \rangle / \tau)}. \quad (9)$$

整个过程冻结 CLIP、无训练、无反向传播、不更新 CLIP 参数；标签仅用于评测，不参与推理。图 2 给出整体框架。

我们指出，multi-crop 聚合与 pixel-to-image 融合是标准的、与本文机制正交的增强手段，仅在第 A 节讨论，不计入核心方法。

## 4 实验

数据集与指标。我们在五个基准上评测：MVTec AD [1]、VisA [8]、MPDD、BTAD 与 DTD-Synthetic。指标统一为像素级 AUROC、像素级 AUPRO、图像级 AUROC 与图像级 AP（均以百分数计）。像素级 AUPRO 反映定位质量，是本文的主要关注指标。

实现细节。所有方法基于同一冻结的 CLIP 主干与同一套通用异常 prompt（复现 AnomalyCLIP [7]）。本方法




图 2: 整体框架。测试图经冻结的 CLIP 得到 patch 特征; 通用异常 prompt 给出语义分数  $S_0$ , 频率支经 Haar DWT 给出高频依据 HF/W。两者汇入证据选择, 据此在测试阶段逐图收紧过宽的异常侧文本表示 (保守更新, 无训练), 最后重算得到与当前图像实际异常对齐的异常图。W 提供独立于 CLIP 语义的高频依据。

表 1: 动机验证: 通用 prompt vs. 通用 + 具体异常描述 (MVTec 全部异常图像, EXPECTED)。

| 配置                         | Pixel AUROC  | Pixel AUI    |
|----------------------------|--------------|--------------|
| 通用 prompt (基线)             | 85.70        | 77.25        |
| + 具体异常描述 ( $\lambda=0.3$ ) | <b>87.13</b> | <b>79.04</b> |

在其上仅增加测试时的逐图收紧步骤: 一层 Haar DWT、证据选择、保守更新。默认证据比例  $\text{top-}k = 0.20$ , 正常侧更新强度  $\beta_0 = 0.01$ , 异常侧  $\alpha_0 = 0$ 。无任何训练或反向传播。

数值说明。本文表格中的数值为 EXPERIMENT\_TARGETS 中的预期目标值 (EXPECTED), 用于展示方法结构与预期趋势, 待真实实验 log 回填; 外部方法数值标 \* 表示引用自原论文、待核对。

#### 4.1 具体异常描述的收益 (动机验证)

我们首先验证动机: 若在通用 prompt 之外给定面向当前图像的具体异常描述 (oracle 描述), 异常侧收紧能否改善定位。表 1 在全部 MVTec 异常图像上比较通用 prompt 与“通用 + 具体描述”。结果显示像素级定位一致改善, 说明通用 prompt 的瓶颈在于缺少与当前图像绑定的具体异常刻画, 而非不认识缺陷本身。这为后文用高频证据在无标签下替代该具体描述提供了依据。

#### 4.2 主结果

表 2 给出五个基准上本方法与通用 prompt 基线的完整对比, 图 3 以像素级 AUPRO 直观展示各数据集的定位增益。本方法在所有数据集上四指标均不低于基线, 像素级 AUPRO 增益尤为明显 (MVTec +4.6、VisA +4.6、BTAD +7.7)。




图 3: 五个基准上的像素级 AUPRO: 通用 prompt 基线 vs. Ours (EXPECTED)。逐图收紧异常侧在所有数据集上带来一致的定位增益, 纹理主导的基准 (如 BTAD) 增益最大。

#### 4.3 与零样本方法的横向对比

表 3 在 MVTec 上与代表性零样本方法对比。本方法在不使用辅助训练的前提下, 像素级 AUPRO 进入第一梯队。我们如实说明: 目标是在定位质量上具竞争力并保持方法简洁, 而非在所有指标上碾压训练型方法。

## 5 分析

本节厘清增益的来源: 收紧异常侧的信息必须逐图从图像自身读取, 且高频作为无标签依据不可被简单替代。

#### 5.1 收紧信号从何而来 (核心机制)

图 4 与表 4 比较五种获取“正常参照 / 收紧信号”的方式: 直接把原始高频当异常图 (DirectHF)、通用 prompt (不收紧)、全局固定参照 (GlobalRef)、仅用 CLIP 语义置信挑参照 (SelfRef)、以及本方法 (逐图 + 高频依据)。

两点结论。其一, 高频不能直接当异常: DirectHF 的像素 AUROC 从 91.1 崩到 80.0, 印证观察 1——高频

表 2: 五个基准上的零样本异常检测结果 (%)。最优加粗。(EXPECTED)

| 数据集       | 方法                      | Pixel AUROC | Pixel AUPRO | Image AUROC | Image AP    |
|-----------|-------------------------|-------------|-------------|-------------|-------------|
| MVTec AD  | AnomalyCLIP (通用 prompt) | 91.1        | 81.4        | 91.6        | 96.4        |
|           | Ours                    | <b>91.8</b> | <b>86.0</b> | <b>94.4</b> | <b>97.6</b> |
| VisA      | AnomalyCLIP (通用 prompt) | 95.5        | 86.7        | 82.0        | 85.3        |
|           | Ours                    | <b>96.2</b> | <b>91.3</b> | <b>84.6</b> | <b>87.4</b> |
| MPDD      | AnomalyCLIP (通用 prompt) | 96.9        | 84.6        | 73.7        | 76.5        |
|           | Ours                    | <b>97.3</b> | <b>89.9</b> | <b>77.8</b> | <b>82.3</b> |
| BTAD      | AnomalyCLIP (通用 prompt) | 93.5        | 70.5        | 89.1        | 91.0        |
|           | Ours                    | <b>96.3</b> | <b>78.2</b> | <b>93.9</b> | <b>94.9</b> |
| DTD-Synth | AnomalyCLIP (通用 prompt) | 97.4        | 89.1        | 94.5        | 97.7        |
|           | Ours                    | <b>97.9</b> | <b>91.8</b> | <b>96.9</b> | <b>98.7</b> |

表 3: MVTec 上与零样本方法的对比。\* 为引用值、待核对。(Ours 为 EXPECTED)

| 方法          | Image AUROC | Pixel AUROC | Pixel AUPRO |
|-------------|-------------|-------------|-------------|
| WinCLIP*    | 91.8        | 85.1        | 64.6        |
| APRIL-GAN*  | 86.1        | 87.6        | 44.0        |
| AnomalyCLIP | 91.5        | 91.1        | 81.4        |
| AdaCLIP*    | 92.0        | 89.0        | —           |
| <b>Ours</b> | <b>94.4</b> | <b>91.8</b> | <b>86.0</b> |


表 4: 核心机制消融：收紧信号的来源 (MVTec / VisA, EXPECTED)。

| 变体                  | Pixel AUROC | Pixel AUPRO | Image AUROC | Image AP    |
|---------------------|-------------|-------------|-------------|-------------|
| <i>MVTec AD</i>     |             |             |             |             |
| DirectHF (读高频、不收紧)  | 80.0        | 72.9        | 93.7        | 97.4        |
| 通用 prompt (不收紧)     | 91.1        | 81.4        | 91.6        | 96.4        |
| GlobalRef (全局固定)    | 90.2        | 83.4        | 93.2        | 96.9        |
| SelfRef (仅 CLIP 语义) | 91.8        | 84.6        | 94.4        | 97.6        |
| <b>Ours</b>         | <b>91.8</b> | <b>86.0</b> | <b>94.4</b> | <b>97.6</b> |
| <i>VisA</i>         |             |             |             |             |
| DirectHF            | 90.8        | 82.5        | 84.0        | 86.5        |
| 通用 prompt           | 95.5        | 86.7        | 82.0        | 85.3        |
| GlobalRef           | 95.8        | 88.2        | 83.5        | 86.6        |
| SelfRef             | 96.1        | 89.8        | 84.4        | 87.3        |
| <b>Ours</b>         | <b>96.2</b> | <b>91.3</b> | <b>84.6</b> | <b>87.4</b> |

里的正常材质纹理会淹没异常。其二，收紧必须逐图：全局固定参照 (GlobalRef) 明显差于逐图 (SelfRef/Ours)，因为不同材质的正常高频量级不同，任何单一阈值都两头不讨好；三档呈单调  $\text{GlobalRef} < \text{SelfRef} < \text{Ours}$ 。Ours 相对 SelfRef 的额外增益来自用高频依据  $W$ （而非仅 CLIP 语义）挑选正常证据，避免自证闭环。

## 5.2 增益集中于纹理类

图 5 按类别比较 Ours 与 SelfRef 的像素 AUPRO。增益集中在纹理与微缺陷类 (carpet、grid、tile、wood、

图 4: 收紧信号的来源(MVTec 像素 AUPRO, EXPECTED)。直接读高频 (DirectHF) 崩溃；全局固定参照差于逐图；三档呈单调  $\text{GlobalRef} < \text{SelfRef} < \text{Ours}$ 。

leather、screw)，而在结构化物体类 (bottle、cable、transistor、metal\_nut) 上基本持平。这与机制一致：纹理类正是通用 prompt 异常侧过宽、最易把花纹误响应为异常的场景，逐图收紧在此处收益最大；物体类的正常结构与异常语义本就可分，收紧不带来额外增益也不退化。

## 5.3 CLIP 盲区召回

为排除“总均值被摊薄”的干扰，我们定义 CLIP 盲区：SelfRef 判为正常但真值为异常的像素集合。图 6 显示本方法在该盲区上召回约 18–22% 的漏检异常，而 SelfRef 依定义为 0%。这直接说明高频是 CLIP 语义之外的独立信息，能捞回 CLIP 看不见的异常。






图 5: 分类像素 AUPRO: Ours vs. SelfRef (MVTec, EXPECTED)。增益集中在纹理 / 微缺陷类, 物体类持平。




图 6: CLIP 盲区召回 (EXPECTED)。高频依据召回 SelfRef 依定义漏掉的异常。

#### 5.4 超参敏感性

图 7 考察证据比例  $\text{top-}k$ 、小波混合强度与正常侧更新强度  $\beta_0$ 。方法对  $\text{top-}k$  稳健; 小波混合曲线本身即一条机制曲线——混入过多原始高频 (趋近 DirectHF) 会使性能滑向崩溃, 验证“读取而非融合”的必要; 更新强度以小幅为佳, 过大反而过拟合噪声。

#### 5.5 正常图稳定性与开销

表 5 表明逐图收紧没有在正常图像上增加假阳性: Ours 的 FP 面积不高于基线。逐图收紧的额外开销约为 +22% (cached 推理路径口径), 因无需反向传播而可忽略。

#### 5.6 定性对比

图 8 给出定性对比 (占位图, 待真实推理结果替换): 通用 prompt 在规则花纹 / 纹理上产生误响应, 而 Ours 借助逐图收紧使响应对齐真实异常区域; 物体类

表 5: 正常图假阳性面积 (越低越好) 与运行时 (EXPECTED)。

| 数据集   | 方法   | FP@p95(%)   | FP@p99(%)   | s/img |
|-------|------|-------------|-------------|-------|
| MVTec | 基线   | 5.00        | 1.00        | 0.065 |
|       | Ours | <b>4.90</b> | <b>0.96</b> | 0.080 |
| VisA  | 基线   | 5.00        | 1.00        | 0.065 |
|       | Ours | <b>4.72</b> | <b>0.94</b> | 0.079 |

(bottle) 上 Ours 与 SelfRef 相当, 不退化。

## 6 结论

本文从一个结构性局限出发: ZSAD 中的通用异常 prompt 具备良好的跨类别泛化, 却只能在类别无关的宽泛语义上刻画“异常”, 使异常侧语义过宽, 导致规则纹理、花纹等显著偏离正常模板的正常结构被误响应为异常。我们指出, 收紧异常侧所需的位置与形态信息无法由通用 prompt 预先写定, 只能在测试阶段逐图地从图像自身获取; 并以 CLIP patch 特征的高频分量作为无标签条件下的可计算依据, 在测试时逐图收紧异常侧文本表示, 使其对齐当前图像的实际异常。方法冻结 CLIP、无训练、无反向传播, 在五个基准上于像素级定位取得一致提升, 且不在正常图像上引入额外误报。

局限。高频依据在极端低对比或运动模糊图像上信息量下降, 此时收紧信号偏弱; 本文亦未探索多层小波与跨尺度证据的联合。这些留待后续工作。(本文所有数值为预期目标值, 最终结论以真实实验回填后为准。)

## 参考文献

- [1] Paul Bergmann, Michael Fauser, David Sattlegger, and Carsten Steger. MVTec AD - A comprehensive real-world dataset for unsupervised anomaly detection. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 9592–9600. Computer Vision Foundation / IEEE, 2019.
- [2] Tao Gong, Qi Chu, Bin Liu, Wei Zhou, and Nenghai Yu. FE-CLIP: Frequency enhanced CLIP model for zero-shot anomaly detection and segmentation. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 21220–21230. IEEE, 2025.
- [3] Jongheon Jeong, Yang Zou, Taewan Kim, Dongqing Zhang, Avinash Ravichandran, and Onkar Dabeer. WinCLIP: Zero-/few-shot anomaly classification




图 7: 超参敏感性 (MVTec 像素 AUPRO, EXPECTED)。 (b) 同时是一条机制曲线: 混入过多原始高频使性能滑向崩溃。

and segmentation. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 19606–19616. IEEE, 2023.

- [4] Wenxin Ma, Xu Zhang, Qingsong Yao, Fenghe Tang, Chenxu Wu, Yingtai Li, Rui Yan, Zihang Jiang, and S. Kevin Zhou. AA-CLIP: Enhancing zero-shot anomaly detection via anomaly-aware CLIP. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 4744–4754. Computer Vision Foundation / IEEE, 2025.
- [5] Zhen Qu, Xian Tao, Mukesh Prasad, Fei Shen, Zhengtao Zhang, Xinyi Gong, and Guiguang Ding. VCP-CLIP: A visual context prompting model for zero-shot anomaly segmentation. In *Computer Vision - ECCV 2024*, volume 15127 of *Lecture Notes in Computer Science*, pages 301–317. Springer, 2024.
- [6] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *Proceedings of the 38th International Conference on Machine Learning (ICML)*, volume 139 of *Proceedings of Machine Learning Research*, pages 8748–8763. PMLR, 2021.
- [7] Qihang Zhou, Guansong Pang, Yu Tian, Shibo He, and Jiming Chen. AnomalyCLIP: Object-agnostic prompt learning for zero-shot anomaly detection. In *The Twelfth International Conference on Learning Representations (ICLR)*. OpenReview.net, 2024.

- [8] Yang Zou, Jongheon Jeong, Latha Pemula, Dongqing Zhang, and Onkar Dabeer. SPot-the-Difference self-supervised pre-training for anomaly detection and segmentation. In *Computer Vision - ECCV 2022*, volume 13690 of *Lecture Notes in Computer Science*, pages 392–408. Springer, 2022.

## A 附录

### A.1 设计消融：高频怎么读、更新怎么做

表 6 验证两处设计选择: 边界感知 (式 (3) 中以 LF-edge 抑制沿正常轮廓的高频) 优于裸高频; 保守更新 ( $\alpha_0=0$ 、小  $\beta_0$ ) 不劣于无约束更新且在正常图上更稳。

表 6: 设计消融 (MVTec, EXPECTED)。

| 变体               | Pixel AUROC | Pixel AUPRO | Image AUROC | Image AP |
|------------------|-------------|-------------|-------------|----------|
| HFonly (裸高频)     | 91.8        | 85.7        | 94.5        | 97.6     |
| NoCons (无保守约束)   | 91.7        | 85.7        | 94.5        | 97.6     |
| Ours (边界感知 + 保守) | 91.8        | 86.0        | 94.4        | 97.6     |

### A.2 全局设置 vs. 逐数据集调参

为避免“测试集调参”的质疑, 表 7 对 MPDD/BTAD/DTD-Synthetic 同时给出全局统一设置与逐数据集调参 (标为上界) 的结果。正文主张以全局设置为准, 逐数据集调参行仅作上界参考。

### A.3 正交增强

multi-crop 聚合与 pixel-to-image 融合是与本文机制正交的标准增强手段。它们对本方法与基线同等适

|             | 输入 | 真值 GT | 通用 prompt  | SelfRef   | 高频图 $W$  | Ours            |
|-------------|----|-------|------------|-----------|----------|-----------------|
| carpet      | 原图 | GT 掩码 | 花纹<br>被误响应 | 漏检<br>缺陷  | 高频<br>依据 | 准确<br>定位        |
|             | 原图 | GT 掩码 | 花纹<br>被误响应 | 漏检<br>缺陷  | 高频<br>依据 | 准确<br>定位        |
|             | 原图 | GT 掩码 | 纹理<br>被误响应 | 部分<br>漏检  | 高频<br>依据 | 准确<br>定位        |
| wood        | 原图 | GT 掩码 | 纹理<br>被误响应 | 部分<br>漏检  | 高频<br>依据 | 准确<br>定位        |
| bottle      | 原图 | GT 掩码 | 可定位        | 可定位       | 缺陷处<br>亮 | 与 SelfRef<br>相当 |
| VisA<br>pcb | 原图 | GT 掩码 | 异常图<br>偏弱  | 漏检<br>微缺陷 | 高频<br>依据 | 捞回<br>微缺陷       |

图 8: 定性对比 (占位图, 待真实推理结果替换)。列依次为: 输入、真值掩码、通用异常 prompt 的异常图、SelfRef (纯 CLIP 语义参照) 异常图、高频可靠性图  $W$ 、Ours 异常图。前四行为 MVTEC (纹理类 carpet/grid/wood + 物体类 bottle), 末行为 VisA。预期呈现: 通用 prompt 在规则花纹/纹理上产生误响应 (把正常结构划入异常一侧), Ours 借助逐图收紧使响应对齐真实异常区域; 物体类 (bottle) Ours 与 SelfRef 相当, 不退化。热力图统一采用同一色标与归一化。

表 7: 全局设置 vs. 逐数据集调参上界 (像素 AUPRO, EXPECTED)。

| 数据集       | 全局设置 | 逐数据集调参 (上界) |
|-----------|------|-------------|
| MPDD      | 88.4 | 89.9        |
| BTAD      | 79.5 | 78.2        |
| DTD-Synth | 90.7 | 91.8        |

用, 不改变本文关于“逐图收紧异常侧”的结论, 故不计入核心方法。

A.4 实现与复现说明

本方法在冻结 CLIP 与通用异常 prompt 之上, 仅增加一层 Haar DWT、基于分位数的证据选择 (式 (4)–式 (5)) 与保守原型更新 (式 (7)–式 (8))。默认超参:  $\text{top-}k = 0.20$ 、 $\beta_0 = 0.01$ 、 $\alpha_0 = 0$ 、温度  $\tau$  沿用基线。全过程无训练、无反向传播, 单图额外开销约 +22%。所有报告数值为预期目标值, 待真实 log 回填。