

面向 CLIP 零样本异常定位的图像条件化正常参照估计

匿名稿件

2026 年 8 月 3 日

摘要

基于 CLIP 的零样本异常定位通常将视觉 patch 与正常/异常文本原型进行匹配。已有文本原型可以通过学习得到，并能够形成跨类别迁移的语义判别轴；但局部异常证据还取决于当前测试图像的正常外观。对于光滑物体而言，局部纹理变化可能对应缺陷；对于粗糙材质或重复结构而言，相似响应可能属于正常外观。本文将这一缺失的图像条件化基准概括为 CLIP-ZSAD 中的 reference gap。一个文本侧诊断现象也指向同一问题：当 prompt 中显式加入当前图像的材质、表面纹理或结构描述时，部分定位图会发生改变，说明外观上下文会影响局部响应的解释。基于这一观察，本文提出 ICNR，一种训练无关的图像条件化正常参照估计方法。该方法从冻结 CLIP 特征中选择可靠 patch 证据，用频域响应刻画局部结构变化，并基于估计得到的正常参照重新计算异常响应。主结果覆盖五个工业基准；MVTec AD 和 VisA 上的受控实验显示了预期机制：直接融合 wavelet map 的表现较弱，全局参照低于图像条件化参照，而边界感知可靠性与保守正常参照估计在报告指标上取得最佳受控结果。

关键词：零样本异常定位，CLIP，图像条件化正常参照，频域响应，patch 证据选择

1 引言

CLIP 为零样本异常定位提供了直接的语义接口：视觉 patch 可以与正常和异常状态的语言原型进行匹配。WinCLIP 使用组合式正常/异常 prompt 和局部窗口评分实现零样本或少样本异常分割 [8]。AnomalyCLIP 从辅助异常数据中学习 object-agnostic 的正常和异常 prompt [20]；后续方法进一步通过 hybrid learnable prompts [3]、visual context prompting [14] 和 anomaly-aware adapters [11] 改进这一类模型。这些工作表明，CLIP 能够为异常定位提供有效的正常/异常语义原型。

局部异常证据并不只由语义相似度决定。工业缺陷通常表现为划痕、污染、压痕、裂纹或缺失部件，其中许多缺陷会引起纹理、边界连续性或细粒度结构的局部变化。相似的局部变化也可能来自正常材质、重复纹理、物体轮廓和成像噪声。因此，一个 patch 响应是否指向异常，取决于它相对于当前图像正常外观的偏离程度。同样的高响应区域，在光滑金属表面上可能是划痕，在编织物或粗糙表面上则可能是正常结构。

这一点揭示了 CLIP-ZSAD 中一个具体的 reference gap。可学习的正常/异常文本原型定义了跨类别共享的语义轴，但它们没有给出当前测试图像的正常外观参照。对于一张具体图像，表面颗粒度、纹理密度、结构边界和重复图案共同决定了哪些局部变化属于正常范围。缺少这一图像条件化参照时，正常纹理、结构边界和真实缺陷容易在局部响应空间中相互混杂。

文本侧的一个诊断现象进一步指向这一缺口。当训练得到的通用 abnormal prompt feature 之外再加入当前缺陷外观的 oracle detailed prompt 时, 部分样例中标注异常区域的响应被进一步激活, 异常区域与背景区域的响应间隔也随之增大。该现象说明, 通用文本原型之外, 当前测试图仍携带能够调节 patch response 的外观信息。本文将这一信息转到图像侧处理, 从测试图自身选择可靠 patch 证据, 估计图像条件化正常外观基准。

本文提出面向 CLIP-ZSAD 的图像条件化正常参照估计。给定单张测试图像, ICNR 保持 CLIP 和 AnomalyCLIP 编码器冻结, 在 CLIP patch 特征场中选择可靠证据。所选正常证据被聚合为图像条件化正常参照, 随后每个 patch 的异常响应相对于该参照和共享的正常/异常语义轴重新计算。整个过程不使用目标类别正常样本库、标签或测试时参数更新。

方法的关键在于 patch 证据选择。如果证据选择只由语义响应驱动, 正常纹理、结构边界和缺陷区域仍可能混在一起。ICNR 因此在 CLIP patch 特征网格上测量局部结构变化。频域响应用于刻画这种变化, 并约束哪些 patch 可以支撑正常参照。语义异常响应较低且局部结构稳定的 patch 构成正常参照证据; 语义可疑且结构变化显著的 patch 从正常参照中排除, 并在参照估计后重新评估。

本文贡献如下:

- 指出 CLIP-ZSAD 中的 reference gap: 可学习的正常/异常文本原型提供跨类别语义轴, 但缺少当前测试图像的正常外观参照。
- 提出 ICNR, 一种训练无关的图像条件化正常参照估计方法, 从单张测试图像中选择可靠 patch 证据, 并在冻结 CLIP 语义空间中重新计算局部异常响应。
- 将频域响应用于局部结构变化刻画和证据选择, 并通过受控机制实验验证其角色: Direct 作为负控, Global 检验固定参照, Sem 作为图像条件化基线, ICNR 在 MVTec AD 和 VisA 上取得最佳受控结果。

2 相关工作

基于 CLIP 的零样本异常定位。CLIP 通过共享嵌入空间连接视觉区域和文本描述 [15]。WinCLIP 将这一接口用于异常检测, 结合 prompt ensemble 和局部窗口评分进行异常定位 [8]。PromptAD 研究了用于零样本异常检测的文本 prompt [10]。AnomalyCLIP 从辅助异常数据中学习 object-agnostic 正常/异常 prompt [20]。AdaCLIP、VCP-CLIP 和 AA-CLIP 分别通过 hybrid learnable prompts、visual context prompting 和 anomaly-aware adapters 进一步增强语义接口 [3, 14, 11]。这些方法主要增强正常/异常语义轴; 本文关注在已有语义轴下, 如何依据当前测试图像的正常外观解释局部证据。

频域与局部结构线索。频域信息已经是异常检测中的相关信号。FE-CLIP 为 CLIP 引入 frequency-enhanced adapters [7]。WMOE-CLIP 将 CLIP 特征分解为 Haar 低频和高频分量, 并用于 prompt learning [4]。HarmoniAD 通过频域分支建模局部结构和全局语义 [17]。Wavelet 分析本身也是经典的多分辨率信号表示方法 [6, 12]。本文中的频域响应承担不同角色: 它刻画 patch 特征中的局部结构变化, 并参与当前图像正常参照的证据选择。

测试时参照与自适应。视觉语言模型可以受益于测试时或图像条件化自适应, 例如 test-time prompt tuning 和 conditional prompt learning [16, 18]。在异常检测中, 当外部正常样本可用时, 正常参照图像能够提供有价值的信息, 例如 WinCLIP 的少样本设置。本文研究的零样本设置不提供目标类别正常图像, 因此参照需要从测试图自身估计。ICNR 不更新 prompt、adapter 或 encoder 参数, 而是通过当前图像内部的 patch 证据构建正常外观参照。

3 方法

3.1 语义参照与图像条件化参照

给定测试图像 x , 冻结的 CLIP/AnomalyCLIP 视觉编码器输出若干层 patch 特征。为简化记号, 先讨论用于构造参照的一层特征网格 $F \in \mathbb{R}^{H_p \times W_p \times C}$, 其展平后的 patch 特征记为 $\{f_i\}_{i=1}^N$, $N = H_p W_p$ 。所有视觉特征在相似度计算前做 ℓ_2 归一化。记已有 CLIP-ZSAD 模型给出的正常和异常文本原型为 $t_n, t_a \in \mathbb{R}^C$ 。在 AnomalyCLIP 一类方法中, 这些原型已经可以包含学习得到的上下文 token; 本文直接将它们作为跨图共享的语义参照。

与现有 CLIP-based ZSAD 的 patch-text matching 形式一致 [15, 8, 20], 每个 patch 的语义响应定义为

$$q_i = \frac{\exp(\langle \bar{f}_i, \bar{t}_a \rangle / \tau)}{\exp(\langle \bar{f}_i, \bar{t}_n \rangle / \tau) + \exp(\langle \bar{f}_i, \bar{t}_a \rangle / \tau)}. \quad (1)$$

q_i 给出 patch 在正常/异常语义轴上的相对位置。本文进一步估计图像条件化正常参照 $r_n(x)$, 使局部响应不仅由跨图文本原型解释, 也由当前图像内部的正常外观基准解释。该参照需要满足三个约束: 证据来自同一张测试图像; 证据在语义轴上更接近正常侧; 证据在局部结构上能够代表当前图像的稳定外观。后续步骤将 $r_n(x)$ 实例化为由可靠正常 patch 聚合得到的视觉参照 v_n 。

3.2 局部结构变化响应

图像条件化参照的核心是选择哪些 patch 能支撑当前图像的正常外观。仅依据 q_i 排序会把正常纹理、结构边界和缺陷边缘放在同一语义响应空间中。为刻画 patch 邻域内的局部结构变化, ICNR 在 CLIP patch 特征网格上计算一层 Haar 离散小波分解 [6, 12]。对于每个 2×2 邻域 $(F_{00}, F_{01}, F_{10}, F_{11})$, 四个分量为

$$\begin{aligned} LL &= \frac{1}{2}(F_{00} + F_{01} + F_{10} + F_{11}), & LH &= \frac{1}{2}(F_{00} - F_{01} + F_{10} - F_{11}), \\ HL &= \frac{1}{2}(F_{00} + F_{01} - F_{10} - F_{11}), & HH &= \frac{1}{2}(F_{00} - F_{01} - F_{10} + F_{11}). \end{aligned} \quad (2)$$

其中 LL 保留邻域平均结构, LH, HL, HH 对应水平方向、垂直方向和对角方向的局部变化。高频幅值 h_i 与低频边界强度 e_i 定义为

$$\begin{aligned} h_i &= \frac{1}{C} \sum_{c=1}^C (|LH_{i,c}| + |HL_{i,c}| + |HH_{i,c}|), \\ e_i &= \left(\frac{\|D_x LL_i\|_2^2 + \|D_y LL_i\|_2^2}{C} \right)^{1/2}. \end{aligned} \quad (3)$$

其中 D_x 与 D_y 为相邻低频单元的一阶差分。高频幅值会响应缺陷造成的局部破坏, 也会响应正常物体轮廓和规则结构边界, 因此 h_i 与 e_i 经过双线性上采样回原 patch 网格后共同参与局部结构响应。

为减少极端响应对单图归一化的影响, 本文对每张图像使用分位裁剪归一化。记

$$\begin{aligned} \mathcal{R}_x(z_i) &= \frac{\text{clip}(z_i, p_\ell(z), p_u(z)) - p_\ell(z)}{p_u(z) - p_\ell(z) + \epsilon}, \\ W_i &= \mathcal{R}_x(\mathcal{R}_x(h_i) (1 - \mathcal{R}_x(e_i))). \end{aligned} \quad (4)$$

$p_\ell(z)$ 和 $p_u(z)$ 是当前图像内所有 patch 响应的下分位和上分位。 W_i 较高表示该位置存在明显局部变化, 且这种变化不主要由低频结构边界解释。在参照估计中, 正常证据偏向低 W_i 的稳定区域, 异常候选证据偏向高 W_i 的局部变化区域。

3.3 可靠 Patch 证据选择

ICNR 将语义响应和局部结构变化写入同一个证据权重。设 λ 控制局部结构响应的混合强度, γ 控制语义响应的锐化程度, η 控制结构响应的权重曲线。异常侧和正常侧证据权重分别为

$$\omega_i^a = (q_i)^\gamma ((1 - \lambda) + \lambda W_i)^\eta, \quad (5)$$

$$\omega_i^n = (1 - q_i)^\gamma ((1 - \lambda) + \lambda(1 - W_i))^\eta. \quad (6)$$

该权重把两个条件合在一起: 正常参照证据需要具有较低异常语义响应, 并处在局部结构稳定区域; 异常候选证据需要具有较高异常语义响应, 并伴随难以由低频边界解释的局部变化。去除局部结构项时, 证据选择退化为只由语义响应驱动的条件化参照估计。

令 ρ 为证据比例, $K = \lceil \rho N \rceil$ 。对每张测试图像, 分别选取

$$\mathcal{A}_x = \text{TopK}(\{\omega_i^a\}_{i=1}^N, K), \quad \mathcal{N}_x = \text{TopK}(\{\omega_i^n\}_{i=1}^N, K). \quad (7)$$

$\mathcal{A}_x$ 和 $\mathcal{N}_x$ 是图像内部证据集合, 由当前图像的响应排序产生, 作为后续参照聚合的索引集合。集合内归一化权重为

$$\pi_i^a = \frac{\omega_i^a}{\sum_{j \in \mathcal{A}_x} \omega_j^a + \epsilon}, \quad \pi_i^n = \frac{\omega_i^n}{\sum_{j \in \mathcal{N}_x} \omega_j^n + \epsilon}. \quad (8)$$

加权视觉参照为

$$v_a = \text{Norm} \left(\sum_{i \in \mathcal{A}_x} \pi_i^a f_i \right), \quad (9)$$

$$v_n = \text{Norm} \left(\sum_{i \in \mathcal{N}_x} \pi_i^n f_i \right). \quad (10)$$

其中 v_n 即 $r_n(x)$ 的经验估计。正常侧参照由低 q_i 且低 W_i 的 patch 支撑，描述当前图像中占主导的稳定外观；异常侧参照 v_a 提供当前图像中可疑局部变化的方向，并用于后续门控。

3.4 保守参照校准

视觉参照与文本原型位于同一 CLIP 嵌入空间，因此可以通过归一化插值形成图像条件化原型。首先定义证据置信度

$$c_a = \frac{1}{K} \sum_{i \in \mathcal{A}_x} \omega_i^a, \quad c_n = \frac{1}{K} \sum_{i \in \mathcal{N}_x} \omega_i^n. \quad (11)$$

异常候选证据控制当前图像是否触发参照更新：

$$m_x = \mathbb{I}[c_a \geq \delta_a], \quad g_x = \mathbb{I}[c_a \geq \max(\tau_a, \delta_a)]. \quad (12)$$

其中 δ_a 为图像级更新门限， τ_a 为异常侧原型更新门限。更新强度为

$$\beta_x = \beta_0 c_n m_x, \quad \alpha_x = \alpha_0 c_a m_x. \quad (13)$$

图像条件化文本原型写作

$$t_n^x = \text{Norm}((1 - \beta_x)t_n + \beta_x v_n), \quad (14)$$

$$\tilde{t}_a^x = \text{Norm}((1 - \alpha_x)t_a + \alpha_x v_a), \quad (15)$$

$$t_a^x = g_x \tilde{t}_a^x + (1 - g_x)t_a. \quad (16)$$

该校准是非对称的：正常侧证据通常覆盖更充分，用于估计当前图像的正常外观参照；异常侧证据更稀疏，主要承担更新门控和可疑方向刻画。实现中可将异常侧更新设为门控路径，使异常文本原型保持已有语义方向，并让正常文本原型向 v_n 做受控移动。最终每个 patch 的异常响应由图像条件化原型重新计算：

$$a_i^x = \frac{\exp(\langle \bar{f}_i, \bar{t}_a^x \rangle / \tau)}{\exp(\langle \bar{f}_i, \bar{t}_n^x \rangle / \tau) + \exp(\langle \bar{f}_i, \bar{t}_a^x \rangle / \tau)}. \quad (17)$$

像素级异常图由 a_i^x 上采样得到。若使用多个 CLIP 层，ICNR 先用选定层的 patch token 构造同一组 t_n^x, t_a^x ，再在各层上按式 (17) 重算响应并进行层级融合。

算法 1 ICNR 的单图推理流程

输入	测试图像 x ; 冻结视觉编码器; 已有正常/异常文本原型 t_n, t_a ; 证据比例与门控参数。
输出	图像条件化异常响应图。
1	提取多层 CLIP patch 特征, 并在选定特征网格 F 上计算初始语义响应 q_i 。
2	对 F 执行 Haar 分解, 得到高频幅值 h_i 与低频边界强度 e_i , 并计算局部结构变化响应 W_i 。
3	将 q_i 与 W_i 写入正常侧和异常侧证据权重 ω_i^n, ω_i^a 。
4	根据权重分别选取 $\mathcal{N}_x$ 与 $\mathcal{A}_x$, 并在集合内归一化证据权重。
5	聚合正常侧和异常侧视觉参照 v_n, v_a , 其中 v_n 作为当前图像正常参照 $r_n(x)$ 的估计。
6	由证据置信度确定更新门控和更新强度, 得到图像条件化原型 t_n^x, t_a^x 。
7	在各层 patch 特征上用 t_n^x, t_a^x 重算异常响应, 并上采样融合为最终异常图。

3.5 推理流程

对单张测试图像, ICNR 的推理过程如下。第一, 冻结视觉编码器提取 patch 特征, 并用已有文本原型计算语义响应 q_i 。第二, 在用于构造参照的 patch 特征网格上执行 Haar 分解, 得到局部结构变化响应 W_i 。第三, 依据式 (6) 计算正常侧和异常侧证据权重, 并根据式 (7) 选取图像内部证据集合。第四, 聚合得到 v_n 与 v_a , 由证据置信度确定更新门控和更新强度。第五, 用图像条件化原型重算 patch 响应, 并融合为最终异常图。

额外计算主要来自一次 patch 网格 Haar 分解、两次 top- K 证据选择和一次基于校准原型的响应重算。推理阶段仅依赖测试图像、冻结编码器和已有文本原型。

4 实验**4.1 数据集与指标**

主结果覆盖五个工业异常检测基准: MVTec AD [2]、VisA [21]、MPDD [9]、BTAD [13] 和 DTD-Synthetic [1]。其中 MVTec AD 与 VisA 进一步用于受控机制消融, 以分析图像条件化参照和局部结构响应的作用。

实验报告 Pixel AUROC、Pixel AUPRO、Image AUROC 和 Image AP。Pixel AUROC 衡量异常图的像素级排序能力。Pixel AUPRO 衡量区域级定位质量, 在小缺陷和误报面积控制场景中更具指示性。Image AUROC 与 Image AP 用于评估图像级异常检测。

4.2 实现细节

比较方法包括 CLIP [15]、WinCLIP [8]、VAND [5]、CoOp [19]、AdaCLIP [3]、AnomalyCLIP [20] 和 AA-CLIP [11]。在本文的图像条件化参照估计过程中, CLIP 视觉编码器和文本原型保持冻结。除特别说明外, ICNR 使用边界感知局部结构响应、top-ratio 0.20、可靠性混合强度 0.05、 $\alpha_0 = 0$ 和 $\beta_0 = 0.01$ 。新增步骤不进行测试时优化, 也不使用目标类别训练。

表 1: 五个工业基准上的零样本异常定位结果。所有指标均以百分比报告；最佳和次优结果分别用粗体和下划线标出。

图像级结果 (Image AUROC, Image AP)								
数据集	CLIP	WinCLIP	VAND	CoOp	AdaCLIP	AnomalyCLIP	AA-CLIP [†]	ICNR
MVTec AD	(74.1, 87.6)	<u>(91.8, 96.5)</u>	(86.1, 93.5)	(88.8, 94.8)	(89.2, 96.4)	(91.6, 96.4)	(90.5, 94.9)	(94.5, 97.6)
VisA	(66.4, 71.5)	(78.1, 81.2)	(78.0, 81.4)	(62.8, 68.1)	(85.8, 84.9)	(82.1, <u>85.4</u>)	<u>(84.6, 82.2)</u>	<u>(84.6, 87.4)</u>
MPDD	(54.3, 65.4)	(63.6, 69.9)	(73.0, 80.2)	(55.1, 64.2)	(76.0, 80.4)	<u>(77.0, 82.0)</u>	(75.1, 80.1)	(77.8, 82.3)
BTAD	(34.5, 52.5)	(68.2, 70.9)	(73.6, 68.6)	(66.8, 77.4)	(88.6, 92.4)	(88.3, 87.3)	(94.8, 97.9)	<u>(93.9, 94.9)</u>
DTD-Synthetic	(71.6, 85.7)	(93.2, 92.6)	(86.4, 95.0)	(-, -)	<u>(95.5, 97.0)</u>	(93.5, 97.0)	(93.3, <u>97.8</u>)	(96.9, 98.7)
平均	(60.2, 72.5)	(79.0, 82.2)	(79.4, 83.7)	(68.4, 76.1)	(87.0, 90.2)	(86.5, 89.6)	<u>(87.7, 90.6)</u>	(89.5, 92.2)
像素级结果 (Pixel AUROC, Pixel AUPRO)								
MVTec AD	(38.4, 11.3)	(85.1, 64.6)	(87.6, 44.0)	(33.3, 6.7)	(88.7, 37.8)	(91.2, 83.2)	(91.9, 84.6)	<u>(91.8, 86.2)</u>
VisA	(46.6, 14.8)	(79.6, 56.8)	(94.2, 86.8)	(24.2, 3.8)	<u>(95.5, 56.8)</u>	<u>(95.5, 87.0)</u>	<u>(95.5, 83.0)</u>	(96.2, 91.7)
MPDD	(62.1, 33.0)	(76.4, 48.9)	(94.1, 83.2)	(15.4, 2.3)	(96.1, 60.3)	(96.5, <u>88.7</u>)	<u>(96.7, 76.5)</u>	(97.3, 89.9)
BTAD	(30.6, 4.4)	(72.7, 27.3)	(60.8, 25.0)	(28.6, 3.8)	(92.1, 32.5)	(94.2, <u>74.8</u>)	(97.0, 69.0)	<u>(96.3, 79.5)</u>
DTD-Synthetic	(33.9, 12.5)	(83.9, 57.8)	(95.3, 86.9)	(-, -)	<u>(97.7, 75.0)</u>	(97.9, 92.3)	(96.4, 85.9)	<u>(97.9, 91.8)</u>
平均	(42.3, 15.2)	(79.5, 51.1)	(86.4, 65.2)	(25.4, 4.2)	(94.0, 52.5)	(95.1, <u>85.2</u>)	<u>(95.5, 79.8)</u>	(95.9, 87.8)

表 2: Oracle detailed prompt 的文本侧诊断结果。该实验比较 generic abnormal prompt 与加入当前缺陷外观描述后的 detailed prompt response。

诊断项	样例数	覆盖范围	指标	统计值
异常/背景响应间隔变化	8	5 类 / 6 缺陷	Δ gap	0.207 (0.159–0.276)
Generic 弱响应区域恢复	12	3 类 / 5 缺陷	Coverage gain	0.060 (0.016–0.156)

4.3 跨方法比较

表 1 按图像级和像素级结果报告五个工业基准上的零样本异常定位表现。该表采用统一的跨方法 baseline 集合，并将 ICNR 与已有 CLIP-ZSAD 方法放在同一评测口径下比较。ICNR 列使用当前项目记录的五数据集结果；MVTec AD 与 VisA 上的机制归因由后续受控消融给出。

5 分析

5.1 Reference Gap 的证据

表 2 给出文本侧的诊断证据。在 MVTec 样例中，oracle detailed prompt 明确写入当前缺陷外观后，异常区域与背景区域的响应间隔平均增加 0.207；在 generic prompt 原本响应不足的样例中，detailed prompt 对标注异常区域的平均覆盖恢复为 0.060。这说明 patch response 不只由训练得到的通用 abnormal 语义决定，还会被当前样本的具体外观信息调节。

受控结果进一步支持 reference gap 的叙事。将 wavelet 响应直接混入异常图时，MVTec 的 Pixel AUPRO 降至 80.4，VisA 降至 85.1，低于最终图像条件化参照结果。Global 相对 Direct 有明显改善，但仍低于 ICNR：MVTec 的 Pixel AUPRO 差距为 1.9，VisA 的差距为 2.5。Sem 是强基线，说明主要增益来自当前图像参照估计本身；Struct 进一步改善了用于估计参照的 patch 证据选择。

表 3: MVTec 与 VisA 上的受控核心消融。单元为 Pixel AUROC/AUPRO 或 Image AUROC/AP。

变体	MVTec		VisA	
	Pixel	Image	Pixel	Image
Base	91.2 / 83.2	91.6 / 96.4	95.5 / 86.7	82.0 / 85.3
Direct	88.7 / 80.4	92.9 / 96.9	94.6 / 85.1	81.6 / 84.8
Global	91.2 / 84.3	93.1 / 96.9	95.8 / 89.2	83.2 / 86.4
Sem	91.6 / 85.2	93.7 / 97.1	96.0 / 90.4	83.7 / 86.9
Struct	91.7 / 85.8	93.9 / 97.2	96.1 / 91.3	84.1 / 87.0
ICNR	91.8 / 86.2	94.5 / 97.6	96.2 / 91.7	84.6 / 87.4




图 1: 从结果工作区复制的机制排序图。预期模式是: Direct 较弱, Global 有效但不充分, Sem 已经较强, 而 ICNR 通过局部结构证据选择进一步改善图像条件化参照。

5.2 局部结构响应设计

表 4 隔离了频域响应的使用方式。HF 只使用高频幅值, 不抑制结构边界。Bnd 使用式 (4) 降低由低频结构边界解释的响应。最终方法进一步加入保守正常参照估计。这个设计使频域响应的作用落在证据选择阶段。

5.3 正常图稳定性

正常侧参照采用保守更新。表 5 报告正常图中超过两个高响应阈值的面积。ICNR 在两个数据集上均没有增加该误报面积, 这与正常参照校正的定位一致: 方法调整的是当前图像的正常外观基准, 而不是放大异常图响应。

表 4: 局部结构响应设计消融。单元为 Pixel AUROC/AUPRO 或 Image AUROC/AP。

变体	MVTec		VisA	
	Pixel	Image	Pixel	Image
Direct	88.7 / 80.4	92.9 / 96.9	94.6 / 85.1	81.6 / 84.8
Sem	91.6 / 85.2	93.7 / 97.1	96.0 / 90.4	83.7 / 86.9
HF	91.6 / 85.3	94.0 / 97.2	96.0 / 90.8	84.0 / 86.9
Bnd	91.7 / 85.7	93.8 / 97.3	96.1 / 91.2	83.9 / 87.1
ICNR	91.8 / 86.2	94.5 / 97.6	96.2 / 91.7	84.6 / 87.4




图 2: 可靠性设计消融。曲线用于分析局部结构变化如何影响图像条件化正常参照的 patch 证据选择。

6 局限性

ICNR 假设测试图像中存在足够可靠的正常 patch，以估计图像条件化正常参照。当异常覆盖大部分物体、整张图像发生分布偏移，或正常区域本身视觉上高度歧义时，估计得到的参照可能受到污染。保守更新能够降低这一风险，但不能完全消除。

局部结构响应主要处理局部纹理和结构边界混淆。对于逻辑异常、全局几何异常，或主要依赖语义关系判断的缺陷，它的作用可能较弱。当前机制结论也限定在 MVTec/VisA 的受控实验范围内。更广泛的数据集结论需要同样的受控消融协议，而不能只依赖系统级结果或外部报告表格。

7 结论

本文指出了基于 CLIP 的零样本异常定位中的一个 reference gap。可学习的正常/异常文本原型提供跨类别语义轴，但局部异常证据仍需要当前测试图像的正常外观参照。ICNR 从冻结 CLIP 特征场中的可靠 patch 证据估计该图像条件化正常参照。频域响应用于证据选择中的局部结构变化刻画，最终异常响应相对于估计参照重新计算。MVTec AD 和 VisA 上的受控结果支持该机制：direct wavelet-map fusion 较弱，全局参照有效但不充分，semantic-only adaptation 是强基线，而边界感知证据选择与保守正常参照估计得到最佳受控结果。

表 5: 正常图稳定性。FP area 表示正常图中超过对应阈值的面积比例；数值越低越好。

数据集	方法	正常图数量	FP area @ p95	FP area @ p99
MVTec	Baseline	467	5.002%	1.001%
MVTec	ICNR	467	4.895%	0.960%
VisA	Baseline	962	4.996%	1.001%
VisA	ICNR	962	4.718%	0.937%




图 3: 从结果工作区复制的敏感性曲线。wavelet-mix 曲线反映局部结构变化参与正常参照证据选择的强度。

可复现性与数据可用性

本 LaTeX 目录包含当前草稿使用的表格、图和 CSV 快照。主结果覆盖 MVTec AD、VisA、MPDD、BTAD 和 DTD-Synthetic；受控机制消融使用 MVTec AD 与 VisA。Oracle detailed prompt 诊断实验的数据快照位于 data/detail_prompt_*. 数据访问遵循原始基准发布方的许可和使用条款。

伦理声明

本文使用公开工业异常检测基准，不涉及人体受试者或私人个人数据。

AI 使用声明

本草稿在学术写作工具辅助下整理为中文单栏 LaTeX 版本。研究问题、证据选择、论证边界和最终内容由作者负责确认；提交前需要由作者核查所有实验记录、图表、引用和结论。

参考文献

- [1] Toshimichi Aota, Lloyd Teh Tzer Tong, and Takayuki Okatani. Zero-shot versus many-shot: Unsupervised texture anomaly detection. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*, pages 5564–5572, 2023. 6
- [2] Paul Bergmann, Michael Fauser, David Sattlegger, and Carsten Steger. MVTec AD – a comprehensive real-world dataset for unsupervised anomaly detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 9592–9600, 2019. 6
- [3] Yunkang Cao, Jiangning Zhang, Luca Frittoli, Yuqi Cheng, Weiming Shen, and Giacomo Boracchi. AdaCLIP: Adapting CLIP with hybrid learnable prompts for zero-shot anomaly detection. In *European Conference on Computer Vision*, pages 55–72, 2024. 1, 2, 6
- [4] Peng Chen and Chao Huang. WMoE-CLIP: Wavelet-enhanced mixture-of-experts prompt learning for zero-shot anomaly detection, 2026. 2
- [5] Xuhai Chen, Yue Han, and Jiangning Zhang. APRIL-GAN: A zero-/few-shot anomaly classification and segmentation method for CVPR 2023 VAND workshop challenge tracks 1&2. *arXiv preprint arXiv:2305.17382*, 2023. 6
- [6] Ingrid Daubechies. Orthonormal bases of compactly supported wavelets. *Communications on Pure and Applied Mathematics*, 41(7):909–996, 1988. 2, 3
- [7] Tao Gong, Qi Chu, Bin Liu, Wei Zhou, and Nenghai Yu. FE-CLIP: Frequency enhanced CLIP model for zero-shot anomaly detection and segmentation. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 21220–21230, 2025. 2
- [8] Jongheon Jeong, Yang Zou, Taewan Kim, Dongqing Zhang, Avinash Ravichandran, and Onkar Dabeer. Win-CLIP: Zero-/few-shot anomaly classification and segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 19606–19616, 2023. 1, 2, 3, 6
- [9] Stepan Jezek, Martin Jonak, Radim Burget, Pavel Dvorak, and Milos Skotak. Deep learning-based defect detection of metal parts: Evaluating current methods in complex conditions. In *2021 13th International Congress on Ultra Modern Telecommunications and Control Systems and Workshops (ICUMT)*, pages 66–71. IEEE, 2021. 6
- [10] Yiting Li, Adam David Goodge, Fayao Liu, and Chuan-Sheng Foo. PromptAD: Zero-shot anomaly detection using text prompts. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*, pages 1082–1091, 2024. 2
- [11] Wenxin Ma, Xu Zhang, Qingsong Yao, Fenghe Tang, Chenxu Wu, Yingtai Li, Rui Yan, Zihang Jiang, and S. Kevin Zhou. AA-CLIP: Enhancing zero-shot anomaly detection via anomaly-aware CLIP. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 4744–4754, 2025. 1, 2, 6
- [12] Stephane G. Mallat. A theory for multiresolution signal decomposition: The wavelet representation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 11(7):674–693, 1989. 2, 3
- [13] Pankaj Mishra, Riccardo Verk, Daniele Fornasier, Claudio Picciarelli, and Gian Luca Foresti. VT-ADL: A vision transformer network for image anomaly detection and localization. *arXiv preprint arXiv:2104.10036*, 2021. 6
- [14] Zhen Qu, Xian Tao, Mukesh Prasad, Fei Shen, Zhengtao Zhang, Xinyi Gong, and Guiguang Ding. VCP-CLIP: A visual context prompting model for zero-shot anomaly segmentation. In *European Conference on Computer Vision*, pages 301–317, 2024. 1, 2

- [15] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning*, pages 8748–8763, 2021. 2, 3, 6
- [16] Manli Shu, Weili Nie, De-An Huang, Zhiding Yu, Tom Goldstein, Anima Anandkumar, and Chaowei Xiao. Test-time prompt tuning for zero-shot generalization in vision-language models. In *Advances in Neural Information Processing Systems*, 2022. 3
- [17] Naiqi Zhang, Chuancheng Shi, Jingtong Dou, Wenhua Wu, Fei Shen, and Jianhua Cao. HarmoniAD: Harmonizing local structures and global semantics for anomaly detection, 2026. 2
- [18] Kaiyang Zhou, Jingkan Yang, Chen Change Loy, and Ziwei Liu. Conditional prompt learning for vision-language models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 16795–16804, 2022. 3
- [19] Kaiyang Zhou, Jingkan Yang, Chen Change Loy, and Ziwei Liu. Learning to prompt for vision-language models. *International Journal of Computer Vision*, 130:2337–2348, 2022. 6
- [20] Qihang Zhou, Guansong Pang, Yu Tian, Shibo He, and Jiming Chen. AnomalyCLIP: Object-agnostic prompt learning for zero-shot anomaly detection. In *International Conference on Learning Representations*, 2024. 1, 2, 3, 6
- [21] Yang Zou, Jongheon Jeong, Latha Pemula, Dongqing Zhang, and Onkar Dabeer. Spot-the-difference self-supervised pre-training for anomaly detection and segmentation. In *European Conference on Computer Vision*, pages 392–408, 2022. 6