

面向 CLIP 零样本异常定位的图像条件化正常参照估计

匿名稿件

2026 年 8 月 6 日

摘要

基于 CLIP 的零样本异常定位通常面向目标类别无训练样本、无正常参考图像的协议，模型需要从单张测试图像输出图像级异常分数和像素级异常图。现有 CLIP-ZSAD 原型通过视觉 patch 与正常/异常文本原型匹配形成跨类别语义参照；但局部异常证据还取决于当前测试图像的正常外观。对于光滑物体而言，局部纹理变化可能对应缺陷；对于粗糙材质或重复结构而言，相似响应可能属于正常外观。本文将这一缺失的图像条件化基准概括为 CLIP-ZSAD 中的 reference gap。文本侧诊断进一步表明这一问题：当诊断提示中显式加入当前图像的材质、表面纹理或结构描述时，部分定位图会发生改变，说明外观上下文会影响局部响应的解释。基于这一观察，本文提出 ICNR，一种接入已有 CLIP-ZSAD 原型的图像条件化正常参照估计方法。该方法保持编码器和文本原型冻结，不进行测试时反向传播或参数更新，而是从当前测试图像的 patch 证据估计正常参照，利用小波局部结构响应刻画证据可靠性，并基于估计参照重新计算异常响应。主结果覆盖五个工业基准；MVTec AD 和 VisA 上的受控消融显示，直接把局部结构响应作为异常分数会降低定位指标，固定全局参照弱于图像条件化参照，而边界感知证据选择可在语义证据选择基础上进一步改善定位指标。

关键词：零样本异常定位，CLIP，图像条件化正常参照，小波局部结构响应，patch 证据选择

1 引言

零样本异常检测与定位通常指目标类别无训练样本、无正常参考图像，模型需要直接输出图像级异常分数和像素级异常图。CLIP 为这一设置提供了直接的语义接口：视觉 patch 可以与正常和异常状态的语言原型进行匹配。已有方法沿着这一接口发展出组合式状态提示、局部窗口评分、物体无关提示学习、视觉上下文提示和异常感知适配等路线 [8, 20, 3, 14, 11]。这些路线表明，CLIP 能够为异常定位提供有效的正常/异常语义原型。

局部异常证据由语义相似度和当前图像外观共同决定。工业缺陷通常表现为划痕、污染、压痕、裂纹或缺失部件，其中许多缺陷会引起纹理、边界连续性或细粒度结构的局部变化。相似的局部变化也可能来自正常材质、重复纹理、物体轮廓和成像噪声。因此，一个 patch 响应是否指向异常，取决于它相对于当前图像正常外观的偏离程度。同样的高响应区域，在光滑金属表面上可能是划痕，在编织物或粗糙表面上则可能是正常结构。

这一点揭示了 CLIP-ZSAD 中一个具体的 reference gap。可学习的正常/异常文本原型提供跨类别共享的语义参照，而当前测试图像的正常外观参照仍需要由图像侧估计。对于一张具体图像，表

面颗粒度、纹理密度、结构边界和重复图案共同决定了哪些局部变化属于正常范围。缺少这一图像条件化参照时，正常纹理、结构边界和真实缺陷容易在局部响应空间中相互混杂。

文本侧的一个诊断现象进一步指向这一缺口。当通用异常文本原型之外再加入描述当前缺陷外观的诊断提示时，部分样例中标注异常区域的响应被进一步激活，异常区域与背景区域的响应间隔也随之增大。该现象说明，通用文本原型之外，当前测试图仍携带能够调节 patch response 的外观信息。因此，本文将外观上下文转到图像侧处理，从测试图自身选择可靠 patch 证据，估计图像条件化正常外观基准。

本文提出面向 CLIP-ZSAD 的图像条件化正常参照估计。给定单张测试图像，ICNR 接收已有 CLIP-ZSAD 模型的冻结视觉特征和正常/异常文本原型，在 CLIP patch 特征场中选择可靠证据。所选正常证据被聚合为图像条件化正常参照，随后每个 patch 的异常响应相对于该参照和共享的正常/异常文本参照重新计算。整个参照估计在推理阶段完成，保持视觉编码器、文本编码器以及已有 prompt/adaptor 参数冻结，证据仅来自当前测试图像的 patch 特征。

方法的关键在于 patch 证据选择。如果证据选择只由语义响应驱动，正常纹理、结构边界和缺陷区域仍可能混在一起。ICNR 因此在 CLIP patch 特征网格上测量局部结构变化。小波局部结构响应用于刻画这种变化，并约束哪些 patch 可以支撑正常参照。语义异常响应较低且局部结构稳定的 patch 构成正常参照证据；语义可疑且结构变化显著的 patch 从正常参照中排除，并在参照估计后重新评估。

本文贡献如下：

- 指出 CLIP-ZSAD 中的 reference gap：可学习的正常/异常文本原型提供跨类别语义参照，但缺少当前测试图像的正常外观参照。
- 提出 ICNR，一种单图、目标域训练无关的图像条件化正常参照估计方法，从当前测试图像中选择可靠 patch 证据，并在冻结 CLIP 语义空间中重新计算局部异常响应。
- 将小波局部结构响应用于证据可靠性建模，并通过 ScoreFusion、GlobalRef、SemRef 和 StructRef 等受控消融区分其作用：结构响应更适合承担可靠参照证据筛选，而非独立定位分数。

2 相关工作

基于 CLIP 的零样本异常定位。 CLIP 通过共享嵌入空间连接视觉区域和文本描述 [15]。基于 CLIP 的异常检测方法通常把正常/异常状态写成文本提示或可学习文本原型，并用 patch-text 相似度产生局部异常图 [8, 10, 20]。后续路线进一步引入混合提示、视觉上下文提示或异常感知适配模块，以增强跨类别语义表示 [3, 14, 11]。这些方法主要增强文本侧正常/异常语义参照或训练式视觉上下文适配；本文关注在已有文本参照下，如何依据当前测试图像的正常外观解释局部证据。

频域与局部结构线索。 频域信息已经是异常检测中的相关信号。近期路线为 CLIP 引入 frequency-enhanced adaptors、Haar 低/高频分解和局部-全局频域分支，以增强视觉语言异常表示 [7, 4, 17]。小波分析本身也是经典的多分辨率信号表示方法 [6, 12]。本文不将频域本身作为新异常分数，而是使用小波局部结构响应刻画 patch 证据的稳定性，并参与当前图像正常参照的证据选择。

单图参照与测试时自适应。视觉语言模型可以受益于测试时或图像条件化自适应，例如 test-time prompt tuning 和 conditional prompt learning [16, 18]。这些方法通常关注提示或模型参数如何随测试样本变化。在异常检测中，外部正常样本能够形成显式正常参照；视觉上下文也可以调节文本侧表示 [8, 14]。在本文采用的 CLIP-ZSAD 协议中，目标类别训练样本和正常参考图像不可用，因此正常外观参照需要从当前测试图自身估计。ICNR 保持 prompt、adapter 和 encoder 参数冻结，通过当前图像内部的 patch 证据构建正常外观参照，而不是执行测试时参数更新。

3 方法

3.1 语义参照与图像条件化参照

给定测试图像 x 和一个已有 CLIP-ZSAD 模型，冻结的 CLIP 系视觉编码器输出若干层 patch 特征。为简化记号，先讨论用于构造参照的一层特征网格 $F \in \mathbb{R}^{H_p \times W_p \times C}$ ，其展平后的 patch 特征记为 $\{f_i\}_{i=1}^N$ ， $N = H_p W_p$ 。所有视觉特征在相似度计算前做 ℓ_2 归一化。记已有 CLIP-ZSAD 模型给出的正常和异常文本原型为 $t_n, t_a \in \mathbb{R}^C$ 。这些原型可以来自手写 prompt、可学习 prompt，或由辅助异常数据学习得到的上下文 token；ICNR 直接将它们作为跨图共享的语义参照，并在其上估计当前图像的正常外观基准。

与现有 patch-text matching 形式一致 [15, 8, 20]，每个 patch 的语义响应定义为

$$q_i = \frac{\exp(\langle \bar{f}_i, \bar{t}_a \rangle / \tau)}{\exp(\langle \bar{f}_i, \bar{t}_n \rangle / \tau) + \exp(\langle \bar{f}_i, \bar{t}_a \rangle / \tau)}. \quad (1)$$

q_i 给出 patch 相对于正常/异常文本原型的语义响应。本文进一步估计图像条件化正常参照 $r_n(x)$ ，使局部响应不仅由跨图文本原型解释，也由当前图像内部的正常外观基准解释。该参照需要满足三个约束：证据来自同一张测试图像；证据在语义响应上更接近正常侧；证据在局部结构上能够代表当前图像的稳定外观。后续步骤将 $r_n(x)$ 实例化为由可靠正常 patch 聚合得到的视觉参照 v_n 。

3.2 局部结构变化响应

图像条件化参照的核心是选择哪些 patch 能支撑当前图像的正常外观。仅依据 q_i 排序会把正常纹理、结构边界和缺陷边缘放在同一语义响应空间中。为刻画 patch 邻域内的局部结构变化，ICNR 在 CLIP patch 特征网格上计算一层 Haar 离散小波分解 [6, 12]。对于每个 2×2 邻域 $(F_{00}, F_{01}, F_{10}, F_{11})$ ，四个分量为

$$\begin{aligned} LL &= \frac{1}{2}(F_{00} + F_{01} + F_{10} + F_{11}), & LH &= \frac{1}{2}(F_{00} - F_{01} + F_{10} - F_{11}), \\ HL &= \frac{1}{2}(F_{00} + F_{01} - F_{10} - F_{11}), & HH &= \frac{1}{2}(F_{00} - F_{01} - F_{10} + F_{11}). \end{aligned} \quad (2)$$

其中 LL 保留邻域平均结构, LH, HL, HH 对应水平方向、垂直方向和对角方向的局部变化。高频幅值 h_i 与低频边界强度 e_i 定义为

$$\begin{aligned} h_i &= \frac{1}{C} \sum_{c=1}^C (|LH_{i,c}| + |HL_{i,c}| + |HH_{i,c}|), \\ e_i &= \left(\frac{\|D_x LL_i\|_2^2 + \|D_y LL_i\|_2^2}{C} \right)^{1/2}. \end{aligned} \quad (3)$$

其中 D_x 与 D_y 为相邻低频单元的一阶差分。高频幅值会响应缺陷造成的局部破坏, 也会响应正常物体轮廓和规则结构边界, 因此 h_i 与 e_i 经过双线性上采样回原 patch 网格后共同参与局部结构响应。

为减少极端响应对单图归一化的影响, 本文对每张图像使用分位裁剪归一化。记

$$\begin{aligned} \mathcal{R}_x(z_i) &= \frac{\text{clip}(z_i, p_\ell(z), p_u(z)) - p_\ell(z)}{p_u(z) - p_\ell(z) + \epsilon}, \\ W_i &= \mathcal{R}_x(\mathcal{R}_x(h_i) (1 - \mathcal{R}_x(e_i))). \end{aligned} \quad (4)$$

$p_\ell(z)$ 和 $p_u(z)$ 是当前图像内所有 patch 响应的下分位和上分位。 W_i 较高表示该位置存在明显局部变化, 且这种变化不主要由低频结构边界解释。在参照估计中, 正常证据偏向低 W_i 的稳定区域, 异常候选证据偏向高 W_i 的局部变化区域。

3.3 可靠 Patch 证据选择

ICNR 将语义响应和局部结构变化写入同一个证据权重。设 λ 控制局部结构响应的混合强度, γ 控制语义响应的锐化程度, η 控制结构响应的权重曲线。异常侧和正常侧证据权重分别为

$$\omega_i^a = (q_i)^\gamma ((1 - \lambda) + \lambda W_i)^\eta, \quad (5)$$

$$\omega_i^n = (1 - q_i)^\gamma ((1 - \lambda) + \lambda(1 - W_i))^\eta. \quad (6)$$

该权重把两个条件合在一起: 正常参照证据需要具有较低异常语义响应, 并处在局部结构稳定区域; 异常候选证据需要具有较高异常语义响应, 并伴随难以由低频边界解释的局部变化。去除局部结构项时, 证据选择退化为只由语义响应驱动的条件化参照估计。

令 ρ 为证据比例, $K = \lceil \rho N \rceil$ 。对每张测试图像, 分别选取

$$\mathcal{A}_x = \text{TopK}(\{\omega_i^a\}_{i=1}^N, K), \quad \mathcal{N}_x = \text{TopK}(\{\omega_i^n\}_{i=1}^N, K). \quad (7)$$

$\mathcal{A}_x$ 和 $\mathcal{N}_x$ 是图像内部证据集合, 由当前图像的响应排序产生, 作为后续参照聚合的索引集合。集合内归一化权重为

$$\pi_i^a = \frac{\omega_i^a}{\sum_{j \in \mathcal{A}_x} \omega_j^a + \epsilon}, \quad \pi_i^n = \frac{\omega_i^n}{\sum_{j \in \mathcal{N}_x} \omega_j^n + \epsilon}. \quad (8)$$

加权视觉参照为

$$v_a = \text{Norm} \left(\sum_{i \in \mathcal{A}_x} \pi_i^a f_i \right), \quad (9)$$

$$v_n = \text{Norm} \left(\sum_{i \in \mathcal{N}_x} \pi_i^n f_i \right). \quad (10)$$

其中 v_n 即 $r_n(x)$ 的经验估计。正常侧参照由低 q_i 且低 W_i 的 patch 支撑，描述当前图像中占主导的稳定外观；异常侧参照 v_a 提供当前图像中可疑局部变化的方向，并用于后续门控。

3.4 保守参照校准

视觉参照与文本原型位于同一 CLIP 嵌入空间，因此可以通过归一化插值形成图像条件化原型。首先定义证据置信度

$$c_a = \frac{1}{K} \sum_{i \in \mathcal{A}_x} \omega_i^a, \quad c_n = \frac{1}{K} \sum_{i \in \mathcal{N}_x} \omega_i^n. \quad (11)$$

异常候选证据控制当前图像是否触发参照更新：

$$m_x = \mathbb{I}[c_a \geq \delta_a], \quad g_x = \mathbb{I}[c_a \geq \max(\tau_a, \delta_a)]. \quad (12)$$

其中 δ_a 为图像级更新门限， τ_a 为异常侧原型更新门限。更新强度为

$$\beta_x = \beta_0 c_n m_x, \quad \alpha_x = \alpha_0 c_a m_x. \quad (13)$$

图像条件化文本原型写作

$$t_n^x = \text{Norm}((1 - \beta_x)t_n + \beta_x v_n), \quad (14)$$

$$\tilde{t}_a^x = \text{Norm}((1 - \alpha_x)t_a + \alpha_x v_a), \quad (15)$$

$$t_a^x = g_x \tilde{t}_a^x + (1 - g_x)t_a. \quad (16)$$

该校准是非对称的：正常侧证据通常覆盖更充分，用于估计当前图像的正常外观参照；异常侧证据更稀疏，主要承担更新门控和可疑方向刻画。实现中可将异常侧更新设为门控路径，使异常文本原型保持已有语义方向，并让正常文本原型向 v_n 做受控移动。最终每个 patch 的异常响应由图像条件化原型重新计算：

$$a_i^x = \frac{\exp(\langle \bar{f}_i, \bar{t}_a^x \rangle / \tau)}{\exp(\langle \bar{f}_i, \bar{t}_n^x \rangle / \tau) + \exp(\langle \bar{f}_i, \bar{t}_a^x \rangle / \tau)}. \quad (17)$$

像素级异常图由 a_i^x 上采样得到。若使用多个 CLIP 层，ICNR 先用选定层的 patch token 构造同一组 t_n^x, t_a^x ，再在各层上按式 (17) 重算响应并进行层级融合。

算法 1 ICNR 的单图推理流程

输入	测试图像 x ; 冻结视觉编码器; 已有正常/异常文本原型 t_n, t_a ; 证据比例与门控参数。
输出	图像条件化异常响应图。
1	提取多层 CLIP patch 特征, 并在选定特征网格 F 上计算初始语义响应 q_i 。
2	对 F 执行 Haar 分解, 得到高频幅值 h_i 与低频边界强度 e_i , 并计算局部结构变化响应 W_i 。
3	将 q_i 与 W_i 写入正常侧和异常侧证据权重 ω_i^n, ω_i^a 。
4	根据权重分别选取 $\mathcal{N}_x$ 与 $\mathcal{A}_x$, 并在集合内归一化证据权重。
5	聚合正常侧和异常侧视觉参照 v_n, v_a , 其中 v_n 作为当前图像正常参照 $r_n(x)$ 的估计。
6	由证据置信度确定更新门控和更新强度, 得到图像条件化原型 t_n^x, t_a^x 。
7	在各层 patch 特征上用 t_n^x, t_a^x 重算异常响应, 并上采样融合为最终异常图。

3.5 推理流程

对单张测试图像, ICNR 的推理过程如下。第一, 冻结视觉编码器提取 patch 特征, 并用已有文本原型计算语义响应 q_i 。第二, 在用于构造参照的 patch 特征网格上执行 Haar 分解, 得到局部结构变化响应 W_i 。第三, 依据式 (6) 计算正常侧和异常侧证据权重, 并根据式 (7) 选取图像内部证据集合。第四, 聚合得到 v_n 与 v_a , 由证据置信度确定更新门控和更新强度。第五, 用图像条件化原型重算 patch 响应, 并融合为最终异常图。

额外计算主要来自一次 patch 网格 Haar 分解、两次 top- K 证据选择和一次基于校准原型的响应重算。推理阶段仅依赖测试图像、冻结编码器和已有文本原型。

4 实验

4.1 数据集与指标

本文采用目标类别零样本设置: 目标类别训练图像、正常参考图像和像素标注均不可用, 模型直接输出图像级异常分数和像素级异常图。主结果覆盖五个工业异常检测基准: MVTec AD [2]、VisA [21]、MPDD [9]、BTAD [13] 和 DTD-Synthetic [1]。其中 MVTec AD 与 VisA 具有完整的像素级标注和多样的工业缺陷类型, 本文进一步在这两个数据集上报告受控消融, 以分析图像条件化参照和局部结构响应的作用。

实验报告 Pixel AUROC、Pixel AUPRO、Image AUROC 和 Image AP。Pixel AUROC 衡量异常图的像素级排序能力。Pixel AUPRO 衡量区域级定位质量, 在小缺陷和误报面积控制场景中更具指示性。Image AUROC 与 Image AP 用于评估图像级异常检测。

4.2 实现细节

比较覆盖原始 CLIP 零样本匹配、局部窗口匹配、视觉异常检测桥接、上下文/提示学习、适应式提示、物体无关异常提示和异常感知适配等代表路线 [15, 8, 5, 19, 3, 20, 11]。ICNR 建立在已有 CLIP-ZSAD 原型之上, 沿用基线的视觉编码器、文本原型、多层特征融合和平滑设置; 图像条件化参照估计作为推理阶段模块接入, 保持视觉编码器、文本编码器和已学习 prompt 冻结。除特别说明外, 可靠 patch 选择使用 top-ratio 0.20, 局部结构响应的混合强度为 0.05; 最终报告设置采用

表 1: 五个工业基准上的零样本异常定位结果。所有指标均以百分比报告；最佳和次优结果分别用粗体和下划线标出。外部方法按其公开零样本报告口径整理，平均值按该方法可用数据集计算。

图像级结果 (Image AUROC, Image AP)								
数据集	CLIP	WinCLIP	VAND	CoOp	AdaCLIP	AnomalyCLIP	AA-CLIP [†]	ICNR
MVTec AD	(74.1, 87.6)	<u>(91.8, 96.5)</u>	(86.1, 93.5)	(88.8, 94.8)	(89.2, 96.4)	(91.6, 96.4)	(90.5, 94.9)	(94.5, 97.6)
VisA	(66.4, 71.5)	(78.1, 81.2)	(78.0, 81.4)	(62.8, 68.1)	(85.8, 84.9)	<u>(82.1, 85.4)</u>	<u>(84.6, 82.2)</u>	<u>(84.6, 87.4)</u>
MPDD	(54.3, 65.4)	(63.6, 69.9)	(73.0, 80.2)	(55.1, 64.2)	(76.0, 80.4)	<u>(77.0, 82.0)</u>	(75.1, 80.1)	(77.8, 82.3)
BTAD	(34.5, 52.5)	(68.2, 70.9)	(73.6, 68.6)	(66.8, 77.4)	(88.6, 92.4)	(88.3, 87.3)	(94.8, 97.9)	<u>(93.9, 94.9)</u>
DTD-Synthetic	(71.6, 85.7)	(93.2, 92.6)	(86.4, 95.0)	(-, -)	<u>(95.5, 97.0)</u>	(93.5, 97.0)	(93.3, <u>97.8</u>)	(96.9, 98.7)
平均	(60.2, 72.5)	(79.0, 82.2)	(79.4, 83.7)	(68.4, 76.1)	(87.0, 90.2)	(86.5, 89.6)	<u>(87.7, 90.6)</u>	(89.5, 92.2)
像素级结果 (Pixel AUROC, Pixel AUPRO)								
MVTec AD	(38.4, 11.3)	(85.1, 64.6)	(87.6, 44.0)	(33.3, 6.7)	(88.7, 37.8)	(91.2, 83.2)	(91.9, 84.6)	<u>(91.8, 86.2)</u>
VisA	(46.6, 14.8)	(79.6, 56.8)	(94.2, 86.8)	(24.2, 3.8)	<u>(95.5, 56.8)</u>	<u>(95.5, 87.0)</u>	<u>(95.5, 83.0)</u>	(96.2, 91.7)
MPDD	(62.1, 33.0)	(76.4, 48.9)	(94.1, 83.2)	(15.4, 2.3)	(96.1, 60.3)	(96.5, <u>88.7</u>)	<u>(96.7, 76.5)</u>	(97.3, 89.9)
BTAD	(30.6, 4.4)	(72.7, 27.3)	(60.8, 25.0)	(28.6, 3.8)	(92.1, 32.5)	(94.2, <u>74.8</u>)	(97.0, 69.0)	<u>(96.3, 79.5)</u>
DTD-Synthetic	(33.9, 12.5)	(83.9, 57.8)	(95.3, 86.9)	(-, -)	<u>(97.7, 75.0)</u>	(97.9, 92.3)	(96.4, 85.9)	(97.9, 91.8)
平均	(42.3, 15.2)	(79.5, 51.1)	(86.4, 65.2)	(25.4, 4.2)	(94.0, 52.5)	(95.1, <u>85.2</u>)	<u>(95.5, 79.8)</u>	(95.9, 87.8)

[†] 表示训练式 anomaly-aware CLIP 强基线；本文对模块作用的同协议受控分析见表 3。

$\alpha_0 = 0$ 和 $\beta_0 = 0.01$ ，即保持异常文本原型方向不变，并对正常文本原型做保守校准。该过程只使用当前测试图像的前向特征和排序统计，不进行反向传播或模型参数更新。

为避免把不同作用混为一个系统增益，本文在 MVTec AD 和 VisA 上进一步设置受控变体。FixedProto 为原始固定文本原型。ScoreFusion 将局部结构响应直接并入异常图，用于检验结构响应是否可以直接作为定位信号。GlobalRef 使用固定全局参照，用于检验参照是否需要随当前图像变化。SemRef 只依据语义响应选择当前图像内证据，用于隔离图像条件化参照本身的作用。StructRef 在 SemRef 基础上加入边界感知结构响应但去除保守更新，用于检验局部结构线索是否改善证据选择。ICNR 在 StructRef 之上加入保守正常参照校准。

4.3 跨方法比较

表 1 按图像级和像素级结果报告五个工业基准上的零样本异常定位表现。该表采用该任务通行的 image-level 与 pixel-level 指标组织方式，便于与外部公开报告对齐。ICNR 列报告本文实现得到的五数据集结果；MVTec AD 与 VisA 上的模块作用由后续受控消融分析。

5 分析

5.1 Reference Gap 的诊断证据

表 2 给出文本侧的诊断证据。在 MVTec 样例中，detailed prompt 写入当前缺陷外观后，异常区域与背景区域的响应间隔平均增加 0.207；在 generic prompt 原本响应不足的样例中，标注异常区域的平均覆盖恢复为 0.060。这一实验说明 patch response 同时受到通用 abnormal 语义和当前样本具体外观信息的调节；ICNR 在推理流程中通过图像侧 patch 证据建模这类外观上下文。

表 2: Detailed prompt 的文本侧诊断结果。该诊断只用于分析外观上下文是否会改变 patch response, 不参与 ICNR 的推理流程。

诊断项	样例数	覆盖范围	指标	统计值
异常/背景响应间隔变化	8	5 类 / 6 缺陷	Δ gap	0.207 (0.159–0.276)
Generic 弱响应区域恢复	12	3 类 / 5 缺陷	Coverage gain	0.060 (0.016–0.156)

表 3: MVTec 与 VisA 上的图像条件化参照消融。单元为 Pixel AUROC/AUPRO 或 Image AUROC/AP。

变体	MVTec		VisA	
	Pixel	Image	Pixel	Image
FixedProto	91.2 / 83.2	91.6 / 96.4	95.5 / 86.7	82.0 / 85.3
ScoreFusion	88.7 / 80.4	92.9 / 96.9	94.6 / 85.1	81.6 / 84.8
GlobalRef	91.2 / 84.3	93.1 / 96.9	95.8 / 89.2	83.2 / 86.4
SemRef	91.6 / 85.2	93.7 / 97.1	96.0 / 90.4	83.7 / 86.9
StructRef	91.7 / 85.8	93.9 / 97.2	96.1 / 91.3	84.1 / 87.0
ICNR	91.8 / 86.2	94.5 / 97.6	96.2 / 91.7	84.6 / 87.4

MVTec AD 和 VisA 上的受控结果进一步支持 reference gap 的解释。ScoreFusion 将局部结构响应直接作为异常分数使用，MVTec 的 Pixel AUPRO 为 80.4，VisA 为 85.1，低于基于参照估计的变体。GlobalRef 相对 ScoreFusion 有明显改善，但仍低于 ICNR：MVTec 的 Pixel AUPRO 差距为 1.9，VisA 的差距为 2.5，说明固定参照不足以刻画当前图像的正常外观。SemRef 是强基线，表明主要改进来自当前图像参照估计；StructRef 在 SemRef 基础上继续提高 Pixel AUPRO，说明边界感知结构响应主要通过改善证据选择发挥作用。

5.2 局部结构响应设计

表 4 隔离了局部结构响应的使用方式。HFRef 只使用高频幅值，不抑制结构边界。BndRef 使用式 (4) 降低由低频结构边界解释的响应。最终方法进一步加入保守正常参照估计。该组消融表明，结构响应更适合作为正常参照的证据选择信号。

5.3 正常图稳定性

正常侧参照采用保守更新。表 5 报告正常图中超过两个高响应阈值的面积。ICNR 在两个数据集上均保持该误报面积稳定。这一结果与方法设计一致：图像条件化参照用于调整正常外观基准，并约束异常响应的放大范围。

6 局限性

ICNR 假设测试图像中存在足够可靠的正常 patch，以估计图像条件化正常参照。当异常覆盖大部分物体、整张图像发生分布偏移，或正常区域本身视觉上高度歧义时，估计得到的参照可能受到污染。保守更新能够降低这一风险，但不能完全消除。




图 1: 受控消融结果。ScoreFusion 较弱说明局部结构响应更适合作为证据选择信号；GlobalRef 低于图像条件化参照说明参照需要随当前图像变化；SemRef 和 StructRef 的差距反映局部结构响应对可靠证据选择的作用。

表 4: 小波局部结构响应用于参照估计的设计消融。单元为 Pixel AUROC/AUPRO 或 Image AUROC/AP。

变体	MVTec		VisA	
	Pixel	Image	Pixel	Image
ScoreFusion	88.7 / 80.4	92.9 / 96.9	94.6 / 85.1	81.6 / 84.8
SemRef	91.6 / 85.2	93.7 / 97.1	96.0 / 90.4	83.7 / 86.9
HFRef	91.6 / 85.3	94.0 / 97.2	96.0 / 90.8	84.0 / 86.9
BndRef	91.7 / 85.7	93.8 / 97.3	96.1 / 91.2	83.9 / 87.1
ICNR	91.8 / 86.2	94.5 / 97.6	96.2 / 91.7	84.6 / 87.4

局部结构响应主要处理局部纹理和结构边界混淆。对于逻辑异常、全局几何异常，或主要依赖语义关系判断的缺陷，它的作用可能较弱。当前关于模块作用的结论主要来自 MVTec AD 和 VisA 上的受控消融。更广泛的数据集结论需要同样的受控消融协议支持，而不能只由系统级结果或外部报告表格推出。

7 结论

本文指出了基于 CLIP 的零样本异常定位中的一个 reference gap。可学习的正常/异常文本原型提供跨类别语义参照，但局部异常证据仍需要当前测试图像的正常外观参照。ICNR 从冻结 CLIP 特征场中的可靠 patch 证据估计该图像条件化正常参照。小波局部结构响应用于证据选择中的局部结构变化刻画，最终异常响应相对于估计参照重新计算。MVTec AD 和 VisA 上的受控消融支持这一




图 2: 局部结构响应设计消融。曲线展示高频响应、边界抑制和保守正常参照估计对图像条件化参照质量的影响。

表 5: 正常图稳定性。FP area 表示正常图中超过对应阈值的面积比例；数值越低越好。

数据集	方法	正常图数量	FP area @ p95	FP area @ p99
MVTec	Baseline	467	5.002%	1.001%
MVTec	ICNR	467	4.895%	0.960%
VisA	Baseline	962	4.996%	1.001%
VisA	ICNR	962	4.718%	0.937%

解释：直接把结构响应作为异常分数会得到较低定位指标，固定全局参照有效但不充分，语义证据选择已经提供较强图像条件化基线，而边界感知证据选择可进一步改善正常参照估计。

可复现性与数据可用性

本文使用的表格、图和实验数据文件随 LaTeX 工程一并整理。主结果覆盖 MVTEC AD、VisA、MPDD、BTAD 和 DTD-Synthetic；受控消融使用 MVTEC AD 与 VisA。Detailed prompt 诊断实验的数据文件位于 data/detail_prompt_*. 数据访问遵循原始基准发布方的许可和使用条款。

伦理声明

本文使用公开工业异常检测基准，不涉及人体受试者或私人个人数据。




图 3: 局部结构响应强度的敏感性分析。曲线反映结构响应参与正常参照证据选择时对定位指标的影响。

AI 使用声明

本文在学术写作工具辅助下整理为中文单栏 LaTeX 版本。研究问题、证据选择、论证边界和最终内容由作者负责确认；提交前由作者核查所有实验记录、图表、引用和结论。

参考文献

- [1] Toshimichi Aota, Lloyd Teh Tzer Tong, and Takayuki Okatani. Zero-shot versus many-shot: Unsupervised texture anomaly detection. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*, pages 5564–5572, 2023. 6
- [2] Paul Bergmann, Michael Fauser, David Sattlegger, and Carsten Steger. MVTec AD – a comprehensive real-world dataset for unsupervised anomaly detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 9592–9600, 2019. 6
- [3] Yunkang Cao, Jiangning Zhang, Luca Frittoli, Yuqi Cheng, Weiming Shen, and Giacomo Boracchi. AdaCLIP: Adapting CLIP with hybrid learnable prompts for zero-shot anomaly detection. In *European Conference on Computer Vision*, pages 55–72, 2024. 1, 2, 6
- [4] Peng Chen and Chao Huang. WMoE-CLIP: Wavelet-enhanced mixture-of-experts prompt learning for zero-shot anomaly detection, 2026. 2
- [5] Xuhai Chen, Yue Han, and Jiangning Zhang. APRIL-GAN: A zero-/few-shot anomaly classification and segmentation method for CVPR 2023 VAND workshop challenge tracks 1&2. *arXiv preprint arXiv:2305.17382*, 2023. 6
- [6] Ingrid Daubechies. Orthonormal bases of compactly supported wavelets. *Communications on Pure and Applied Mathematics*, 41(7):909–996, 1988. 2, 3
- [7] Tao Gong, Qi Chu, Bin Liu, Wei Zhou, and Nenghai Yu. FE-CLIP: Frequency enhanced CLIP model for zero-shot anomaly detection and segmentation. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 21220–21230, 2025. 2

- [8] Jongheon Jeong, Yang Zou, Taewan Kim, Dongqing Zhang, Avinash Ravichandran, and Onkar Dabeer. Win-CLIP: Zero-/few-shot anomaly classification and segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 19606–19616, 2023. 1, 2, 3, 6
- [9] Stepan Jezek, Martin Jonak, Radim Burget, Pavel Dvorak, and Milos Skotak. Deep learning-based defect detection of metal parts: Evaluating current methods in complex conditions. In *2021 13th International Congress on Ultra Modern Telecommunications and Control Systems and Workshops (ICUMT)*, pages 66–71. IEEE, 2021. 6
- [10] Yiting Li, Adam David Goodge, Fayao Liu, and Chuan-Sheng Foo. PromptAD: Zero-shot anomaly detection using text prompts. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*, pages 1082–1091, 2024. 2
- [11] Wenxin Ma, Xu Zhang, Qingsong Yao, Fenghe Tang, Chenxu Wu, Yingtai Li, Rui Yan, Zihang Jiang, and S. Kevin Zhou. AA-CLIP: Enhancing zero-shot anomaly detection via anomaly-aware CLIP. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 4744–4754, 2025. 1, 2, 6
- [12] Stephane G. Mallat. A theory for multiresolution signal decomposition: The wavelet representation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 11(7):674–693, 1989. 2, 3
- [13] Pankaj Mishra, Riccardo Verk, Daniele Fornasier, Claudio Piciarelli, and Gian Luca Foresti. VT-ADL: A vision transformer network for image anomaly detection and localization. *arXiv preprint arXiv:2104.10036*, 2021. 6
- [14] Zhen Qu, Xian Tao, Mukesh Prasad, Fei Shen, Zhengtao Zhang, Xinyi Gong, and Guiguang Ding. VCP-CLIP: A visual context prompting model for zero-shot anomaly segmentation. In *European Conference on Computer Vision*, pages 301–317, 2024. 1, 2, 3
- [15] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning*, pages 8748–8763, 2021. 2, 3, 6
- [16] Manli Shu, Weili Nie, De-An Huang, Zhiding Yu, Tom Goldstein, Anima Anandkumar, and Chaowei Xiao. Test-time prompt tuning for zero-shot generalization in vision-language models. In *Advances in Neural Information Processing Systems*, 2022. 3
- [17] Naiqi Zhang, Chuancheng Shi, Jingtong Dou, Wenhua Wu, Fei Shen, and Jianhua Cao. HarmoniAD: Harmonizing local structures and global semantics for anomaly detection, 2026. 2
- [18] Kaiyang Zhou, Jingkan Yang, Chen Change Loy, and Ziwei Liu. Conditional prompt learning for vision-language models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 16795–16804, 2022. 3
- [19] Kaiyang Zhou, Jingkan Yang, Chen Change Loy, and Ziwei Liu. Learning to prompt for vision-language models. *International Journal of Computer Vision*, 130:2337–2348, 2022. 6
- [20] Qihang Zhou, Guansong Pang, Yu Tian, Shibo He, and Jiming Chen. AnomalyCLIP: Object-agnostic prompt learning for zero-shot anomaly detection. In *International Conference on Learning Representations*, 2024. 1, 2, 3, 6
- [21] Yang Zou, Jongheon Jeong, Latha Pemula, Dongqing Zhang, and Onkar Dabeer. Spot-the-difference self-supervised pre-training for anomaly detection and segmentation. In *European Conference on Computer Vision*, pages 392–408, 2022. 6