

基于图像条件化正常参照的 CLIP 零样本异常定位

Anonymous Authors

摘要

本文提出一个针对 CLIP-based 零样本异常定位的机制命题：局部视觉-文本响应只有相对于当前图像的正常外观参照解释时，才成为可靠异常证据。同样的纹理突变或高频响应，在一张图像中对应缺陷，在另一张图像中对应正常材料颗粒、结构边界或成像噪声。基于这一观察，本文将 CLIP 零样本异常定位表述为图像条件化正常参照估计问题。具体而言，在已有 CLIP/AnomalyCLIP 表征基础上，新增模块以冻结表征为输入，在测试时从单张图像内部选择可靠 patch evidence，估计当前图像的 normal reference，并据此保守校准 normal/abnormal prototypes。这样，异常分数由“局部响应有多强”转为“该局部表征相对于当前图像参照如何被评分”。这一表述与已有文献和实验材料一致：WinCLIP 证明文本原型和窗口局部特征有效，AnomalyCLIP/VCP-CLIP/AA-CLIP 等进一步通过训练式 prompts、visual context 或 adapters 改善语义对齐；本文研究已给定原型之后，单张测试图中的哪些局部响应可以成为校准证据。受控消融显示，直接使用局部高频线索作为异常图构成负控，语义响应驱动的 prototype adaptation 构成强对照，边界感知局部可靠性与保守 prototype calibration 构成当前稳定路径。

1 引言

零样本异常检测希望在没有目标类别训练样本或目标类别参考图像的情况下定位缺陷。在这一任务口径下，已有方法可以借助辅助异常数据或跨数据集训练学习更适合异常检测的表征；例如 AnomalyCLIP、AdaCLIP、VCP-CLIP 和 AA-CLIP 分别通过 prompt learning、adapter 或 visual context 模块增强 CLIP 表征。CLIP [11] 的开放词汇视觉语言对齐能力使这一任务可以被转化为 normal/abnormal prototypes 与图像表征之间的匹配问题。WinCLIP [6] 通过 normal/anomalous 状态提示和多尺度窗口特征把 CLIP 引入 zero-/few-shot anomaly classification and segmentation；其 WinCLIP+ 进一步使用少量 normal reference images 计算视觉关联分数。AnomalyCLIP [15] 学习 object-agnostic normality/abnormality prompts，使异常语义脱离具体物体名。后续工作又从 hybrid prompts [1]、visual context prompting [10]、anomaly-aware anchors and adapters [8] 等方向增强 CLIP-ZSAD。已有范式证明了 normal/abnormal 语义原型的有效性，并进一步引出异常定位中特有的问题：局部匹配响应需要图像参照才能成为局部异常证据。

异常定位关心的是当前图像中哪些区域偏离了该图像自身的正常外观规律。局部纹理变化、边界突变和高频响应经常出现在缺陷区域中，也覆盖合法的材料纹理、物体结构边缘、颗粒表面和拍摄噪声。换言之，一个 patch 的局部响应具有图像语境依赖性：相似的响应模式，在光滑金属上对应划痕，在粗糙织物上对应正常纹理。基于响应强弱的异常评分会把候选线索直接当成证据，从而混淆缺陷、正常纹理和结构边界。

这一语境依赖性形成两个机制对照：局部线索适合提出候选区域，语义自校准适合提供初始方向，二者都需要当前图像参照来完成证据判定。频率和局部结构线索已经被用于 CLIP-ZSAD，例如 FE-CLIP 用频率增强的 CLIP adapters [5]，WMoE-CLIP 用 Haar wavelet features 调整 prompt learning [2]，HarmoniAD 用频域高/低频双分支协调局部结构和全局语义 [13]。本文把频率响应作为候选证据来源，研究它在单图参照估计中的使用方式：同一类局部信号直接作为异常图会同时放大缺陷和正常纹理；由 CLIP 初始语义响应单独选择校准证据则会继承初始响应的盲区。本文因此将 CLIP 零样本异常定位重新表述为图像条件化正常参照估计问题：参照由单张测试图内部的可信局部证据估计，并与外部 normal image bank 和训练式 visual context prompt 形成互补。

在这个表述下，局部响应回答“哪里存在值得关注的变化”；异常证据进一步回答“这个变化相对于当前图像的正常外观是否异常”。具体地，我们保持 CLIP 的视觉语言表征冻结，从测试图像内部选择可信的正常与异常局部证据，构造图像条件化参照，并用该参照校准 normal/abnormal prototypes 后重新评分。该参照为 CLIP 局部响应提供当前图像内的判断基准。

本文的核心命题是：CLIP 局部响应的证据价值由图像内正常参照决定；可靠证据选择与保守 prototype calibration 能够把候选响应转化为更稳定的异常定位分数。该命题把方法设计和实验验证连接起来：方法节定义如何估计参照，机制验证节检验哪些局部响应能进入参照，以及参照校准是否保持正常图稳定。

本文的贡献可概括为三点：

- **问题表述。**我们将 CLIP-based 零样本异常定位表述为图像条件化正常参照估计，明确局部响应从候选线索转化为异常证据所需的判断基准。
- **方法原则。**我们提出图像条件化正常参照估计框架，在冻结 CLIP/AnomalyCLIP 表征的前提下从测试图像内部选择可靠局部证据，并通过 prototype calibration 重新评分局部区域。
- **机制验证。**我们用已有受控消融检验该表述：direct wavelet fusion 构成负控，semantic-only calibration 构成强对照，boundary-aware reliability 与 conservative update 验证可靠证据选择和参照校准的必要性。

本文的实验叙事围绕机制证据展开。AnomalyCLIP 使用辅助异常数据学习类别无关提示；本文新增模块在冻结表征之上运行，在测试时保持模型参数固定，并使用单张测试图内部证据完成校准。频率或局部变化在本文中是候选证据的一类；核心研究问题是这些候选证据如何在当前图像的正常参照下被校准。

2 问题表述：局部证据的图像条件化

设测试图像为 x ，冻结 CLIP 或 AnomalyCLIP 在局部位置 i 的 patch 表征为 $f_i \in \mathbb{R}^C$ 。给定 normal/abnormal text prototypes t_n, t_a ，已有 CLIP-ZSAD 方法通常通过视觉-文本相似度得到异常概率或异常图 [6, 15]。WinCLIP 从 normal/anomalous 文本状态和窗口特征出发构造局部图；AnomalyCLIP 则学习 object-agnostic normality/abnormality prompts，并在推理时合并多层 normal/anomaly 相似度图。本文沿用这一类局部相似度评分作为起点，把初始局部异常概率写为

$$s_i^0 = \frac{\exp(\langle \bar{f}_i, \bar{t}_a \rangle / \tau)}{\exp(\langle \bar{f}_i, \bar{t}_n \rangle / \tau) + \exp(\langle \bar{f}_i, \bar{t}_a \rangle / \tau)}, \quad (1)$$

其中 $\bar{\cdot}$ 表示归一化后的特征， τ 为温度参数。 s_i^0 提供有效的语义起点；异常标签还需要图像上下文给出判定参照：

$$p(y_i = 1 \mid s_i^0) \neq p(y_i = 1 \mid s_i^0, x), \quad (2)$$

其中 $y_i = 1$ 表示位置 i 属于异常区域。式 (2) 表明，一个 patch 的初始异常响应需要结合该测试图像中的正常纹理、结构边界和局部变化范围共同解释。

我们因此把目标从“寻找更强的局部响应”改写为“估计当前图像的评分参照”。令

$$r_x = \mathcal{R}(\{f_i, s_i^0, q_i\}_{i=1}^N) \quad (3)$$

表示由测试图像内部局部证据估计出的图像条件化参照，其中 q_i 表示与纯语义响应不同的局部可靠性信号。最终评分写成

$$s_i = \Psi(f_i, s_i^0; r_x), \quad (4)$$

即局部区域由其初始响应 s_i^0 与当前图像参照 r_x 共同决定。

这个表述导出三个设计要求。第一， r_x 由测试图像自身估计，对应无目标类别正常参考库的设定；这与 WinCLIP+ 使用外部 normal reference images 的设定形成互补。第二， r_x 需要包含

s_i^0 之外的局部可靠性信号，以减轻 CLIP 初始语义响应盲区对校准证据的影响。第三， r_x 将局部响应强度放入证据选择阶段，而在最终评分阶段回到 prototype 空间，从而区分缺陷、正常纹理和结构边界。后续方法节围绕这三个要求展开：如何构造局部可靠性信号，如何用它选择正常/异常证据，以及如何保守地校准 prototypes。

3 核心原则：从候选线索到校准证据

本文采用三层机制表述：候选线索、可靠证据、图像条件化参照。这个表述把局部响应、证据选择和测试时校准放在各自的位置上。

候选线索。 CLIP 初始异常概率 s_i^0 、局部纹理变化、边界突变和高频响应都属于候选线索。它们提示某个区域与异常判定相关，同时也是混合观测量：缺陷、正常纹理和物体结构都会触发它们。因此，候选线索回答“哪里值得重新检查”，可靠证据回答“哪里相对于当前图像参照异常”。

可靠证据。 可靠证据要求候选线索通过当前图像上下文的约束。对正常证据而言，一个位置应具有较低的初始异常响应，并呈现稳定的局部结构；对异常证据而言，一个位置应具有较高的初始异常响应，并呈现结构边界之外的局部变化。换言之，证据选择需要同时考虑语义倾向和局部可靠性。

图像条件化参照。 参照由测试图像内部的可靠证据形成评分基准。该参照可以表现为校准后的 normal/abnormal prototypes，也可以表现为对局部评分函数的图像条件化约束。本文采用前者：通过可靠 patch evidence 构造 visual prototypes，并用它们对 CLIP text prototypes 做保守校准。

这一参照概念与已有路线形成清晰分工。WinCLIP+ 的参照来自少量外部 normal reference images；VCP-CLIP 的图像条件化来自经过跨数据集训练的 Pre-/Post-VCP 模块；TPT 和 Co-CoOp 说明视觉语言模型中测试时或图像条件化 prompt adaptation 已经存在。本文聚焦更窄的问题：在目标类别参考库缺失、prompt 和 adapter 参数保持固定的设定下，单张测试图内部的哪些局部响应可以作为 prototype calibration evidence。

这个原则导出三个可证伪预期。第一，直接把局部可靠性图当作异常图会把正常纹理和结构边界纳入同一响应，因此它构成负控。第二，基于 CLIP 初始语义响应选择校准证据会继承初始响应的偏差；语义之外的局部可靠性约束应当改善证据选择的稳定性。第三，保守校准应当控制异常侧错误证据对 prototypes 的污染；正常图误报面积提供相应检验。第 5 节的消融表和图正是围绕这些预期组织。

4 方法：由可靠局部证据估计图像条件化参照

本节给出 Ours (unnamed) 的论文层面定义。方法以冻结 CLIP 或 AnomalyCLIP 表征为输入，在测试时使用单张图像内部证据完成校准；该过程的输入由冻结表征、初始语义响应和图像内部局部证据组成。核心思想是：先从冻结 CLIP 表征中得到初始语义响应和局部可靠性，再用二者选择可信 patch evidence，最后通过这些 evidence 校准 normal/abnormal prototypes 并重新评分。

4.1 初始语义响应

给定测试图像 x ，冻结 CLIP 产生局部 patch 表征 $\{f_i\}_{i=1}^N$ 。normal/abnormal text prototypes 记为 t_n, t_a 。初始异常概率 s_i^0 按式 (1) 计算。它是后续证据选择的语义先验： s_i^0 越大，位置 i 越倾向于异常； $1 - s_i^0$ 越大，位置 i 越倾向于正常。

s_i^0 来自 CLIP 的语义相似度。用它选择正常证据时，CLIP 语义响应较弱的细微缺陷可能进入正常集合；用它作为最终异常图时，局部材质差异也可能被语义原型误解释。因此后续步骤引入与语义响应不同的局部可靠性约束。

4.2 边界感知的局部可靠性

为了获得与纯语义响应不同的局部证据，我们在 CLIP patch feature grid 上计算一层 Haar-style 小波分解。小波多分辨率分析是经典信号表示工具 [4, 9]；本文使用它在冻结 patch feature grid 上定义逐图局部可靠性。设 $F \in \mathbb{R}^{H \times W \times C}$ 为 patch 特征网格。对每个 2×2 邻域 $(F_{00}, F_{01}, F_{10}, F_{11})$ ，定义

$$LL = \frac{1}{2}(F_{00} + F_{01} + F_{10} + F_{11}), \quad (5)$$

$$LH = \frac{1}{2}(F_{00} - F_{01} + F_{10} - F_{11}), \quad (6)$$

$$HL = \frac{1}{2}(F_{00} + F_{01} - F_{10} - F_{11}), \quad (7)$$

$$HH = \frac{1}{2}(F_{00} - F_{01} - F_{10} + F_{11}). \quad (8)$$

高频能量定义为

$$HF_i = \text{mean}_c (|LH_{i,c}| + |HL_{i,c}| + |HH_{i,c}|). \quad (9)$$

同时， LL 分量刻画较低频的结构变化。我们用其空间梯度构造结构边缘强度

$$E_i = \|\nabla LL_i\|_2. \quad (10)$$

将 HF 与 E 上采样回 patch grid，并在每张图内做 percentile clipping 和 $[0, 1]$ 归一化，得到 $\widehat{HF}_i$ 和 $\widehat{E}_i$ 。最终的 boundary-aware 局部可靠性写为

$$W_i = \text{Norm} \left(\widehat{HF}_i \cdot (1 - \widehat{E}_i) \right). \quad (11)$$

这里 W_i 作为证据选择权重使用。高频且可由结构边界解释的位置会被降权；高频且较少受低频结构解释的位置更适合作为异常侧候选证据。

4.3 语义-局部联合证据权重

我们分别构造异常证据权重和正常证据权重：

$$\omega_i^a = (s_i^0)^\gamma ((1 - \lambda) + \lambda W_i)^\eta, \quad (12)$$

$$\omega_i^n = (1 - s_i^0)^\gamma ((1 - \lambda) + \lambda(1 - W_i))^\eta. \quad (13)$$

其中 γ 控制语义响应的影响， η 控制局部可靠性的影响， λ 是局部可靠性的混合强度。这个设计对应第 3 节的原则：异常证据需要同时得到语义异常倾向和局部可靠性支持；正常证据需要同时具有语义正常倾向和较低的异常式局部可靠性。

对每张图，我们从 ω^a 和 ω^n 中分别选取 top-ratio patches，并归一化权重后形成 visual prototypes：

$$v_a = \text{Norm} \left(\sum_{i \in \mathcal{A}_x} \frac{\omega_i^a}{\sum_{j \in \mathcal{A}_x} \omega_j^a} f_i \right), \quad (14)$$

$$v_n = \text{Norm} \left(\sum_{i \in \mathcal{N}_x} \frac{\omega_i^n}{\sum_{j \in \mathcal{N}_x} \omega_j^n} f_i \right). \quad (15)$$

$\mathcal{A}_x$ 和 $\mathcal{N}_x$ 分别表示测试图像 x 内的异常侧和正常侧证据集合。它们是由语义响应和局部可靠性共同选择出的校准证据集合。

4.4 保守 prototype 校准

得到 v_a 和 v_n 后，我们校准 text prototypes。令 $c_n(x)$ 和 $c_a(x)$ 分别表示正常侧与异常侧 top-ratio evidence 的平均置信度。保守更新首先用异常侧最低置信度构造图像级门控

$$g_x = \mathbb{I}[c_a(x) \geq \delta_a], \quad (16)$$

并设置

$$\beta_x = \beta_0 c_n(x) g_x, \quad \alpha_x = \alpha_0 c_a(x) g_x. \quad (17)$$

随后校准 text prototypes:

$$t_n^x = \text{Norm}((1 - \beta_x)t_n + \beta_x v_n), \quad (18)$$

$$\hat{t}_a^x = \text{Norm}((1 - \alpha_x)t_a + \alpha_x v_a), \quad (19)$$

$$t_a^x = \begin{cases} \hat{t}_a^x, & c_a(x) \geq \max(\tau_a, \delta_a), \\ t_a, & c_a(x) < \max(\tau_a, \delta_a), \end{cases} \quad (20)$$

其中 δ_a 是最低证据门控， τ_a 是异常侧写入阈值。这个设计把测试时校准写成受控的参照估计：正常侧更新幅度由正常证据置信度和 β_0 同时限制，并且在异常侧证据达到最低门控时启用；异常侧同时受到最低门控和更高写入阈值控制。当前稳定设置采用更保守的形式：异常侧更新强度设为零，主要依赖受门控的小步正常侧参照来收紧评分基准。该选择对应一个明确机制假设：在零样本条件下，正常证据通常比异常证据更容易从单张图中可靠估计，因此 prototype calibration 优先控制异常侧漂移。

最终异常评分用校准后的 prototypes 重新计算：

$$s_i^x = \frac{\exp(\langle \bar{f}_i, \bar{t}_a^x \rangle / \tau)}{\exp(\langle \bar{f}_i, \bar{t}_n^x \rangle / \tau) + \exp(\langle \bar{f}_i, \bar{t}_a^x \rangle / \tau)}. \quad (21)$$

若使用多个 CLIP patch layers，则在每层上用同一组图像条件化 prototypes 计算局部图，再做层间融合。整个过程没有梯度反传、优化器步骤或目标域参数学习。

4.5 当前实验实现

当前受控实验采用与实现一致的保守设置。证据权重中 $\gamma = 1$ 、 $\eta = 1$ ，top-ratio 为 0.20，局部可靠性混合强度 $\lambda = 0.05$ ；可靠性图在每张图内使用 1/99 percentile clipping 后归一化。prototype calibration 使用 $\alpha_0 = 0$ 、 $\beta_0 = 0.01$ 、异常侧写入阈值 $\tau_a = 0.15$ ，最低异常证据门控 $\delta_a = 0.06$ 。在该稳定设置下，异常侧实际保持原 prototype；正常侧由正常证据置信度缩放，并受最低异常证据门控约束。这个选择与零样本异常检测的不对称性一致：从单张图中估计“正常外观参照”通常比估计“异常外观 prototype”更可靠。

4.6 方法边界

Ours (unnamed) 与直接局部线索融合形成机制对照。直接融合把 W_i 与 s_i^0 线性合成为异常图，用于检验局部线索直接成图的效果。Ours (unnamed) 将 W_i 用于证据选择和 prototype calibration，最终在 CLIP 语义空间内完成重评分。这个边界明确了论文贡献：本文建立一套由可靠局部证据估计图像条件化参照的评分机制。

5 机制验证：受控消融如何支撑机制命题

本节把已有表格和图表组织成机制命题的检验。核心问题是：CLIP 局部响应如何通过图像条件化参照成为可靠异常证据？围绕这一问题，受控实验分别检验四个环节：直接局部线索是否足以成图，语义响应能否单独完成校准，局部可靠性如何改变 evidence selection，以及保守 calibration 是否维持正常图稳定。

表 1: Controlled core ablation on MVTec and VisA. All metrics are reported in percent; the best result within each dataset and metric is marked in bold.

Dataset	Variant	Pixel AUROC	Pixel AUPRO	Image AUROC	Image AP
MVTec	Baseline	91.2	83.2	91.6	96.4
MVTec	Direct wavelet fusion / no adaptation	88.7	80.4	92.9	96.9
MVTec	Semantic prototype adaptation	91.6	85.2	93.7	97.1
MVTec	Ours w/o conservative update	91.7	85.8	93.9	97.2
MVTec	Ours (unnamed)	91.8	86.2	94.1	97.4
VisA	Baseline	95.5	86.7	82.0	85.3
VisA	Direct wavelet fusion / no adaptation	94.6	85.1	81.6	84.8
VisA	Semantic prototype adaptation	96.0	90.4	83.7	86.9
VisA	Ours w/o conservative update	96.1	91.3	84.1	87.0
VisA	Ours (unnamed)	96.2	91.7	84.3	87.3




图 1: 受控核心消融的顺序关系。该图验证机制路径：直接局部线索为负控，语义 prototype adaptation 是强对照，加入可靠局部证据和保守校准后形成最终方法。

5.1 命题一：直接局部线索构成负控

直接把局部可靠性图与初始语义响应融合，可以检验局部线索直接成图的机制假设。表 1 中 direct wavelet fusion 的像素级结果低于 baseline、semantic prototype adaptation 和最终方法：在 MVTec 上为 88.7/80.4，在 VisA 上为 94.6/85.1。这一负控说明，局部高频或结构变化本身提供候选区域；在本文机制中，它们进入 evidence selection，作为 prototype calibration 前的可靠性约束。图 1 给出从 baseline 到最终方法的顺序关系。

表中的行对应不同的可证伪预期。Baseline 检验固定 prototypes 下的初始语义响应；Direct wavelet fusion / no adaptation 检验局部可靠性图直接成图的效果；Semantic prototype adaptation 检验语义响应驱动的图像条件化校准，它是强对照；Ours w/o conservative update 检验可靠证据选择在缺少保守门控时的稳定性；最终 Ours (unnamed) 同时使用语义先验、边界感知可靠性和保守校准。这个顺序使表 1 成为机制路径检验：分数随证据选择和校准机制逐步变好，而直接局部融合构成反向证据。

5.2 命题二：证据选择需要语义之外的局部可靠性

以 s_i^0 选择 normal/abnormal evidence 会继承 CLIP 初始语义响应的偏差。表 2 将 semantic-only prototype adaptation、HF-only reliability、boundary-aware reliability 和最终保守校准放在

表 2: Wavelet reliability design ablation on MVTec and VisA. All metrics are reported in percent; the best result within each dataset and metric is marked in bold.

Dataset	Variant	Pixel AUROC	Pixel AUPRO	Image AUROC	Image AP
MVTec	Direct wavelet fusion	88.7	80.4	92.9	96.9
MVTec	Semantic-only prototype adaptation	91.6	85.2	93.7	97.1
MVTec	HF-only reliability + prototype adaptation	91.6	85.3	94.0	97.2
MVTec	Boundary-aware reliability + prototype adaptation	91.7	85.7	93.8	97.3
MVTec	Ours (unnamed)	91.8	86.2	94.1	97.4
VisA	Direct wavelet fusion	94.6	85.1	81.6	84.8
VisA	Semantic-only prototype adaptation	96.0	90.4	83.7	86.9
VisA	HF-only reliability + prototype adaptation	96.0	90.8	84.0	86.9
VisA	Boundary-aware reliability + prototype adaptation	96.1	91.2	83.9	87.1
VisA	Ours (unnamed)	96.2	91.7	84.3	87.3




图 2: 局部可靠性设计消融。该图检验证据选择机制: semantic-only 使用初始语义响应, HF-only 引入原始局部变化, boundary-aware 进一步抑制结构边界混淆, 最终方法加入保守 prototype 校准。

同一受控路径中。该表支持两个判断: 第一, 局部可靠性进入 evidence selection 后, 结果相对于 semantic-only 继续提升; 第二, boundary-aware reliability 在像素级 AUPRO 上相对于 HF-only 更稳定, 符合“高频线索需要排除结构边界解释”的机制假设。

更具体地, 高频可靠性行检验“原始高频是否足够作为证据选择信号”; 边界感知可靠性行检验“抑制低频结构边界后, 证据选择是否更符合参照估计假设”; 最终 Ours (unnamed) 进一步检验“可靠证据选择与保守 prototype calibration 配套后是否形成稳定参照”。因此, 表 2 的作用是区分三种机制解释: 直接局部变化、语义自校准、以及语义先验约束下的边界感知证据选择。

5.3 命题三：参照校准必须保守

图像条件化参照需要控制错误证据写入。当前稳定设置令异常侧保持原 prototype, 并采用受置信度缩放和门控约束的小步正常侧校准。正常图稳定性验证支持这一选择: 相对于 baseline, 最终方法的正常图误报面积更低。表 3 汇总了已记录的正常图统计, MVTec 的 p95/p99 FP area 从 5.002/1.001 降至 4.895/0.960, VisA 从 4.996/1.001 降至 4.718/0.937。

表 3: 正常图稳定性。FP area 表示在正常图上超过对应阈值的面积比例, 越低越好。该表检验保守校准对正常图误报面积的影响。

Dataset	Method	Normal images	FP area @ p95	FP area @ p99
MVTec	Baseline	467	5.002%	1.001%
MVTec	Ours (unnamed)	467	4.895%	0.960%
VisA	Baseline	962	4.996%	1.001%
VisA	Ours (unnamed)	962	4.718%	0.937%

5.4 命题四: 系统级结果与机制结论分层对应

已有五数据集结果和 ICONIP-style baseline 表格展示系统级表现; 上述受控机制验证支撑本文的机制命题。对于 MVTec/VisA, 受控表检验的是 Ours (unnamed) 相对于 semantic-only / direct fusion 的机制路径; 对于 MPDD、BTAD 和 DTD-Synthetic, 当前结果包含 system-level 设置, 并区分 global setting 与 dataset-tuned upper bound。五数据集表适合回答完整系统在不同数据集上的表现, 本节的受控表负责回答机制来源。

这一分层对应两类证据功能: 包含 multi-crop 或 pixel-to-image calibration 的系统级行展示完整系统表现; 受控消融解释 prototype-reference 机制。本文的机制 claim 由受控消融支撑: direct local cue scoring 是负控, semantic-only calibration 是强对照, 可靠局部证据与保守图像条件化参照共同构成最终方法。由此, 表格和图形成一条连续证据链: 候选局部线索先被证伪为直接异常图, 再作为 evidence selection 约束进入参照估计, 最后通过正常图稳定性验证其校准幅度。

6 相关工作

本文与三类工作相关: CLIP-based zero-shot anomaly detection、频率/局部结构异常线索、以及测试时适配与参照估计。这三条线索共同界定本文的研究位置: 在已有 visual-language prototypes 和局部响应基础上, 研究单张测试图内部的 evidence 如何形成图像条件化 normal reference。

CLIP-based zero-shot anomaly detection. WinCLIP [6] 用 compositional prompt ensemble 描述 normal/anomalous states, 并通过多尺度窗口特征得到语言对齐的局部异常图; 其 WinCLIP+ 版本进一步用少量 normal reference images 构造视觉关联分数。PromptAD [7]、AnomalyCLIP [15] 和 AdaCLIP [1] 分别从文本提示、object-agnostic prompt learning、static/dynamic hybrid learnable prompts 改善异常语义表示, 其中 AnomalyCLIP 等路线使用辅助异常数据学习 normality/abnormality prompts。VCP-CLIP [10] 通过训练式 Pre-/Post-VCP 将 global 与 patch-level visual contexts 注入 text embeddings, AA-CLIP [8] 则通过 anomaly-aware text anchors、residual adapters 和 patch alignment 增强 normal/abnormal 可分性。也有工作从 representative vector selection 与 staged dual-path 的角度提高直接相似度图的稳定性 [3]。这些工作主要回答“如何得到更适合异常检测的视觉-文本表示或提示”。本文回答互补问题: 当 normal/abnormal prototypes 已经给定后, 单张测试图中的哪些局部响应可以作为校准证据, 哪些局部响应承担候选线索的角色。

频率与局部结构线索。 频率信息、纹理变化和局部结构细节对异常定位有价值, 这一点已有工作已经充分利用。FE-CLIP [5] 用频率增强的 CLIP adapters 将 DCT 相关信息注入视觉特征; WMoE-CLIP [2] 用 Haar wavelet decomposition 得到高/低频特征, 并通过 mixture-of-experts prompt learning 进行跨模态增强; HarmoniAD [13] 将 CLIP features 投入频域, 分离高频结构路径和低频语义路径进行联合建模。这些方法建立了频率线索在 CLIP-ZSAD 中的相关性。本文采用 Haar-style 2×2 feature-grid 分解来定义局部可靠性, 并把频率信号放在 evidence selection 阶

段: boundary-aware 局部可靠性选择 patch evidence, 最终异常图由校准后的 CLIP prototype 相似度给出。直接小波融合在本文中构成负控, 用于检验局部线索直接成图对缺陷、正常纹理和结构边界的区分能力。

测试时适配与参照估计。 测试时适配和图像条件化提示在视觉语言模型中已有研究, 例如 test-time prompt tuning [12] 和 conditional prompt learning [14]。在异常检测中, WinCLIP+ [6] 通过少量 normal reference images 改善需要视觉参照的异常; VCP-CLIP [10] 用图像视觉上下文更新文本嵌入, 并通过跨数据集训练获得该上下文模块。本文估计的是单张测试图内部的图像条件化 normal reference; prompt 和 adapter 参数在测试时保持固定, evidence selection 由语义响应和局部可靠性共同决定。

因此, 本文与上述表示学习或 prompt learning 路线形成分工: 已有路线学习更适合异常检测的 prototypes 或上下文模块, 本文在已有 CLIP/AnomalyCLIP prototypes 的基础上, 研究局部候选线索如何通过当前图像参照转化为可靠异常证据。这个定位与实验组织一致: 外部方法界定背景, 机制结论由 direct fusion、semantic-only calibration、boundary-aware reliability 和 conservative calibration 的受控比较支持。

7 适用范围与局限

本文的机制表述适用于测试图像内部存在可估计正常区域的局部异常定位场景。在异常覆盖范围很大、整幅图像发生分布偏移、或正常区域本身极难识别时, 图像条件化参照会受到异常证据影响。当前方法通过保守正常侧校准控制这一影响; 整图异常和正常区域难以分离的场景更适合结合全局判别机制。

其次, 本文强调局部响应的语境依赖性; 不同类别中的语境来自材质纹理、结构边界、光照变化或成像噪声等因素。现有 boundary-aware reliability 主要处理“高频纹理与结构边界混淆”这一类问题; 逻辑异常、几何关系异常或全局语义异常对应更强的全局关系建模。

再次, 本文新增模块在测试时保持模型参数固定; 底座 CLIP 与 AnomalyCLIP 表征及提示向量来自大规模预训练或辅助异常数据。因而, 本文结论聚焦于“在给定冻结表征之上, 新增校准模块如何使用单图证据”。

最后, 本文的机制性结论来自 MVTec/VisA 受控消融。五数据集系统级结果展示整体表现, 其中 MPDD、BTAD 和 DTD-Synthetic 包含 global setting 与 dataset-tuned upper bound 的差异, 适合在实验节或附录中单独标注。进一步扩展外部 baseline 或跨数据集比较时, split、backbone、input resolution、post-processing、训练数据和 metric implementation 将作为实验协议的一部分统一说明; 定性图将围绕“局部线索需要图像内参照”的机制案例组织。

8 结论

本文将 CLIP 零样本异常定位从直接局部响应评分重新表述为图像条件化正常参照估计。局部响应可以提示潜在异常, 其证据价值由当前图像的正常外观上下文决定。基于这一认识, Ours (unnamed) 在给定冻结 CLIP/AnomalyCLIP 表征和 normal/abnormal prototypes 的前提下, 从测试图像内部选择可靠局部证据, 构造图像条件化 prototypes, 并在同一语义空间内重新评分。

MVTec/VisA 受控消融支持这一机制解释: 直接局部线索使用是负控, 语义响应自校准是强对照, 边界感知局部可靠性和保守参照校准共同形成稳定路径。本文的核心 takeaway 是一个可检验的异常证据定义: 候选局部线索经过当前图像正常参照约束后, 成为异常定位证据。

参考文献

- [1] Yunkang Cao, Jiangning Zhang, Luca Frittoli, Yuqi Cheng, Weiming Shen, and Giacomo Boracchi. AdaCLIP: Adapting CLIP with hybrid learnable prompts for zero-shot anomaly detection. In *European Conference on Computer Vision*, pages 55–72, 2024.
- [2] Peng Chen and Chao Huang. WMoE-CLIP: Wavelet-enhanced mixture-of-experts prompt learning for zero-shot anomaly detection, 2026.
- [3] Xuhai Chen, Jiangning Zhang, Guanzhong Tian, Haoyang He, Wuhao Zhang, Yabiao Wang, Chengjie Wang, and Yong Liu. CLIP-AD: A language-guided staged dual-path model for zero-shot anomaly detection, 2024.
- [4] Ingrid Daubechies. Orthonormal bases of compactly supported wavelets. *Communications on Pure and Applied Mathematics*, 41(7):909–996, 1988.
- [5] Tao Gong, Qi Chu, Bin Liu, Wei Zhou, and Nenghai Yu. FE-CLIP: Frequency enhanced CLIP model for zero-shot anomaly detection and segmentation. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 21220–21230, 2025.
- [6] Jongheon Jeong, Yang Zou, Taewan Kim, Dongqing Zhang, Avinash Ravichandran, and Onkar Dabeer. WinCLIP: Zero-/few-shot anomaly classification and segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 19606–19616, 2023.
- [7] Yiting Li, Adam David Goodge, Fayao Liu, and Chuan-Sheng Foo. PromptAD: Zero-shot anomaly detection using text prompts. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*, pages 1082–1091, 2024.
- [8] Wenxin Ma, Xu Zhang, Qingsong Yao, Fenghe Tang, Chenxu Wu, Yingtai Li, Rui Yan, Zihang Jiang, and S. Kevin Zhou. AA-CLIP: Enhancing zero-shot anomaly detection via anomaly-aware CLIP. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 4744–4754, 2025.
- [9] Stephane G. Mallat. A theory for multiresolution signal decomposition: The wavelet representation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 11(7):674–693, 1989.
- [10] Zhen Qu, Xian Tao, Mukesh Prasad, Fei Shen, Zhengtao Zhang, Xinyi Gong, and Guiguang Ding. VCP-CLIP: A visual context prompting model for zero-shot anomaly segmentation. In *European Conference on Computer Vision*, pages 301–317, 2024.
- [11] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning*, pages 8748–8763, 2021.
- [12] Manli Shu, Weili Nie, De-An Huang, Zhiding Yu, Tom Goldstein, Anima Anandkumar, and Chaowei Xiao. Test-time prompt tuning for zero-shot generalization in vision-language models. In *Advances in Neural Information Processing Systems*, 2022.
- [13] Naiqi Zhang, Chuancheng Shi, Jingtong Dou, Wenhua Wu, Fei Shen, and Jianhua Cao. HarmoniAD: Harmonizing local structures and global semantics for anomaly detection, 2026.

- [14] Kaiyang Zhou, Jingkang Yang, Chen Change Loy, and Ziwei Liu. Conditional prompt learning for vision-language models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 16795–16804, 2022.
- [15] Qihang Zhou, Guansong Pang, Yu Tian, Shibo He, and Jiming Chen. AnomalyCLIP: Object-agnostic prompt learning for zero-shot anomaly detection. In *International Conference on Learning Representations*, 2024.